



Universidade Federal
de Campina Grande

PROCESSAMENTO ADAPTATIVO DE SINAIS - 2026

**RASTREAMENTO BIDIMENSIONAL DE ALVOS VIA FILTRO DE KALMAN
ESTENDIDO EM SISTEMAS DE POSICIONAMENTO POR ESTAÇÃO BASE**

Professor: Dr. Edson Porto da Silva

Aluno: Saulo José Almeida Silva

saulo.jose.silva@ee.ufcg.edu.br

24/06/2026

Sumário

1. Contexto e Motivação;

2. Objetivos;

3. Fundamentação Teórica;

3.1. Conceito de Belief (Crença) e Filtros de Bayes;

3.2. Filtro de Kalman;

3.3. Por que EKF?;

4. Formulação do Problema;

4.1. Descrição do Problema;

4.2. Descrição dos Modelos;

5. Metodologia;

5.1. A arquitetura do simulador;

5.2. Métricas de Avaliação;

5.3. Cenários Experimentais;

6. Resultados;

6.1. Trajetórias;

6.2. Gráficos de RMSE;

6.3. NIS e Histogramas;

6.4. Caso Especial: Oclusão;

6.5. Resumo dos resultados;

7. Conclusão;

8. Trabalhos Futuros

Referências Bibliográficas

1. Contexto e Motivação

- **Localização** é um requisito **fundamental** para a autonomia de robôs móveis.
- Em *Probabilistic Robotics*, Thrun, Burgard e Fox (2005) destacam a localização como **um dos problemas fundamentais da robótica móvel**.
- **Erros instrumentais** e **ruídos aleatórios** comprometem a qualidade das **estimativas** de posição;
- Soluções baseadas em GPS/IMU e **multilateração** demandam técnicas de **filtragem probabilística** para reduzir incertezas.

1. Contexto e Motivação




Tabela 1: Síntese do Estado da Arte e Comparação com o Trabalho Proposto

Referência / Autor	Foco Principal e Contexto	Plataforma, Métricas e Diferenciais
Caron et al. (2004)	Fusão sensorial de dados GPS/IMU utilizando filtragem de Kalman multissensor.	Introdução e análise de aspectos contextuais na fusão de dados.
Falek & Kaniewski (2010)	Estudo do Filtro de Kalman Estendido (EKF) em multilateração, avaliando o impacto do número de estações base (2, 3 e 4).	Desenvolvido em MATLAB . Avaliação limitada ao RMSE e ao erro máximo .
Chen et al. (2018)	Auto sintonia de Filtros de Kalman utilizando Otimização Bayesiana.	Utilização das métricas estatísticas NEES e NIS para consistência do filtro.
Trabalho Proposto (Baseado em Thrun, Burgard & Fox e Falek & Kaniewski)	Diagnóstico bidimensional e validação espacial do Filtro de Kalman aplicado ao contexto de multilateração.	Desenvolvido em Python (código aberto com GUI interativa e modular). Avaliação conjunta de acurácia (RMSE) e consistência (NIS). Validação espacial de crença (Métrica de Inliers via ROI dinâmica) e Análise de Resíduos (normalidade e viés).

2. Objetivos

➤ Objetivo Geral


Desenvolver, Implementar e avaliar o desempenho de um **Filtro de Kalman Estendido (EKF)** para o contexto de **rastreamento** bidimensional sob **restrições não lineares** de medição.

➤ Objetivo Específicos

1. **Modelar** a cinemática do alvo (modelo PVA) e as equações não-lineares de medição de distância (*range-only*);
2. **Estruturar** o algoritmo recursivo do Filtro de Kalman Estendido (EKF) para o rastreamento 2D;
3. **Desenvolver** um ambiente de simulação modular em Python com interface gráfica (GUI) interativa;
4. **Validar** o estimador combinando métricas geométricas (RMSE, Taxa de Inliers) e estatísticas (NIS) relativo à sua sintonia;
5. **Analisar** a precisão e o comportamento do modelo sob condições de oclusão temporária de sinal.

3. Fundamentação Teórica: Robótica Probabilística

3.1. Conceito de *Belief* (Crença) e Filtros de Bayes



“[...] A robot that carries a notion of its own uncertainty and that acts accordingly, will do better than one that does not.”

- THRUN; BURGARD; FOX, 2005.

3. Fundamentação Teórica: Robótica Probabilística

3.1. Conceito de *Belief* (Crença) e Filtros de Bayes

A **crença** (*belief*) representa a **estimativa** que o robô possui sobre **seu estado** e sua **incerteza**, enquanto o **Filtro de Bayes** é o método matemático que atualiza essa estimativa com base nas medições dos sensores e no modelo do sistema.

$$bel(\mathbf{x}_k) = P(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k)$$

Algorithm 2 Filtro de Bayes

Require: $bel(x_{k-1})$, u_k , z_k

Predição (Atualização pelo Movimento):

$$1: \bar{bel}(x_k) \leftarrow \int p(x_k \mid u_k, x_{k-1}) bel(x_{k-1}) dx_{k-1}$$

Correção (Atualização pela Medição):

$$2: bel(x_k) \leftarrow \eta p(z_k \mid x_k) \bar{bel}(x_k)$$

Ensure: $bel(x_k)$




Figure 7.4 Illustration of the Markov localization algorithm. Each picture depicts the position of the robot in the hallway and its current belief $bel(x)$. (b) and (d) additionally depict the observation model $p(z_t \mid x_t)$, which describes the probability of observing a door at the different locations in the hallway.

3. Fundamentação Teórica: Robótica Probabilística

3.2. Filtro de Kalman

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k$$

O Filtro de Kalman é aplicado a modelos lineares do tipo **Gauss-Markov**, assumindo que os ruídos de processo e de medição são **Gaussianos** de média nula, isto é, $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q})$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R})$.

Algorithm 1 Filtro de Kalman Linear

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$


Predição (Propagação do Modelo):

- 1: $\hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$
- 2: $\mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

- 3: $\mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$
- 4: $\hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$
- 5: $\mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$



3. Fundamentação Teórica: Robótica Probabilística

3.2. Por que o EKF?

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \boldsymbol{\epsilon}_k$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \boldsymbol{\delta}_k$$

Quando o modelo de transição de estados ou de observação não é no **formato linear**, é utilizado uma linearização por expansão de **séries de Taylor** calculando, portanto, as jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$, substituindo as matrizes $\mathbf{A}_k$ e $\mathbf{H}_k$ no algoritmo do filtro.

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \hat{\mathbf{x}}_{k-1|k-1}}$$
$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}}$$

Algorithm 2 Filtro de Kalman Estendido (EKF)

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

- 1: $\hat{\mathbf{x}}_{k|k-1} \leftarrow g(\mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$
- 2: $\mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$
- 3: $\mathbf{P}_{k|k-1} \leftarrow \mathbf{G}_k \mathbf{P}_{k-1|k-1} \mathbf{G}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

- 4: $\mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$
- 5: $\mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$
- 6: $\hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}))$
- 7: $\mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$


4. Formulação do Problema

4.1. Descrição do Problema

- **Objeto:** Robô móvel em plano 2D.
- **Descrição do ambiente:** 4 estações base fixas (x_i, y_i) (âncoras).
- **Desafio:** Melhorar a estimativa (x, y) do robô via medições de distância ruidosas D_i do robô até as torres i .

$$D_i = \sqrt{(x_i - x_r)^2 + (y_i - y_r)^2} + \delta_i$$

$$\delta_i \sim \mathcal{N}(0, \sigma^2)$$



4. Formulação do Problema

4.2. Descrição dos Modelos Utilizados

Transição de Estados

Vetor de Estado:

$$\mathbf{x}_k = [x, y, \dot{x}, \dot{y}, \ddot{x}, \ddot{y}]^T$$

Matriz de Transição de Estados:

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

Covariância do erro do modelo:

Contínuo: $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$

Discreto: $\mathbf{Q}_d \approx \mathbf{Q}_c \Delta T \quad (\Delta T \ll 1)$

Observação (Não linear)

Vetor de Observações:

$$\mathbf{z}_k = [D_{1,k}, D_{2,k}, D_{3,k}, D_{4,k}]^T$$

Matriz de Transição de Estados:

$$\mathbf{z}_k = h(\mathbf{x}_k) \quad h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2}$$

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_k | k-1}$$


Covariância do erro da medição:

$$\mathbf{R}_d = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$$


5. Metodologia

5.1. Arquitetura e interface do Simulador

Arquitetura



Interface



5. Metodologia

5.2. Métricas de Avaliação

NIS (Normalized Innovation Squared)

Métrica para verificar se o estimador é consistente do ponto de vista estatístico.

$$\boldsymbol{\nu}_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1})$$

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k$$

$$\epsilon_k = \boldsymbol{\nu}_k^T \mathbf{S}_k^{-1} \boldsymbol{\nu}_k$$

$$IC = [\chi_{\alpha,n}^2, \chi_{1-\alpha,n}^2]$$

$$IC = [0,484; 11,143]$$

RMSE (Root Mean Square Error)

Métrica para verificar se o estimador é consistente do ponto de vista estatístico.

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2}$$

TAXA DE INLIERS (TI)*

Métrica **apenas visual** para avaliar a crença do robô ($\mathbf{P}$) de forma semelhante ao NIS.

$$\mathbf{P}_{\text{pos}} = \mathbf{P}_{k|k}^{(1:2,1:2)}$$



$$\tilde{\mathbf{p}}_k = [x_{GT,k} - \hat{x}_{k|k}, y_{GT,k} - \hat{y}_{k|k}]^T$$

$$TI = \tilde{\mathbf{p}}_k^T (\mathbf{P}_{\text{pos}})^{-1} \tilde{\mathbf{p}}_k$$

$$TI \in [0,051; 7,378]$$

5. Metodologia

5.2. Métricas de Avaliação




5. Metodologia

5.3. Cenários Experimentais

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Circular	Quadrada	Tanh	Lemniscata	Nav. Aleatória	Oclusão Cíclica
Movimento	$v = 10,0 \text{ m/s}$ $r = 30,0 \text{ m}$	$v = 10 \text{ m/s}$ $L = 40,0 \text{ m}$	$A_y = 20,0 \text{ m}$ $v = 10,0 \text{ m/s}$	$v = 10,0 \text{ m/s}$ $A = 35,0 \text{ m}$	$v_0 = 8,0 \text{ m/s}$ $\epsilon_v = 0,5 \text{ m/s}$	$v = 5,0 \text{ m/s}$ 30 fr/occlusão
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Posição das Torres (x,y)	$B_1[10, 10]; B_2[190, 10]; B_3[190, 130]; B_4[10, 130]$					
Tempo de Simulação (s)	40					
Taxa de Quadros (FPS)	30					
Semente Aleatória (Seed)	42					
Ruído nas Torres (σ)	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$
Matriz Processo $Q_{6 \times 6}$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1I_4$ (Sup.)	$0,1I_4$ (Sup.)	$0,01I_4$ (Sub.)	$0,09I_4$	$0,01I_4$ (Sub.)	$0,01I_4$ (Sub.)
Matriz Processo $Q_{6 \times 6}$	$0,01I_6$ (Sub.)	$0,01I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,3I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,05I_6$ (Sub.)

Nota: I_n representa a matriz identidade de dimensão $n \times n$, denotando configurações diagonais. A matriz R apresenta um superdimensionamento conservador intencional ($0,9I_4$), não refletindo estritamente a variância do ruído injetado (σ^2). No Cenário 4 (Não Sintonizado), R foi propositalmente mantido inalterado para isolar e avaliar exclusivamente o efeito da subestimação de Q . (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.




Taxa de amostragem = $1 / \text{FPS} = 33 \text{ ms}$

6. Resultados


6.1 Trajetórias

Cenário 2

a) Filtro sintonizado



b) Filtro não sintonizado




6. Resultados


6.2. Gráficos do RMSE

Cenário 2

a) Sintonizado




b) Não Sintonizado



6. Resultados

6.3. NIS e Histogramas: Cenários Sintonizados


a) NIS



(a) Círculo

(b) Quadrado

(c) Tangente Hiperbólica




(d) Lemniscata

(e) Aleatória

(f) Oclusão


b) Histogramas dos Erros



(a) Círculo

(b) Quadrado

(c) Tangente Hiperbólica



(d) Lemniscata

(e) Aleatória

(f) Oclusão

6. Resultados

6.3. NIS e Histogramas: Cenários Não sincronizados


a) NIS



(a) Círculo

(b) Quadrado

(c) Tangente Hiperbólica




(d) Lemniscata

(e) Aleatória

(f) Oclusão


b) Histogramas dos Erros



(a) Círculo

(b) Quadrado

(c) Tangente Hiperbólica



(d) Lemniscata


(e) Aleatória

(f) Oclusão


6. Resultados

6.4. Caso especial: Oclusão

Animação com ROI



Cenário 6



6. Resultados

6.5. Resumo dos Resultados

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	$RMSE_x$ [m]	$RMSE_y$ [m]	$E_{\max}$ [m]	μ_x [m]	$\overline{NIS}$	$NIS \in IC$ [%]	TD [%]	TI [%]
CONDIÇÃO SINTONIZADA ($Q = 0,64I_6$; $R = 0,09I_4$)								
Cenário 1	0,11	0,16	0,64	+0,01	3,39	96,33	100,00	100,00
Cenário 2	0,13	0,18	0,58	0,00	3,86	95,84	100,00	96,88
Cenário 3	0,12	0,14	0,58	+0,00	3,34	96,58	100,00	100,00
Cenário 4	0,11	0,15	0,58	+0,01	3,34	97,17	100,00	100,00
Cenário 5	0,11	0,16	0,57	+0,00	3,49	96,58	100,00	100,00
Cenário 6	0,17	0,34	2,62	+0,01	3,40	95,19	90,00	100,00
CONDIÇÃO NÃO SINTONIZADA (Parâmetros Descalibrados)								
Cenário 1	0,23	0,34	0,75	+0,01	6,76	80,25	100,00	10,08
Cenário 2	0,60	0,82	2,24	-0,02	24,07	49,48	100,00	28,07
Cenário 3	0,16	0,20	0,79	+0,00	23,85	26,75	100,00	97,25
Cenário 4	0,14	0,20	0,74	+0,01	25,50	22,67	100,00	93,83
Cenário 5	0,15	0,21	0,73	+0,00	24,14	26,08	100,00	96,25
Cenário 6	0,17	0,33	2,62	+0,01	31,67	15,56	90,00	71,76

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limites bicaudais do NIS a 95% de confiança para 4 G.L. são [0, 484; 11, 143]. TD: Taxa de Detecção; TI: Taxa de *Inliers*.

Obs: Sistemas a GPS podem ter erros de até 3 metros, melhorando devido a configuração.

7. Conclusão

Esse estudo serviu como forma de analisar na prática o comportamento de um filtro de Kalman e entender seu comportamento, associando à área de **robótica probabilística** e verificar o comportamento do **NIS** e **RMSE** na avaliação do Filtro.

Contribuições:

- Simulador com Interface GUI;
- Análise prática da ideia de um ROI dinâmico, útil em contexto de visão computacional;
- Conteúdo **didático**;

Limitações

- Estudo limitado a **ruídos puramente gaussianos**;
- **Desconsiderado distúrbios severos** encontrados na prática (multipath, NLOS);
- Calibração manual;
- Os resultados são apenas **experimentais** em ambiente simulado.

Obs: Interface e demais resultados podem ser encontrados no Github do projeto (<https://github.com/SauloJose/PASKalmanTraj>).

8. Trabalhos Futuros

- Implementar algoritmos de **Sintonia Automática** das matrizes Q e R ;
- Integrar com algoritmos de visão computacional utilizando a estratégia de ROI dinâmico para diminuir custo computacional no processamento de imagens;
- Utilizar **filtros avançados**, como Unscented Kalman Filter (UKF) e comparar com o EKF

On the Identification of Noise Covariances and Adaptive Kalman Filtering: A New Look at a 50 Year-Old Problem

LINGYI ZHANG¹, DAVID SIDOTI², ADAM BIENKOWSKI¹,
KRISHNA R. PATTIPATI¹, (Life Fellow, IEEE),
YAAKOV BAR-SHALOM¹, (Life Fellow, IEEE),
AND DAVID L. KLEINMAN¹, (Life Fellow, IEEE)

¹Department of Electrical and Computer Engineering, University of Connecticut, Storrs, CT 06269, USA

²U.S. Naval Research Laboratory, Marine Meteorology Division, Monterey, CA 93943, USA

Corresponding author: Lingyi Zhang (lingyi.zhang@uconn.edu)

This work was supported in part by the U.S. Office of Naval Research and U.S. Naval Research Laboratory under Grant N00014-18-1-1238, Grant N00173-16-1-G905, and Grant HPCM034125HQ. The work of David Sidoti was supported by a Karles Fellowship Award at the Naval Research Laboratory in Monterey, CA, USA. The work of Krishna R. Pattipati was supported in part by the Space Technology Research Institutes from NASA's Space Technology Research Grants Program under Grant 80NSSC19K1076.

REFERÊNCIAS BIBLIOGRÁFICAS

- CARON, F.; DUFLOS, E.; POMORSKI, D.; VANHEEGHE, P. Gps/imu data fusion using multisensor kalman filtering: Introduction of contextual aspects. Information Fusion, v. 7, n. 2, p. 221–230, 2006. Disponível em: <https://www.sciencedirect.com/science/article/pii/S156625350400065X>. Acesso em: 24 jun. 2026.
- CHEN, S. Y. Kalman filter for robot vision: A survey. IEEE Transactions on Industrial Electronics, v. 59, n. 11, p. 4409–4419, 2012.
- CHEN, Z.; HECKMAN, C.; JULIER, S. Weak in the nees?: Auto-tuning kalman filters with bayesian optimization. [S. l.: s. n.], 2018. Disponível em: <https://arxiv.org/abs/1807.08855>. Acesso em: 24 jun. 2026.
- FAŁEK, P.; KANIEWSKI, P. Computer application for testing kalman filter. In: CONFERENCE PROCEEDINGS OF SPIE, 11442., 2020. Proceedings [...]. [S. l.]: SPIE, 2020. p. 1144213.
- SILVA, S. J. A. Ferramenta de simulação e rastreamento bidimensional via EKF. 2026. Repositório GitHub. Disponível em: <https://github.com/SauloJose/PASKalmanTraj>. Acesso em: 13 jun. 2026.
- Simon, D. Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches. Wiley, 2006;
- Thrun, S., Burgard, W., & Fox, D. Probabilistic Robotics. MIT Press, 2005.;



Universidade Federal
de Campina Grande

Obrigado!

Saulo José Almeida Silva.
saulo.jose.silva@ee.ufcg.edu.br

24/06/2026