

Rastreamento Bidimensional de Alvos via Filtro de Kalman Estendido em Sistemas de Posicionamento por Estações Base

Saulo José Almeida Silva, *Mestrando, UFCG,*

Resumo—A localização precisa é um requisito fundamental para a operação autônoma de sistemas robóticos móveis. Este trabalho propõe o desenvolvimento de um ambiente de simulação *open-source* em *Python*, projetado para a auditoria geométrica e estatística de algoritmos de estimação de estado. Como estudo de caso para a validação da ferramenta, investiga-se o rastreamento bidimensional de alvos via Filtro de Kalman Estendido (EKF) a partir de medições não lineares de distância (*range-only*), utilizando um modelo cinemático de Posição-Velocidade-Aceleração (PVA). A arquitetura desenvolvida viabiliza o monitoramento simultâneo da acurácia posicional (RMSE), da consistência estatística pelo *Normalized Innovation Squared* (NIS) e da convergência espacial por meio da Taxa de *Inliers*. Os ensaios demonstram que, sob sintonia adequada das matrizes de processo ($\mathbf{Q}$) e medição ($\mathbf{R}$), o filtro atinge precisão submétrica e robustez a oclusões. Em contrapartida, as simulações de descalibração revelam um risco inerente à avaliação puramente geométrica: subestimar $\mathbf{R}$ gera taxas de *inliers* artificialmente altas enquanto corrompe o NIS, mascarando o estresse probabilístico do estimador. Conclui-se que a plataforma atende de forma rigorosa à necessidade de cruzar métricas espaciais e probabilísticas para atestar a verdadeira confiabilidade em sistemas de navegação.

Index Terms—Filtro de Kalman Estendido, Localização em Tempo Real, Posicionamento *Range-Only*, Consistência Estatística.

I. INTRODUÇÃO

A O passo que os sistemas robóticos autônomos assumem tarefas mais complexas, cresce também a exigência por soluções de navegação precisas e confiáveis. Para mitigar as incertezas inerentes a esse processo, a literatura tem apostado fortemente em arquiteturas de fusão sensorial — que combinam dados de múltiplos sensores — associadas a análises estatísticas das medições. Essa integração tem se mostrado essencial para refinar a estimativa de estado do sistema e viabilizar sua aplicação no mundo real [1], [2].

O grande desafio no desenvolvimento dessas soluções de localização está nos erros instrumentais e nos ruídos estocásticos que afetam a dinâmica do robô. Mesmo sob uma modelagem cinemática detalhada, perturbações ambientais e não-linearidades — presentes tanto na resposta física dos sensores quanto na própria dinâmica veicular — acabam inserindo margens inevitáveis de imprecisão no estado estimado.

Para contornar essa limitação e obter estimativas de alta fidelidade, utiliza-se o Filtro de Kalman (KF), um estimador ótimo iterativo para sistemas lineares sob o critério do erro

quadrático mínimo [3]. Como parte da família dos filtros bayesianos, o KF estima variáveis de estado não mensuradas diretamente, o que viabiliza sua aplicação em cenários de observabilidade incompleta [4]. Essa formulação clássica, no entanto, é limitada em sistemas de posicionamento baseados em distância (alcance), cujas equações de observação são essencialmente não-lineares. Nesses cenários, aplica-se o Filtro de Kalman Estendido (EKF), que contorna a não linearidade por meio da linearização do modelo em torno da estimativa corrente [4], [5].

Embora o EKF possua uma fundamentação teórica consolidada, seu sucesso prático depende diretamente do ajuste das matrizes de covariância do processo ($\mathbf{Q}$) e de medição ($\mathbf{R}$). A sintonia desses parâmetros requer simulações computacionais detalhadas, etapa essencial no desenvolvimento de sistemas de navegação. Um exemplo dessa abordagem é o trabalho de Falek e Kaniewski [6], que propuseram um ambiente em MATLAB para avaliar o comportamento do EKF em redes de posicionamento baseadas em estações fixas.

Nesse contexto, este trabalho apresenta um simulador em Python voltado à análise do rastreamento bidimensional de alvos via quatro estações base. A ferramenta integra uma GUI interativa para avaliar a acurácia posicional (RMSE), a consistência estatística (NIS) e o comportamento da crença do robô (Taxa de *Inliers*). Para detalhar essa abordagem, o artigo está estruturado da seguinte forma: a Seção II revisa a fundamentação do EKF; a Seção III detalha a modelagem cinemática proposta; a Seção IV descreve a metodologia e as métricas de validação; a Seção V discute os resultados comparativos de sintonia; e a Seção VI apresenta as conclusões e trabalhos futuros.

A. Notação e Convenções

Neste trabalho, adota-se a seguinte convenção de notação: escalares são representados por letras minúsculas em itálico (a), vetores por minúsculas em negrito ($\mathbf{a}$ ou $\hat{\mathbf{x}}$) e matrizes por maiúsculas em negrito ($\mathbf{A}$ ou $\mathbf{P}$).

No domínio discreto, o subscrito k denota a variável física real no instante de tempo atual (como o estado $\mathbf{x}_k$ ou a medição $\mathbf{z}_k$). Por outro lado, os estados e as covariâncias calculados pelo estimador utilizam uma notação composta:

- $k|k-1$: indica os valores *a priori* (etapa de predição), computados a partir do histórico do sistema até o instante $k-1$, tais como o estado predito $\hat{\mathbf{x}}_{k|k-1}$ e a covariância do erro $\mathbf{P}_{k|k-1}$.

- $k|k$: representa os valores *a posteriori* (etapa de correção), atualizados após a incorporação da nova medição, tais como o estado corrigido $\hat{\mathbf{x}}_{k|k}$ e a covariância do erro $\mathbf{P}_{k|k}$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta a fundamentação teórica necessária para o desenvolvimento do estimador estocástico. A discussão avança da modelagem de sistemas e representation de incertezas até os filtros de estimação sequencial e suas respectivas métricas de validação estatística.

A. Modelagem Estocástica e Justificativa Probabilística

A representação clássica de sistemas dinâmicos em espaço de estados baseia-se em formulações determinísticas ideais, descritas por $\dot{\mathbf{x}}(t) = f(\mathbf{x}(t), \mathbf{u}(t))$ e $\mathbf{z}(t) = h(\mathbf{x}(t))$, as quais pressupõem conhecimento exato da física do modelo e sensores isentos de falhas [7]. Em contrapartida, robôs móveis operando em ambientes reais estão sujeitos a perturbações dinâmicas não modeladas (ruído de processo) e imperfeições transdutivas inerentes (ruído de medição) [2]. A incapacidade dos modelos determinísticos em acomodar tais distúrbios justifica a transição para variáveis estocásticas, em que o estado deixa de ser um ponto invariante e passa a ser tratado como uma densidade de probabilidade condicional. Esse tratamento probabilístico garante a estabilidade matemática do estimador sob condições de incerteza severa [6].

B. Robótica Probabilística e a Suposição de Markov

A robótica probabilística mitiga as incertezas operacionais computando a crença (*belief*) do agente, definida como a distribuição a posteriori do estado $\mathbf{x}_k$ condicionada ao histórico de entradas $\mathbf{u}_{1:k}$ e medições $\mathbf{z}_{1:k}$ [4]:

$$bel(\mathbf{x}_k) = P(\mathbf{x}_k | \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (1)$$

Para viabilizar o processamento em tempo real, adota-se a **Suposição de Markov**, que postula que o estado atual $\mathbf{x}_k$ constitui uma estatística suficiente do sistema. Dessa forma, o comportamento futuro independe do histórico de estados passados, permitindo a decomposição recursiva do *belief* nas etapas sequenciais de predição e correção [4].

C. O Modelo Gauss-Markov e a Discretização Temporal

O cálculo analítico do *belief* torna-se tratável sob o **Modelo Gauss-Markov**, o qual assume processos lineares cujos ruídos de processo (ϵ_k) e medição (δ_k) são brancos, de média nula e gaussianos [8]. Devido à propriedade de conservação estatística de transformações lineares sobre variáveis gaussianas, o *belief* permanece estritamente gaussiano ao longo do tempo [9]. Consequentemente, o rastreamento do sistema reduz-se à atualização do vetor de médias ($\hat{\mathbf{x}}$) e da matriz de covariância ($\mathbf{P}$).

Dado que os processadores digitais operam de forma amostrada em intervalos Δt , o sistema contínuo é discretizado

mantendo-se a estrutura do modelo Gauss-Markov [8], resultando em:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k$$

onde $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$, e a matriz de covariância discreta $\mathbf{Q}_k$ preserva o acoplamento cruzado das incertezas cinemáticas sem a necessidade de expansões integrais explícitas. Para extensões não lineares, adota-se a linearização local por matrizes Jacobianas baseada na aproximação de primeira ordem de Taylor [4].

D. Algoritmo do Filtro de Kalman

O Filtro de Kalman (Linear e Estendido) configura a solução ótima para a propagação do *belief* gaussiano em sistemas markovianos [4]. O ciclo recursivo do estimador baseia-se na estrutura descrita pelas etapas de predição e correção [8], [9]:

1) Etapa de Predição (Propagação):

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k \quad (2)$$

$$\mathbf{P}_{k|k-1} = \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k \quad (3)$$

2) Etapa de Correção (Atualização):

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1} \quad (4)$$

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1}) \quad (5)$$

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} \quad (6)$$

Em cenários não lineares (Filtro de Kalman Estendido), as matrizes fixas $\mathbf{A}_k$ e $\mathbf{H}_k$ são substituídas pelas matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$ avaliadas localmente a cada passo de tempo [4]. Na ausência temporária de medições sensoriais, a etapa de correção é suprimida e o filtro opera em malha aberta, o que acarreta o crescimento monótono da matriz de covariância $\mathbf{P}$.

E. Métricas de Avaliação e Consistência Estocástica

O desempenho do estimador é validado por meio de critérios geométricos e testes estatísticos de consistência baseados nos resíduos da inovação [9]. A precisão espacial é quantificada pela Raiz do Erro Quadrático Médio (RMSE), calculada sobre um horizonte de N amostras:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (7)$$

A consistência estatística do filtro é verificada via teste do Quadrado da Inovação Normalizado (NIS). A inovação $\nu_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1})$ e sua respectiva covariância teórica $\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k$ (onde a matriz de covariância predita provém da equação 3) definem o escalar NIS através da forma quadrática:

$$\epsilon_k = \nu_k^T \mathbf{S}_k^{-1} \nu_k \quad (8)$$

Sob condições ideais de parametrização, ϵ_k assume uma distribuição Qui-Quadrado (χ^2) com graus de liberdade equivalentes à dimensão do vetor de medições $\mathbf{z}_k$, validando rigorosamente a sintonia das matrizes de covariância de ruído [9].

III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Este capítulo detalha o cenário de rastreamento bidimensional baseado exclusivamente em dados de distância (*range-only tracking*) [9] utilizado para avaliar o Filtro de Kalman Estendido (EKF). A evolução cinemática do agente é modelada sob o paradigma de Posição, Velocidade e Aceleração (PVA), expandindo a metodologia descrita em [6].

A. Descrição do Problema

O problema consiste em estimar a trajetória plana de um robô móvel operando em uma arena monitorada por $M = 4$ estações fixas (âncoras) com coordenadas conhecidas $\mathbf{p}_i = [X_i, Y_i]^T$ ($i = 1, \dots, 4$), conforme esquematizado na Figura 1. Desprovido de sensores odométricos ou de velocidade própria, o agente depende unicamente de medições escalares de distância obtidas por radiofrequência ou acústica. O objetivo do estimador é reconstruir recursivamente as coordenadas cartesianas, velocidades e acelerações instantâneas do robô a partir dessas observações ruidosas.




Figura 1: Representação geométrica do sistema de posicionamento *range-only* com quatro estações base fixas nos vértices da arena.

B. Modelo Cinemático de Processo (Espaço de Estados PVA)

O estado do robô no instante discreto k é definido pelo vetor expandido $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$. Sob regime de aceleração constante (CA) integrado no intervalo de amostragem Δt , a matriz de transição de estados $\mathbf{A}_k$ (6×6) é dada por:

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (9)$$

As incertezas dinâmicas decorrentes de perturbações ambientais e erros de modelagem são incorporadas via matriz de densidade espectral de potência contínua e diagonal

$\mathbf{Q}_c = \text{diag}(q_1, \dots, q_6)$ [4]. A matriz de covariância discreta equivalente, $\mathbf{Q}_k$, é obtida analiticamente através da integração estocástica $\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau$. Esse procedimento gera uma estrutura esparsa e simétrica na qual os blocos polinomiais de ordem superior em Δt mapeiam o acoplamento cruzado das incertezas entre posição, velocidade e aceleração de forma independente para os eixos X e Y , garantindo o desacoplamento estocástico e eliminando a necessidade de representações algébricas extensas.

C. Modelo de Observação e Geometria das Estações Base

O vetor de observações sensoriais a cada passo é $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$. A relação não linear entre o estado cinemático do robô e a distância escalar até a i -ésima âncora é modelada por:

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (10)$$

Uma vez que as leituras dependem unicamente da posição cartesiana, as derivadas parciais em relação à velocidade e aceleração são nulas [9], resultando na matriz Jacobiana $\mathbf{H}_k$ (4×6):

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix} \quad \mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1} \quad (11)$$

O ruído instrumental é parametrizado pela matriz de covariância diagonal $\mathbf{R}_k = \text{diag}(\sigma_1^2, \dots, \sigma_4^2)$.

D. Cenário de Desafio: Modelagem de Oclusão Temporal

Para estressar o estimador e validar a consistência estatística via teste NIS, projetou-se uma janela de oclusão severa no intervalo $t \in [t_{\text{start}}, t_{\text{end}}]$, na qual as medições de todas as âncoras são inteiramente suprimidas ($\mathbf{z}_{i,k} \rightarrow \emptyset$). Sob regime nominal (Figura 2a), a fusão de dados contínua restringe a elipse de incerteza. Durante a interrupção do sinal, o algoritmo opera estritamente com base na predição cinemática da Equação (9). Sem a etapa de correção, as incertezas acumuladas via $\mathbf{Q}_k$ propagam-se rapidamente na matriz $\mathbf{P}_{k|k-1}$, provocando a expansão geométrica progressiva do ROI dinâmico ao longo da trajetória do robô (Figuras 2b e 2c).

IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo detalha a metodologia utilizada para avaliar o desempenho, a sensibilidade e a robustez à oclusão do estimador proposto. A apresentação segue a ordem lógica dos experimentos: inicialmente, descreve-se a geração cinemática das trajetórias de referência. Em seguida, detalham-se os cenários de teste e a modelagem do filtro. Por fim, definem-se as métricas estatísticas aplicadas na avaliação do Filtro de Kalman Estendido (EKF) sob diferentes parametrizações.




Figura 2: Evolução temporal do ROI dinâmico: as elipses cinza e verde denotam as incertezas predita ($\mathbf{P}_{k|k-1}$) e corrigida ($\mathbf{P}_{k|k}$), evidenciando a divergência em malha aberta durante a supressão de dados.

A. Síntese Cinemática das Trajetórias de Referência

Para que a precisão do Filtro de Kalman Estendido (EKF) possa ser avaliada, é indispensável compará-lo a um referencial absoluto e livre de ruídos, o *Ground Truth*. Nessa etapa, o simulador atua como um gerador de gabaritos: ele calcula a física exata do alvo para cada instante discreto k e armazena essas informações no vetor de estado $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$, que engloba as posições, velocidades e acelerações reais nos eixos ortogonais.

Como um alvo em uma aplicação real pode apresentar desde um trajeto altamente previsível até manobras bruscas, o simulador foi projetado para testar os limites do estimador utilizando duas abordagens distintas de movimento:

- **Curvas paramétricas analíticas (Determinísticas):** Simulam cenários onde o alvo obedece a regras geométricas bem definidas e contínuas. Servem para testar o filtro sob dinâmicas estáveis e previsíveis.
- **Modelos numéricos comportamentais (Estocásticos):** Inserem aleatoriedade na navegação do alvo. Servem para testar a capacidade de adaptação do EKF quando o objeto realiza trajetórias erráticas ou mudanças repentinas de direção.

O conjunto completo dessas trajetórias, abrangendo todos os perfis cinemáticos abordados nos testes, pode ser visualizado na Figura 3.

1) *Geração de Curvas Paramétricas e Analíticas:* Para os testes com movimentos contínuos e regulares, as posições do alvo no simulador são ditadas por funções trigonométricas e hiperbólicas dependentes do tempo. Para garantir que o *Ground Truth* seja matematicamente exemplar e livre de erros de discretização, a velocidade e a aceleração do alvo são extraídas a partir da diferenciação analítica exata das equações de posição. Os parâmetros geométricos específicos que governam a geração de cada um desses cenários estruturados (Circular, Quadrada e Tanh) encontram-se mapeados e detalhados diretamente na Tabela I.

2) *Geração de Navegação Aleatória e Oclusões:* Para aproximar a simulação do comportamento estocástico de um alvo real, adotou-se uma dinâmica de navegação aleatória, onde o agente altera sua direção e velocidade sob perturbações controladas, contando com um mecanismo de evasão caso

atinga os limites da arena. Os componentes probabilísticos de movimento, as janelas de oclusão temporal e os respectivos níveis de ruído físico aplicados a cada simulação encontram-se sintetizados e referenciados na Tabela I, que centraliza toda a parametrização experimental e elimina a necessidade de descrição algorítmica linear.

B. Cenários de Simulação e Estratégia de Sintonia

Para avaliar o estimador na prática, a campanha de testes foi dividida em **6 cenários cinemáticos** (ilustrados na Figura 3), abrangendo diferentes perfis de aceleração e condições de oclusão. Além do movimento do alvo, o comportamento do EKF depende diretamente das suas matrizes de covariância ($\mathbf{Q}_k$ para o processo e $\mathbf{R}_k$ para a medição). Para testar a robustez e a sensibilidade do algoritmo a esses parâmetros, cada cenário foi avaliado sob **duas condições de sintonia distintas**:

- 1) **Situação Sintonizada (Filtro Calibrado):** Representa a condição de funcionamento ideal do rastreador. Os valores das matrizes foram ajustados de forma empírica, baseando-se nas propriedades do ambiente e refinados por tentativa e erro até que o filtro apresentasse o melhor desempenho. A matriz de medição foi definida como $\mathbf{R} = 0,09\mathbf{I}_4$ (quadrado do desvio padrão do ruído das torres, $\sigma = 0,30$ m), enquanto a matriz de processo foi fixada em $\mathbf{Q} = 0,64\mathbf{I}_6$ ($0,8^2$), assumindo estatisticamente as incertezas de modelagem do movimento. O critério de sucesso foi a minimização do erro de posição aliada a elipses de confiança visualmente e estatisticamente coerentes com a trajetória real.
- 2) **Situação Não Sintonizada (Filtro Descalibrado):** Representa falhas na configuração do projeto. Nessa etapa, os valores das matrizes foram intencionalmente alterados por superestimação (Sup.) ou subestimação (Sub.). O objetivo de impor essas condições anormais é avaliar a sensibilidade do estimador, demonstrar o impacto do desalinhamento de covariâncias no erro adaptativo e comprovar a importância de uma sintonia rigorosa.

A Tabela I consolida todas as variáveis utilizadas nos testes: a configuração de movimento do alvo, o nível de ruído físico (σ) simulado nos sensores e os valores numéricos utilizados




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos.

para sintonizar (or descalibrar) o EKF em cada um dos seis cenários.

C. Configuração do Estimador e Modelagem do Ruído

O estimador visa determinar o vetor de estado completo do alvo ($\mathbf{x}_k$), detalhado na Seção III. Os dados de entrada do algoritmo consistem nas medições de distância entre o robô e quatro estações rádio-base localizadas no perímetro da área de testes.

A modelagem do erro instrumental é realizada pela inserção de ruído gaussiano branco de média nula e desvio padrão σ (conforme especificado na Tabela I) às distâncias ideais obtidas do *Ground Truth*. Esse procedimento gera o vetor de observação não linear $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$, que alimenta diretamente o EKF de acordo com a Equação (12):

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (12)$$

Embora o EKF opere diretamente com as distâncias em sua forma não linear ($\mathbf{z}_k$), o sistema executa um cálculo paralelo. Para fornecer suporte visual à interface gráfica e subsídio para validações externas, o sistema computa uma coordenada cartesiana de apoio $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$ via algoritmo numérico de multilateração por Mínimos Quadrados, sem interferência direta nas etapas recursivas do Filtro de Kalman.

D. Ambiente Computacional e Infraestrutura de Simulação

Para automatizar a execução dos cenários e garantir a reprodutibilidade dos dados, o simulador foi desenvolvido em *Python* (versão 3.10) utilizando uma arquitetura modular, conforme ilustrado na Figura 4. O processamento matricial e a computação vetorizada do EKF foram implementados com a biblioteca *NumPy*.




Figura 4: Diagrama da arquitetura de software da aplicação de simulação, destacando o fluxo de dados entre o gerador de trajetórias, o estimador de estados e a camada de aplicação.

Conforme detalhado no diagrama, a arquitetura divide-se logicamente entre o núcleo de simulação e a camada de aplicação. O fluxo de execução inicia-se na Interface Gráfica do Usuário (GUI), onde são definidos os parâmetros iniciais, incluindo a sintonia empírica das matrizes de covariância de processo ($\mathbf{Q}_k$) e de ruído de medição ($\mathbf{R}_k$). Esses parâmetros alimentam o bloco *Simulador*, onde o *Gerador de Trajetórias* estabelece a cinemática real do alvo (*ground truth*).

Para avaliar adequadamente a capacidade de estimação do filtro, a trajetória exata é ramificada para dois destinos: o *Gerenciador de Métricas* (servindo como base de comparação para o cálculo de erros) e a *Modelagem do Mundo e das Entidades*. Este último atua como o simulador do sistema de localização, convertendo as posições reais em distâncias ruidosas relativas a quatro torres (multilateração). Essa pseudo-observação ruidosa alimenta, então, a etapa de *Correção* do

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Circular	Quadrada	Tanh	Lemniscata	Nav. Aleatória	Oclusão Cíclica
Movimento	$v = 10,0 \text{ m/s}$ $r = 30,0 \text{ m}$	$v = 10 \text{ m/s}$ $L = 40,0 \text{ m}$	$A_y = 20,0 \text{ m}$ $v = 10,0 \text{ m/s}$	$v = 10,0 \text{ m/s}$ $A = 35,0 \text{ m}$	$v_0 = 8,0 \text{ m/s}$ $\epsilon_v = 0,5 \text{ m/s}$	$v = 5,0 \text{ m/s}$ 30 fr/occlusão
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Posição das Torres (x,y)	$B_1[10, 10]; B_2[190, 10]; B_3[190, 130]; B_4[10, 130]$					
Tempo de Simulação (s)	40					
Taxa de Quadros (FPS)	30					
Semente Aleatória (Seed)	42					
Ruído nas Torres (σ)	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$
Matriz Processo $Q_{6 \times 6}$	$0.64I_6$	$0.64I_6$	$0.64I_6$	$0.64I_6$	$0.64I_6$	$0.64I_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1I_4$ (Sup.)	$0,1I_4$ (Sup.)	$0,01I_4$ (Sub.)	$0,09I_4$	$0,01I_4$ (Sub.)	$0,01I_4$ (Sub.)
Matriz Processo $Q_{6 \times 6}$	$0,01I_6$ (Sub.)	$0,01I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,3I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,05I_6$ (Sub.)

Nota: I_n representa a matriz identidade de dimensão $n \times n$, denotando configurações diagonais. A matriz R apresenta um superdimensionamento conservador intencional ($0,9I_4$), não refletindo estritamente a variância do ruído injetado (σ^2). No Cenário 4 (Não Sintonizado), R foi propositalmente mantido inalterado para isolar e avaliar exclusivamente o efeito da subestimação de Q . (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.

Filtro de Kalman, que trabalha em malha fechada com a *Predição* estocástica.

A GUI, construída nativamente com a biblioteca *Tkinter*, não se limita à parametrização, atuando também na camada de *Aplicação*. Ela integra o *Visualizador de Vídeo* — que renderiza instantaneamente o vetor de observações e a elipse de incerteza da região de interesse (ROI) — e os painéis do *Gerenciador de Métricas*, que acompanham as estatísticas de NIS e RMSE. Apesar dessa integração visual para inspeção qualitativa, o núcleo numérico do simulador opera de forma independente, garantindo que as campanhas de teste em lote e a geração de arquivos de log ocorram de forma assíncrona e automatizada.

E. Métodos de Avaliação e Consistência

O desempenho do EKF é avaliado pela sua precisão espacial e consistência estatística. A acurácia geométrica é quantificada pela Raiz do Erro Quadrático Médio (RMSE), calculada de forma independente para os eixos X e Y ao comparar as estimativas *a posteriori* ($\hat{x}_{k|k}, \hat{y}_{k|k}$) com o *Ground Truth*. O erro médio com sinal (ME) também é monitorado para identificar eventuais vieses sistemáticos no rastreamento.

Embora a análise espacial meça a exatidão geométrica, ela não garante o equilíbrio estatístico do estimador. Para a validação formal de consistência, utiliza-se o *Normalized Innovation Squared* (NIS). O teste do NIS avalia se a magnitude dos resíduos de inovação é coerente com a incerteza teórica parametrizada nas matrizes de covariância Q_k e R_k [9].

1) *Validação da Crença do Estimador (Inlier Rate)*: Como métrica complementar em ambiente de simulação, a convergência da crença (*belief*) do filtro é avaliada graficamente pela taxa de *inliers*. Por depender do *Ground Truth*, essa abor-

dagem restringe-se à calibração e análise do comportamento do modelo frente a dados sintéticos controlados.

Baseando-se no conceito de elipsoide de erro [4], quantifica-se a proporção de frames em que o estado real (x_{GT}, y_{GT}) permanece contido na fronteira de incerteza do filtro. A validação baseia-se na distância de Mahalanobis aplicada sobre a submatriz de covariância de posição *a posteriori* $P_{\text{pos}} = P_{k|k}^{(1:2,1:2)}$. Definindo o vetor de erro real como $\tilde{p}_k = [x_{GT,k} - \hat{x}_{k|k}, y_{GT,k} - \hat{y}_{k|k}]^T$, o estado é classificado como um *inlier* se atender à restrição:

$$\tilde{p}_k^T (P_{\text{pos}})^{-1} \tilde{p}_k \leq M \quad (13)$$

em que M é o valor crítico da distribuição Qui-Quadrado (χ^2) bicaudal com 2 graus de liberdade para o nível de significância adotado.

Para a renderização em tempo real na interface gráfica, a elipse é aproximada por uma janela delimitadora (*bounding box*) baseada no critério 3σ . Os desvios-padrão marginais teóricos são dados por:

$$\sigma_{x,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(1,1)})} \quad (14)$$

$$\sigma_{y,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(2,2)})} \quad (15)$$

Os limites semi-eixais da janela visual (L_x, L_y) incorporar uma constante de salvaguarda inferior $\tau_{\min}$ para evitar o colapso da caixa em cenários de incerteza nula ou falhas de inicialização:

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{filt}}) \quad (16)$$

$$L_y = \max(\tau_{\min}, 3\sigma_{y,\text{filt}}) \quad (17)$$

A Figura 5 ilustra a correlação espacial entre a elipse probabilística (Equação 13) e a janela ortogonal de renderização (Equações 16 e 17), permitindo aferir qualitativamente se a dispersão das estimativas é coerente com a evolução da matriz P .

2) *Análise de Estabilidade Estatística via Limites de Confiança do NIS*: Enquanto a taxa de *inliers* atua como um validador visual externo restrito à simulação, o NIS avalia a estabilidade matemática de forma independente do *Ground Truth*, refletindo a operação real do algoritmo. O teste de hipóteses é governado por um intervalo de confiança bicaudal de 95%, cujos graus de liberdade (*DOF*) dependem do número de torres de recepção ativas na multilateração a cada passo de tempo k .

Para um cenário padrão com 4 graus de liberdade (4 *DOF*), os limites críticos da tabela χ^2 são $\chi_{0.025,4}^2 = 0,484$ (inferior) e $\chi_{0.975,4}^2 = 11,143$ (superior). O histórico do NIS permite classificar o comportamento dinâmico do EKF em três regimes:

- **Filtro Consistente**: O NIS oscila predominantemente dentro dos limites calculados. Espera-se que aproximadamente 95% das amostras temporais residam nessa faixa, validando a representação correta da própria incerteza do filtro.
- **Filtro Otimista (Subestimação do Erro)**: O NIS ultrapassa repetidamente o limite superior. Isso indica que os resíduos reais são significativamente maiores do que a covariância calculada em P , sinalizando que o filtro confia excessivamente no modelo preditivo em detrimento das medições, o que gera risco de divergência.
- **Filtro Pessimista (Superestimação do Erro)**: O NIS permanece abaixo do limite inferior. Nesse estado, a matriz de covariância cresce de forma desproporcional aos resíduos de inovação. O filtro torna-se excessivamente conservador e lento para responder a variações dinâmicas do alvo.




Figura 5: Representação da métrica de *inliers*. A elipse validada estatisticamente a convergência frente ao *Ground Truth*, enquanto a janela retangular delimita a incerteza para fins de visualização na GUI.

V. RESULTADOS E DISCUSSÃO

Este capítulo detalha a avaliação experimental do Filtro de Kalman Estendido (EKF) ao longo dos seis cenários de navegação propostos na Seção IV. A análise fundamenta-se em métricas de acurácia posicional (RMSE e Erro Máximo), consistência estatística (NIS) e validação espacial (Taxa de *Inliers*). Para avaliar a sensibilidade do algoritmo, os ensaios comparam o EKF com matrizes calibradas em contraponto a uma configuração intencionalmente descalibrada. A Tabela II consolida os indicadores quantitativos obtidos na simulação.

O código-fonte do simulador, os dados brutos e as imagens em alta resolução estão publicamente disponíveis no repositório do projeto no GitHub¹.

A. Interface Gráfica e Ambiente de Simulação

A Figura 6 exibe o ambiente de simulação desenvolvido para este estudo. A interface gráfica integra a renderização espacial da arena, a telemetria das posições estimadas face ao *ground truth* e os painéis de monitoramento temporal de RMSE e NIS. Essa estrutura permite a manipulação direta das matrizes de covariância Q e R , viabilizando a análise empírica do impacto da calibração nas elipses de incerteza do filtro.

B. Análise de Acurácia Posicional e Distribuição de Erros

A parametrização do EKF correlaciona-se de forma direta com a eficácia de atenuação do ruído intrínseco das observações. A configuração sintonizada mantém o RMSE posicional global em patamares sub-métricos estritos em todos os cenários operando sob visibilidade contínua das estações base. Mesmo diante de transições cinemáticas abruptas e descontinuidades de aceleração ortogonal — representadas de forma crítica nos vértices da trajetória quadrada do Cenário 2 —, o alinhamento correto do filtro garante robustez geométrica, amortecendo desvios e contendo o erro máximo absoluto de modo a evitar oscilações espúrias.

Em contrapartida, a imposição de um regime dinâmico descalibrado, caracterizado pelo engessamento do ganho de transição, incapacita o estimador de acompanhar variações transientes de aceleração. Essa assimetria temporal introduz um atraso de fase clássico nas vizinhanças de manobras bruscas, resultando na degradação severa do erro médio quadrático e na amplificação exponencial do pico de erro máximo absoluto.

A caracterização estocástica dos resíduos de predição valida esse comportamento. Sob calibração ideal, os erros ortogonais de estimação distribuem-se de forma assintoticamente aderente a uma normal bivariada ideal com viés médio nulo. Sob descalibração, contudo, o descompasso geométrico rompe a simetria gaussiana do estimador, induzindo o surgimento de distribuições com caudas pesadas e dispersões deslocadas que evidenciam o erro sistemático acumulado.

¹Disponível em: <https://github.com/SauloJose/PASKalmanTraj> - Acesso em: 22 jun. 2026.

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	$RMSE_x$ [m]	$RMSE_y$ [m]	E_{max} [m]	μ_x [m]	NIS	$NIS \in IC$ [%]	TD [%]	TI [%]
CONDIÇÃO SINTONIZADA ($Q = 0,64I_6$; $R = 0,09I_4$)								
Cenário 1	0,11	0,16	0,64	+0,01	3,39	96,33	100,00	100,00
Cenário 2	0,13	0,18	0,58	0,00	3,86	95,84	100,00	96,88
Cenário 3	0,12	0,14	0,58	+0,00	3,34	96,58	100,00	100,00
Cenário 4	0,11	0,15	0,58	+0,01	3,34	97,17	100,00	100,00
Cenário 5	0,11	0,16	0,57	+0,00	3,49	96,58	100,00	100,00
Cenário 6	0,17	0,34	2,62	+0,01	3,40	95,19	90,00	100,00
CONDIÇÃO NÃO SINTONIZADA (Parâmetros Descalibrados)								
Cenário 1	0,23	0,34	0,75	+0,01	6,76	80,25	100,00	10,08
Cenário 2	0,60	0,82	2,24	-0,02	24,07	49,48	100,00	28,07
Cenário 3	0,16	0,20	0,79	+0,00	23,85	26,75	100,00	97,25
Cenário 4	0,14	0,20	0,74	+0,01	25,50	22,67	100,00	93,83
Cenário 5	0,15	0,21	0,73	+0,00	24,14	26,08	100,00	96,25
Cenário 6	0,17	0,33	2,62	+0,01	31,67	15,56	90,00	71,76

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limites bicaudais do NIS a 95% de confiança para 4 G.L. são [0, 484; 11, 143]. TD: Taxa de Detecção; TI: Taxa de *Inliers*.




Figura 6: Ambiente gráfico desenvolvido em Python. O painel central exibe a cinemática do alvo, ladeado pelos controles de simulação à esquerda e gráficos de monitoramento temporal à direita.




Figura 7: Evolução temporal do RMSE (Cenário 2). A estabilidade da curva reflete a consistência do filtro quando devidamente sintonizado frente a manobras evasivas.


C. Consistência Estatística e Monitoramento do NIS

A estatística *Normalized Innovation Squared* (NIS) constitui o mecanismo formal de auditoria interna do filtro, avaliando a coerência entre o elipsoide de incerteza teórica calculado na


matriz P e a magnitude dos resíduos de inovação reais. Sob condições sintonizadas, o estimador preserva um equilíbrio rigoroso, com a média operacional estável do NIS aproximando-se da esperança matemática teórica e mantendo as taxas de violação marginal estritamente contidas dentro do intervalo de confiança estabelecido.

O núcleo desta análise de sensibilidade reside na identificação do **fenômeno de falso positivo estatístico** gerado pela subestimação da matriz de covariância do ruído de medição (R). Ao parametrizar o estimador com uma variância instrumental artificialmente reduzida (Cenários 3, 4, 5 e 6 descalibrados), força-se o algoritmo a interpretar medições inerentemente ruidosas como absolutas. Esse viés preserva o RMSE posicional em patamares baixos, forçando o filtro a perseguir o ruído de alta frequência e gerando uma falsa percepção macroespacial de acurácia.

Contudo, esse comportamento mascara o colapso completo da consistência probabilística: por subestimar a dispersão real dos sensores, os resíduos de inovação tornam-se desproporci-



(a) Condição Sintonizada



(b) Condição Não Sintonizada

Figura 8: Histogramas e dispersão dos erros de predição (Cenário 2). Em (a), a condição sintonizada converge para uma distribuição normal centrada no zero. Em (b), a ausência de calibração induz dispersão irregular e acúmulo de erros de fase.

onalmente maiores do que a incerteza teórica admitida pelo filtro. O resultado direto é a completa destruição do indicador NIS, cujos valores médios disparam patologicamente e cujas taxas de permanência dentro das fronteiras críticas despencam de forma severa, denunciando um estimador excessivamente otimista e altamente vulnerável à divergência em condições não generalizadas.

Por outro lado, o acoplamento descalibrado inverso — pautado pela superestimação de $\mathbf{R}$ concomitante à subestimação crônica da dinâmica de processo $\mathbf{Q}$ — induz inércia severa no estimador. Ao negligenciar as transições físicas do veículo, o filtro gera inovações persistentemente elevadas que estouram o limite bicaudal superior do NIS em grande parte das amostras temporais, configurando um regime de operação pessimista e tardio.

D. Região de Confiança e Taxa de Inliers

A Taxa de Inliers (TI) quantifica a integridade espacial da crença do filtro com base na distância quadrática de Mahalanobis. A sintonia fina reflete-se em taxas de cobertura ótimas em trajetórias de curvatura contínua, garantindo que as elipses probabilísticas envolvam o estado real de forma fidedigna. Mesmo perante a severidade geométrica do quadrado, a calibração mantém a concordância estatística estável.

Sob descalibração restritiva com redução de $\mathbf{Q}$, ocorre um estreitamento incorreto das elipses teóricas associado ao atraso




Figura 9: Comportamento temporal da métrica NIS. A calibração adequada mantém o parâmetro próximo à média teórica (4, 0) e abaixo do limite crítico superior (11, 14).

cinemático de fase. Esse colapso geométrico faz com que a região de confiança calculada pelo filtro falhe em englobar a posição real do veículo, acarretando uma queda drástica na TI e evidenciando a incapacidade de um filtro descalibrado em mapear a própria incerteza operacional.

E. Resposta Transitória sob Oclusão (Cenário 6)

O Cenário 6 impõe o estresse limite ao estimador ao simular a supressão temporária abrupta e total de dados sensoriais. No intervalo de apagão bi-dimensional, a ausência de inovações suspende a etapa de atualização do filtro, forçando o algoritmo a propagar os estados em malha aberta com base exclusiva no modelo cinemático integrado e nas velocidades estimadas no passo imediatamente anterior à oclusão.

Embora o comportamento puramente preditivo induza uma expansão geométrica inevitável do elipsoide de incerteza da matriz $\mathbf{P}$ e eleve o desvio máximo posicional no ápice da interrupção, o modelo PVA absorve a dinâmica inercial e impede o colapso numérico ou o desvio divergente do filtro. A robustez da modelagem estocástica manifesta-se no restabelecimento imediato da convergência sub-métrica e no rápido amortecimento dos resíduos de inovação após a reconexão com a infraestrutura de balizas fixas.

VI. CONCLUSÃO

A. Resumo e Principais Constatações

Este trabalho analisou o comportamento do Filtro de Kalman Estendido (EKF) sob a modelagem cinemática Posição-Velocidade-Aceleração (PVA) em cenários de rastreamento bidimensional. Os resultados indicam que o estimador calibrado filtra o ruído instrumental com eficácia e preserva a estabilidade do rastreamento sob obstruções severas de sinal, apoiado na inércia mecânica do modelo preditivo.

A principal constatação teórica desta pesquisa indica o desacoplamento entre a acurácia geométrica visual e a coerência matemática interna do algoritmo. Distorções intencionais nas matrizes de covariância induzem regimes operacionais patológicos. A subestimação da incerteza de medição, por exemplo, gera um falso positivo: o estimador exibe aparente precisão macroespacial ao aproximar-se da trajetória ruidosa, mas colapsa sua integridade probabilística fundamental. Este comportamento mascara o estresse do filtro e prova que análises




Figura 10: Recorte do Cenário 6 sob oclusão temporária. O EKF propaga a cinemática em malha aberta sem divergência crítica.

restritas aos desvios posicionais não garantem a confiabilidade de sistemas de navegação autônoma.

B. Contribuições

As contribuições deste estudo compreendem:

- A concepção de uma arquitetura modular de simulação que audita os parâmetros estatísticos de inovação e projeta elipses de incerteza em tempo real.
- A consolidação de um protocolo de diagnóstico bimodal que integra métricas geométricas e testes de hipóteses probabilísticos, o qual estabelece um critério rigoroso para homologar filtros de estimação.
- A formulação da Taxa de *Inliers* integrada ao conceito de Região de Interesse (ROI) Dinâmica. Esta abordagem gera um indicador matemático de convergência que viabiliza o particionamento preditivo de fluxos de dados e otimiza algoritmos de visão computacional.

C. Limitações e Trabalhos Futuros

O escopo desta investigação limitou-se a distúrbios gaussianos. Fenômenos não gaussianos severos e comuns em ambientes industriais — como caminhos múltiplos e ausência de linha de visada direta — não foram abordados, e a calibração restringiu-se ao método manual empírico. Para expandir esta pesquisa, propõem-se as seguintes frentes de desenvolvimento:

- **Sintonia Automática de Covariâncias:** Integrar rotinas de otimização matemática baseadas em meta-heurísticas ou descida de gradiente para determinar de forma autônoma as matrizes de processo e medição.
- **Validação em Sistemas Visuais Reais:** Aplicar a janela de incerteza preditiva do filtro no processamento de imagens de câmeras embarcadas, para quantificar o incremento na taxa de quadros por segundo via redução do espaço de busca.

- **Exploração de Filtragens Avançadas:** Conduzir estudos comparativos frente a arquiteturas que evitam a linearização por matrizes Jacobianas em trajetórias altamente não lineares, como o Filtro de Kalman *Unscented* (UKF) e os Filtros de Partículas.

D. Conclusão Final

O projeto de estimadores de estado robustos exige compreender que quantificar a própria incerteza de forma realista tem a mesma relevância que calcular a coordenada espacial final do alvo. O equilíbrio entre a exatidão macroespacial e a auditoria estatística interna consolida uma metodologia madura para a evolução de algoritmos de localização em robótica móvel e sistemas embarcados de tempo real.

REFERÊNCIAS

- [1] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [6] P. Falek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [7] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [8] D. Simon, *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [9] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.

APÊNDICE A

MATERIAL SUPLEMENTAR E REPOSITÓRIO DO CÓDIGO

O código-fonte completo da ferramenta de simulação desenvolvida neste trabalho está disponível publicamente para consulta e reprodução dos testes. O repositório inclui a interface gráfica (GUI) em Python, os scripts de geração das trajetórias e a implementação matemática do EKF.

Também foram disponibilizados no link os gráficos de todas as simulações em alta resolução, incluindo as trajetórias espaciais e as métricas do NIS que não couberam na íntegra ao longo do texto.

O acesso ao código e aos dados adicionais pode ser feito pelo link:

<https://github.com/SauloJose/PASKalmanTraj>

No repositório [10], é possível rodar o simulador localmente para interagir com o ajuste das matrizes **Q** e **R**, além de acompanhar a variação dinâmica da janela de ROI e das elipses de incerteza do filtro em tempo real.