

Rastreamento Bidimensional de Alvos via Filtro de Kalman Estendido em Sistemas de Posicionamento por Estações Base

Saulo José Almeida Silva, *Mestrando, UFCG*,

Resumo—A localização precisa é um requisito fundamental para a operação autônoma de sistemas robóticos móveis. Este trabalho apresenta o desenvolvimento, a implementação e a análise rigorosa de um Filtro de Kalman Estendido (EKF) aplicado ao rastreamento bidimensional de alvos utilizando medições não lineares de distância (*range-only*). Fundamentado em um modelo cinemático de Posição-Velocidade-Aceleração (PVA), o estimador foi avaliado por meio de um ambiente de simulação consolidado em Python. A arquitetura viabiliza o monitoramento em tempo real da acurácia posicional (RMSE), da consistência estatística via *Normalized Innovation Squared* (NIS) e do diagnóstico espacial de crença através da Região de Confiança (Taxa de *Inliers*). Os resultados demonstram que, sob sintonização estocástica adequada das matrizes de processo ($\mathbf{Q}$) e de medição ($\mathbf{R}$), o EKF atinge precisão submétrica estável e robustez contra oclusões temporárias. Em contraste, evidencia-se que a subestimação paramétrica induz à divergência estatística imediata e a atrasos de fase severos. Conclui-se que a eficácia preditiva do filtro é estritamente dependente da calibração contínua de suas elipses de incerteza em relação ao ruído do mundo físico.

Index Terms—Filtro de Kalman Estendido, Localização em Tempo Real, Posicionamento *Range-Only*, Consistência Estatística.

I. INTRODUÇÃO

A O passo que os sistemas robóticos autônomos assumem tarefas mais complexas, cresce também a exigência por soluções de navegação precisas e confiáveis. Para mitigar as incertezas inerentes a esse processo, a literatura tem apostado fortemente em arquiteturas de fusão sensorial — que combinam dados de múltiplos sensores — associadas a análises estatísticas das medições. Essa integração tem se mostrado essencial para refinar a estimativa de estado do sistema e viabilizar sua aplicação no mundo real [1], [2].

O grande desafio no desenvolvimento dessas soluções de localização está nos erros instrumentais e nos ruídos estocásticos que afetam a dinâmica do robô. Mesmo sob uma modelagem cinemática detalhada, perturbações ambientais e não-linearidades — presentes tanto na resposta física dos sensores quanto na própria dinâmica veicular — acabam inserindo margens inevitáveis de imprecisão no estado estimado.

Para contornar essa limitação e obter estimativas de alta fidelidade, utiliza-se o Filtro de Kalman (KF), um estimador ótimo iterativo para sistemas lineares sob o critério do erro quadrático mínimo [3]. Como parte da família dos filtros

bayesianos, o KF estima variáveis de estado não mensuradas diretamente, o que viabiliza sua aplicação em cenários de observabilidade incompleta [4]. Essa formulação clássica, no entanto, é limitada em sistemas de posicionamento baseados em distância (alcance), cujas equações de observação são essencialmente não-lineares. Nesses cenários, aplica-se o Filtro de Kalman Estendido (EKF), que contorna a não linearidade por meio da linearização do modelo em torno da estimativa corrente [4], [5].

Embora o EKF possua uma fundamentação teórica consolidada, seu sucesso prático depende diretamente do ajuste das matrizes de covariância do processo ($\mathbf{Q}$) e de medição ($\mathbf{R}$). A sintonia desses parâmetros requer simulações computacionais detalhadas, etapa essencial no desenvolvimento de sistemas de navegação. Um exemplo dessa abordagem é o trabalho de Falek e Kaniewski [6], que propuseram um ambiente em MATLAB para avaliar o comportamento do EKF em redes de posicionamento baseadas em estações fixas.

Nesse contexto, este trabalho apresenta uma aplicação computacional em Python projetada para simular e analisar o rastreamento bidimensional de um robô a partir de quatro estações base. A ferramenta proposta integra uma interface gráfica (GUI) interativa que, além de computar os erros de estimativa e a Raiz do Erro Quadrático Médio (RMSE), permite validar a consistência estatística do filtro por meio do teste do *Normalized Innovation Squared* (NIS) e monitorar o comportamento da crença (*belief*) em regiões de interesse (ROI) dinâmicas. Desse modo, o trabalho contribui com um ferramental visual e estatístico voltado a sistematizar a parametrização e a validação do EKF.

A. Notação e Convenções

Neste trabalho, adota-se a seguinte convenção de notação: escalares são representados por letras minúsculas em itálico (a), vetores por minúsculas em negrito ($\mathbf{a}$ ou $\hat{\mathbf{x}}$) e matrizes por maiúsculas em negrito ($\mathbf{A}$ ou $\mathbf{P}$).

No domínio discreto, o subscrito k denota a variável física real no instante de tempo atual (como o estado $\mathbf{x}_k$ ou a medição $\mathbf{z}_k$). Por outro lado, os estados e as covariâncias calculados pelo estimador utilizam uma notação composta:

- $k|k-1$: indica os valores *a priori* (etapa de predição), computados a partir do histórico do sistema até o instante $k-1$, tais como o estado predito $\hat{\mathbf{x}}_{k|k-1}$ e a covariância do erro $\mathbf{P}_{k|k-1}$.
- $k|k$: representa os valores *a posteriori* (etapa de correção), atualizados após a incorporação da nova

medição, tais como o estado corrigido $\hat{\mathbf{x}}_{k|k}$ e a covariância do erro $\mathbf{P}_{k|k}$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta a base teórica para o problema de estimativa de estados em robótica. O texto parte da modelagem determinística ideal e avança para os filtros probabilísticos usados na mitigação de incertezas em sistemas reais. Inicialmente, são apresentados os conceitos de sistemas dinâmicos e as fontes de ruído que afetam o comportamento do robô. Em seguida, introduz-se a definição de crença (*belief*) sob a suposição de Markov, o que fundamenta a relação geométrica entre a matriz de covariância e a região de incerteza do agente. Por fim, são discutidos o modelo Gauss-Markov, a discretização temporal, as formulações do Filtro de Kalman (Linear e Estendido) e as métricas para validação do estimador.

A. Sistemas Dinâmicos e Modelagem Determinística

A modelagem de robôs móveis para navegação e controle costuma utilizar a representação em espaço de estados. No domínio do tempo contínuo, a evolução do vetor de estados ocultos $\mathbf{x}(t) \in \mathbb{R}^n$ e as medições ideais do sistema são descritas por equações diferenciais e algébricas [7], na forma:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{h}(\mathbf{x}(t)) \quad (1)$$

onde $\mathbf{u}(t) \in \mathbb{R}^m$ é o vetor de entradas de controle e $\mathbf{z}(t) \in \mathbb{R}^d$ é o vetor de medições. Se as funções $\mathbf{f}$ e $\mathbf{h}$ forem lineares, o sistema pode ser escrito em sua forma canônica:

$$\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{H}_c \mathbf{x}(t) \quad (2)$$

As matrizes $\mathbf{A}_c$, $\mathbf{B}_c$ e $\mathbf{H}_c$ definem a dinâmica, a entrada e a observação contínuas [7]. Essa abordagem determinística assume sensores perfeitos e um modelo físico exato, desconsiderando os ruídos e distúrbios comuns em ambientes reais.

B. Sistemas Estocásticos e Fontes de Incerteza

Na prática, os sistemas robóticos sofrem perturbações que inviabilizam o uso de modelos puramente determinísticos. Essas incertezas vêm de duas fontes principais [2]:

- 1) **Ruído de Processo (ϵ):** Representa distúrbios dinâmicos, forças ambientais (como atrito variante, irregularidades no solo e correntes de ar) e erros de modelagem que afetam a locomoção do robô.
- 2) **Ruído de Medição (δ):** Agrupa as incertezas dos próprios sensores. Em sistemas de localização por radiofrequência ou acústicos, decorre de efeitos de multicaminho, ruído térmico nos circuitos, atenuação de sinal e falhas de calibração [8].

Com a inclusão desses ruídos, o estado deixa de ser um ponto exato e passa a ser tratado como uma variável aleatória. A evolução temporal do sistema e as leituras dos sensores passam a ser modeladas por densidades de probabilidade condicionais:

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (3)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (4)$$

onde $k \in \mathbb{N}$ indica o passo de tempo discreto. O tratamento matemático dessas incertezas garante que os estimadores operem de forma estável mesmo sob condições severas [6].

C. Robótica Probabilística, Suposição de Markov e a Crença (*Belief*)

Para lidar com as incertezas de modelos e sensores, a robótica probabilística calcula a crença (*belief*) do robô a respeito de seu próprio estado. O *belief* é a distribuição de probabilidade a posteriori do vetor de estados $\mathbf{x}_k$, condicionada ao histórico de comandos enviados e medições recebidas [4]:

$$\text{bel}(\mathbf{x}_k) = P(\mathbf{x}_k | \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (5)$$

Para viabilizar o cálculo dessa distribuição em tempo real, aplica-se a **Suposição de Markov**. Esse postulado assume que o estado atual $\mathbf{x}_k$ é uma estatística suficiente do sistema, contendo toda a informação do passado. Assim, o estado futuro depende apenas do estado presente e da ação atual, o que simplifica a probabilidade condicional para:

$$P(\mathbf{x}_k | \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (6)$$

A propriedade de Markov permite dividir o cálculo do *belief* de forma recursiva em duas etapas: predição e correção, que formam a estrutura dos filtros de estimação sequenciais [4].

D. O Modelo Gauss-Markov

O cálculo das distribuições probabilísticas torna-se tratável quando o sistema segue o Modelo Gauss-Markov. Esse modelo define um processo que obedece à propriedade de Markov e cujos ruídos de processo e medição (ϵ_k e δ_k) são gaussianos, brancos e com média nula [9].

A principal vantagem dessa modelagem está na conservação das propriedades estatísticas: transformações lineares aplicadas a variáveis gaussianas geram novas variáveis gaussianas [8]. Com isso, o *belief* $\text{bel}(\mathbf{x}_k)$ permanece estritamente gaussiano ao longo do tempo.

Como uma distribuição gaussiana é definida apenas pelo seu vetor de médias ($\hat{\mathbf{x}}$) e por sua matriz de covariância ($\mathbf{P}$), o problema de rastrear uma função contínua de dimensão infinita resume-se a atualizar esses dois parâmetros a cada passo de tempo discreto.

E. Discretização do Sistema e das Covariâncias

Embora os modelos cinemáticos baseiem-se no tempo contínuo (t), os processadores digitais operam em intervalos discretos Δt . Considerando o vetor de controle $\mathbf{u}(t)$ constante dentro de cada intervalo de amostragem, o sistema linear contínuo $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ é convertido para sua forma discreta equivalente sob o modelo Gauss-Markov [9]:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (7)$$

As matrizes discretas de transição de estados ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) são obtidas a partir das matrizes contínuas pelas relações:

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \left(\int_0^{\Delta t} e^{\mathbf{A}_c \tau} d\tau \right) \mathbf{B}_c \quad (8)$$

Discretização das Covariâncias de Ruído: A amostragem digital também exige a discretização das matrizes de covariância dos ruídos [9]. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se de acordo com a própria dinâmica do sistema. A matriz discreta equivalente, $\mathbf{Q}_k$, é calculada pela integral:

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (9)$$

Para taxas de amostragem altas ($\Delta t \ll 1$), pode-se aproximar essa relação por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, assumindo um crescimento linear da incerteza [9]. No entanto, em modelos cinemáticos de ordem superior — como o espaço de estados Posição-Velocidade-Aceleração (PVA) deste trabalho —, a resolução analítica da Equação (9) é necessária para manter o acoplamento cruzado das incertezas, gerando os termos polinomiais apresentados na Seção III.

Extensão para Sistemas Não Lineares: Se a dinâmica do sistema contínuo for não linear, utilizam-se métodos de integração numérica para a discretização. O método de Euler, por exemplo, resulta na aproximação:

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (10)$$

Para propagar a incerteza gaussiana nesses casos, o modelo aproximado deve ser linearizado localmente por meio de matrizes Jacobianas a cada passo k [4].

F. Filtros de Estimação Baseados em Kalman

O Filtro de Kalman é a solução ótima para propagar e corrigir o *belief* gaussiano em sistemas lineares sob a suposição de Markov. O algoritmo não estima o estado como um ponto fixo, mas rastreia os parâmetros que definem sua distribuição de probabilidade.

1) *Filtro de Kalman Linear:* Com base no modelo Gauss-Markov discreto, a dinâmica e o modelo de observação incorporam os ruídos de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (11)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (12)$$

onde $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O filtro calcula recursivamente o estado corrigido $\hat{\mathbf{x}}_{k|k}$ (média) e sua matriz de covariância $\mathbf{P}_{k|k}$ (incerteza). O processo é dividido em etapas de predição e correção, conforme descrito no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$$

$$2: \mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$3: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$4: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

Se houver oclusão de sinal ou indisponibilidade dos sensores, a etapa de correção (linhas 4 a 6) não é executada. Nessas situações, o filtro opera em malha aberta apenas com a predição cinemática. Como consequência, a covariância $\mathbf{P}_{k|k-1}$ cresce a cada passo, resultando no aumento contínuo do ROI Dinâmico.

2) *Filtro de Kalman Estendido (EKF):* Quando o sistema de localização utiliza distâncias radiais em relação a estações com coordenadas conhecidas, as equações de observação tornam-se não lineares devido à geometria do problema. Nesses cenários, utiliza-se o Filtro de Kalman Estendido (EKF) [4], que aceita funções não lineares genéricas g e h :

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (13)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (14)$$

Para propagar as matrizes de incerteza, o algoritmo utiliza uma expansão em série de Taylor de primeira ordem. Essa linearização local exige o cálculo das matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$ em torno das estimativas atuais:

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \hat{\mathbf{x}}_{k-1|k-1}} \quad (15)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (16)$$

Essas matrizes Jacobianas substituem as matrizes fixas do caso linear na propagação das incertezas e no cálculo do ganho de Kalman ($\mathbf{K}_k$), permitindo o rastreamento em sistemas com não linearidades geométricas (Algoritmo 2).

Algorithm 2 Filtro de Kalman Estendido (EKF)

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow g(\mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$2: \mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$3: \mathbf{P}_{k|k-1} \leftarrow \mathbf{G}_k \mathbf{P}_{k-1|k-1} \mathbf{G}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$4: \mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$6: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}))$$

$$7: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

G. Métricas de Avaliação e Consistência Estocástica

O desempenho do estimador é avaliado por meio de métricas de precisão geométrica e testes estatísticos baseados nos resíduos da inovação [8].

1) *Root Mean Square Error (RMSE)*: A precisão geométrica espacial nas trajetórias bidimensionais é medida pela Raiz do Erro Quadrático Médio (RMSE). O RMSE calcula a distância euclidiana média entre o estado real $\mathbf{x}_k$ e o estado corrigido $\hat{\mathbf{x}}_{k|k}$ em um horizonte de N amostras:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (17)$$

Essa métrica também pode ser calculada de forma independente para os eixos cartesianos (X e Y) para identificar a direção de eventuais falhas de rastreamento.

2) *Normalized Innovation Squared (NIS)*: A precisão medida pelo RMSE não garante que o estimador seja consistente do ponto de vista estatístico. Um filtro é consistente se seus erros de estimação tiverem média nula e covariância compatível com os valores teóricos calculados pelo próprio algoritmo [8]. O teste do quadrado da inovação normalizada (NIS) verifica se a incerteza estimada na matriz $\mathbf{P}_k$ condiz com o comportamento real das medições.

A inovação $\boldsymbol{\nu}_k \in \mathbb{R}^d$ representa a diferença entre a medição real e a predição calculada pelo filtro:

$$\boldsymbol{\nu}_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}) \quad (18)$$

A matriz de covariância teórica da inovação, obtida na etapa de correção, é dada por:

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k \quad (19)$$

O escalar NIS (ϵ_k) é calculado pela forma quadrática baseada na distância de Mahalanobis:

$$\epsilon_k = \boldsymbol{\nu}_k^T \mathbf{S}_k^{-1} \boldsymbol{\nu}_k \quad (20)$$

Se o modelo cinemático e as matrizes de ruído ($\mathbf{Q}_k$ e $\mathbf{R}_k$) estiverem corretos, a variável ϵ_k segue uma distribuição Qui-Quadrado (χ^2) com n_z graus de liberdade, onde n_z é a dimensão do vetor de medições $\mathbf{z}_k$ [8].

Quando o histograma empírico dos resultados se mantém dentro dos limites de aceitação da distribuição Qui-Quadrado, o filtro e o ROI Dinâmico são considerados consistentes. Desvios prolongados para fora desses limites indicam erros de parametrização, sinalizando que o filtro está subestimando ou superestimando as incertezas reais do sistema [8].

III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Para analisar o comportamento do EKF quanto à convergência, ajuste de parâmetros e consistência estatística, este estudo delinea um cenário de rastreamento bidimensional baseado exclusivamente em dados de distância (*range-only tracking*) [8]. Essa modelagem expande o método sugerido em [6], descrevendo a movimentação do agente por meio de um modelo cinemático estruturado no espaço de estados de Posição, Velocidade e Aceleração (PVA).

A. Descrição do Problema

O problema abordado consiste em estimar a trajetória de um robô móvel que opera em um plano bidimensional. O agente se desloca dentro de uma arena monitorada por uma infraestrutura de localização local, composta por $M = 4$ estações fixas (âncoras) instaladas em posições conhecidas, denotadas por $\mathbf{p}_i = [X_i, Y_i]^T$ para $i = 1, \dots, 4$. O arranjo completo desse ambiente operacional encontra-se esquematizado na Figura 1.

O robô não possui sensores de odometria ou de velocidade própria, dependendo exclusivamente de medições escalares de distância obtidas via radiofrequência ou ondas acústicas em relação a cada uma das estações. O objetivo do estimador é processar essas observações ruidosas e reconstruir, a cada passo temporal, a posição horizontal (X) e vertical (Y) do agente, estimando também suas componentes de velocidade e aceleração instantâneas.




Figura 1: Representação geométrica do sistema de posicionamento: o agente móvel no espaço bidimensional e os raios de medição (*range-only*) oriundos das quatro estações base fixas nos vértices da arena.

B. Modelo Cinemático de Processo (Espaço de Estados PVA)

Diferentemente de abordagens simplificadas de velocidade constante, o estado do agente móvel no instante discreto k passa a ser representado por um vetor expandido de seis dimensões: $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$. Nessa estrutura, (x_k, y_k) correspondem às coordenadas de posição cartesiana, $(v_{x,k}, v_{y,k})$ às componentes da velocidade linear e $(a_{x,k}, a_{y,k})$ às acelerações instantâneas nos eixos X e Y , respectivamente.

A dinâmica temporal do sistema sob regime de aceleração constante (CA) é integrada ao longo do intervalo de amostragem Δt . Essa operação dá origem à matriz de transição de estados $\mathbf{A}_k$ (6×6), especificada na Equação (21):

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (21)$$

Fatores práticos como o escorregamento de rodas, desalinhamentos mecânicos e irregularidades do terreno introduzem erros cumulativos na navegação [4]. Na formulação PVA escolhida, esse comportamento estocástico é transposto para o modelo admitindo que as perturbações ajam de forma independente sobre os componentes de posição, velocidade e aceleração. Essas fontes de incerteza são sintetizadas pela matriz de densidade espectral de potência contínua $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$.

Ao calcular a discretização analítica desse termo, ponderada pela própria dinâmica veicular no intervalo Δt , obtém-se uma matriz de covariância discreta $\mathbf{Q}_k$ caracterizada por ser esparsa e simétrica. O perfil estritamente diagonal de $\mathbf{Q}_c$ garante o desacoplamento estocástico entre as dinâmicas dos eixos horizontal (X) e vertical (Y). Os elementos não nulos associados aos estados do eixo X (índices 0, 2 e 4) são calculados conforme as relações dispostas na Equação (22):

$$\begin{cases} Q_{0,0} = q_1 \Delta t + q_3 \frac{\Delta t^3}{3} + q_5 \frac{\Delta t^5}{20} \\ Q_{0,2} = Q_{2,0} = q_3 \frac{\Delta t^2}{2} + q_5 \frac{\Delta t^4}{8} \\ Q_{0,4} = Q_{4,0} = q_5 \frac{\Delta t^3}{6} \\ Q_{2,2} = q_3 \Delta t + q_5 \frac{\Delta t^3}{3} \\ Q_{2,4} = Q_{4,2} = q_5 \frac{\Delta t^2}{2} \\ Q_{4,4} = q_5 \Delta t \end{cases} \quad (22)$$

De maneira análoga, os componentes vinculados ao eixo Y (índices 1, 3 e 5) replicam essa mesma estrutura algébrica, utilizando as variâncias espectrais específicas $\{q_2, q_4, q_6\}$ detalhadas na Equação (23):

$$\begin{cases} Q_{1,1} = q_2 \Delta t + q_4 \frac{\Delta t^3}{3} + q_6 \frac{\Delta t^5}{20} \\ Q_{1,3} = Q_{3,1} = q_4 \frac{\Delta t^2}{2} + q_6 \frac{\Delta t^4}{8} \\ Q_{1,5} = Q_{5,1} = q_6 \frac{\Delta t^3}{6} \\ Q_{3,3} = q_4 \Delta t + q_6 \frac{\Delta t^3}{3} \\ Q_{3,5} = Q_{5,3} = q_6 \frac{\Delta t^2}{2} \\ Q_{5,5} = q_6 \Delta t \end{cases} \quad (23)$$

C. Modelo de Observação e Geometria das Estações Base

A partir do arranjo de infraestrutura detalhado na Seção III-A, o vetor de observações obtido a cada passo amostral é estruturado como $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$. A relação geométrica entre o estado cinemático estimado do robô e a distância escalar real até a i -ésima estação fixa é governada por uma função de observação não linear $h_i(\mathbf{x}_k)$, descrita na Equação (24):

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (24)$$

Como o vetor de estado possui seis dimensões e as leituras dependem estritamente das coordenadas de posição (x_k, y_k) ,

as derivadas parciais da função de medição associadas aos componentes de velocidade e aceleração anulam-se por completo [8]. Sob essas condições, a matriz Jacobiana $\mathbf{H}_k$ (4×6) avaliada a cada iteração assume o formato estabelecido na Equação (25):

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_k | k-1} \quad (25)$$

Para concluir a modelagem matemática do sensor, a matriz de covariância do ruído de medição é definida como $\mathbf{R}_k = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$, em que cada termo diagonal reflete a variância do erro instrumental intrínseco de sua respectiva âncora de leitura.

D. Cenário de Desafio: Modelagem de Oclusão Temporal

Para avaliar os limites do estimador e a utilidade prática da região de interesse (ROI) dinâmica e do teste NIS, projetou-se uma janela de oclusão severa no ambiente de simulação. Dentro de um intervalo cronometrado $t \in [t_{\text{start}}, t_{\text{end}}]$, as leituras vindas das quatro estações base são intencionalmente suprimidas ($\mathbf{z}_{i,k} \rightarrow \emptyset$).


Esse bloqueio — cujo comportamento é ilustrado na Figura 2 — força o algoritmo a depender apenas das projeções geradas pela matriz de transição PVA (21). Sob condições normais de operação com o filtro atualizando as medições, a elipse mantém-se estável e restrita (Figura 2a). Contudo, sem o suporte das correções trazidas pelos sensores durante a oclusão, as incertezas de aceleração modeladas em $\mathbf{Q}_k$ acumulam-se rapidamente. O resultado direto é uma expansão geométrica acentuada na matriz de covariância predita ($\mathbf{P}_{k|k-1}$), que se traduz no alargamento progressivo da elipse de confiança (ROI) ao longo do deslocamento do robô, variando conforme a trajetória realizada (Figuras 2b e 2c).

IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo detalha a metodologia utilizada para avaliar o desempenho, a sensibilidade e a robustez à oclusão do estimador proposto. A apresentação segue a ordem lógica dos experimentos: inicialmente, descreve-se a geração cinemática das trajetórias de referência. Em seguida, detalham-se os cenários de teste e a modelagem do filtro. Por fim, definem-se as métricas estatísticas aplicadas na avaliação do Filtro de Kalman Estendido (EKF) sob diferentes parametrizações.

A. Síntese Cinemática das Trajetórias de Referência

Para que a precisão do Filtro de Kalman Estendido (EKF) possa ser avaliada, é indispensável compará-lo a um referencial absoluto e livre de ruídos, o *Ground Truth*. Nessa etapa, o simulador atua como um gerador de gabaritos: ele calcula a física exata do alvo para cada instante discreto k e armazena essas informações no vetor de estado $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$, que engloba as posições, velocidades e acelerações reais nos eixos ortogonais.



(a) Operação nominal: predição e atualização. (b) Oclusão: trajetória 1 (predição pura). (c) Oclusão: trajetória 2 (predição pura).

Figura 2: Representação visual da incerteza do EKF (ROI dinâmica): a elipse em cinza denota a incerteza predita ($\mathbf{P}_{k|k-1}$), enquanto a elipse em verde representa a incerteza atualizada após a correção ($\mathbf{P}_{k|k}$). (a) Regime de operação estável sob observações contínuas; (b) e (c) expansão da incerteza e degradação da precisão decorrentes da supressão das medições (occlusão temporal) em distintos perfis de trajetória.

Como um alvo em uma aplicação real pode apresentar desde um trajeto altamente previsível até manobras bruscas, o simulador foi projetado para testar os limites do estimador utilizando duas abordagens distintas de movimento:

- **Curvas paramétricas analíticas (Determinísticas):** Simulam cenários onde o alvo obedece a regras geométricas bem definidas e contínuas. Servem para testar o filtro sob dinâmicas estáveis e previsíveis.
- **Modelos numéricos comportamentais (Estocásticos):** Inserem aleatoriedade na navegação do alvo. Servem para testar a capacidade de adaptação do EKF quando o objeto realiza trajetórias erráticas ou mudanças repentinas de direção.

O conjunto completo dessas trajetórias, abrangendo todos os perfis cinemáticos abordados nos testes, pode ser visualizado na Figura 3.

1) *Geração de Curvas Paramétricas e Analíticas:* Para os testes com movimentos contínuos e regulares, as posições do alvo no simulador são ditadas por funções trigonométricas e hiperbólicas dependentes do tempo. Um cuidado fundamental nessa etapa foi evitar o cálculo numérico das derivadas. Para garantir que o *Ground Truth* seja matematicamente perfeito e livre de erros de discretização, a velocidade e a aceleração do alvo são extraídas a partir da diferenciação analítica exata das equações de posição, conforme detalha o Algoritmo 3.

As trajetórias com quinas, como o percurso quadrado, obedecem a esse mesmo rigor determinístico. A única diferença é que a modelagem utiliza segmentos de reta conectados para formar as arestas, aplicando-se uma restrição geométrica de fechamento para garantir que o alvo retorne exatamente à coordenada onde iniciou o percurso.

2) *Geração de Navegação Aleatória e Oclusões:* Para aproximar a simulação do comportamento estocástico de um alvo real, desenvolveu-se um algoritmo de navegação aleatória. O agente (UGV - Unmanned Ground Vehicle) move-se em linha reta por distâncias mínimas antes de realizar deflexões suaves. Se o robô atinge os limites da arena (raio superior a 35 metros), um mecanismo de evasão direciona o movimento de volta ao centro, mantendo o robô na área útil.

Algorithm 3 Geração de Trajetórias Paramétricas Analíticas

Require: Tempo contínuo $t_k = k\Delta t$, Parâmetros geométricos (Amplitude A , Frequência ω)

```

1: for cada instante  $k$  do
2:   if Perfil = Circular then
3:      $\mathbf{p}_k \leftarrow [c_x + R \cos(\omega t_k), c_y + R \sin(\omega t_k)]^T$ 
4:   else if Perfil = Mudança de Faixa (Tanh) then
5:      $\mathbf{p}_k \leftarrow [v_x t_k, c_y + A \tanh(S \cdot t_k)]^T$ 
6:   else if Perfil = Lemniscata then
7:      $\mathbf{p}_k \leftarrow [c_x + A \sin(\omega t_k), c_y + \frac{A}{2} \sin(2\omega t_k)]^T$ 
8:   end if
9:    $\mathbf{v}_k \leftarrow \frac{d}{dt} \mathbf{p}_k$ 
10:   $\mathbf{a}_k \leftarrow \frac{d}{dt} \mathbf{v}_k$ 
11:   $\mathbf{x}_k \leftarrow [\mathbf{p}_k^T, \mathbf{v}_k^T, \mathbf{a}_k^T]^T$ 
12: end for

```

Ensure: Sequência de estados reais $\mathbf{x}_{1:N}$

Como as mudanças de direção são aleatórias, a aceleração de referência é calculada por diferenciação numérica discreta, conforme estruturado no Algoritmo 4.

B. Cenários de Simulação e Estratégia de Sintonia

Para avaliar o estimador na prática, a campanha de testes foi dividida em **6 cenários cinemáticos** (ilustrados na Figura 3), abrangendo diferentes perfis de aceleração e condições de oclusão. Além do movimento do alvo, o comportamento do EKF depende diretamente das suas matrizes de covariância ($\mathbf{Q}_k$ para o processo e $\mathbf{R}_k$ para a medição). Para testar a sensibilidade do algoritmo a esses parâmetros, cada cenário foi simulado sob **duas condições distintas**:

- 1) **Situação Sintonizada (Filtro Calibrado):** Representa a condição de funcionamento ideal do rastreador. Os valores das matrizes foram ajustados de forma empírica (por tentativa e erro), avaliando o comportamento do filtro até que ele apresentasse um desempenho considerado "bom". O critério de sucesso foi a minimização do erro de posição aliada a elipses de confiança visualmente e estatisticamente coerentes com a trajetória.




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos.

Algorithm 4 Geração de Navegação Dinâmica Aleatória

Require: Vetor posição central $\mathbf{p}_c$, Limite da arena $R_{\max}$, Ruído cinemático w

```

1: for cada instante  $k$  do
2:   if Distância percorrida  $> D_{\min}$  then
3:     if  $\|\mathbf{p}_{k-1} - \mathbf{p}_c\| > R_{\max}$  then
4:        $\theta_{\text{alvo}} \leftarrow$  Ângulo forçado em direção a  $\mathbf{p}_c$ 
5:     else
6:        $\theta_{\text{alvo}} \leftarrow \theta_{k-1} + \mathcal{U}(-\frac{\pi}{3}, \frac{\pi}{3})$ 
7:     end if
8:      $v_{\text{alvo}} \leftarrow v_{\text{base}} + \mathcal{U}(-w, w)$ 
9:   end if
10:   $\theta_k \leftarrow \text{SuavizarTransição}(\theta_{k-1}, \theta_{\text{alvo}})$ 
11:   $v_k \leftarrow \text{SuavizarTransição}(v_{k-1}, v_{\text{alvo}})$ 
12:   $\mathbf{v}_k \leftarrow [v_k \cos(\theta_k), v_k \sin(\theta_k)]^T$ 
13:   $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$ 
14:   $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$ 
15: end for

Configuração Especial para Oclusão Cíclica:
16: if Modo Oclusão then
17:   Emite uma máscara binária atribuindo valor Falso
   (Oculito) no segmento temporal central de 4 blocos.
18: end if

```

2) **Situação Não Sintonizada (Filtro Descalibrado):** Representa falhas severas na configuração do projeto. Nessa etapa, os valores das matrizes foram intencionalmente sabotados, sendo superestimados ou subestimados. O objetivo de impor essas condições anormais é

demonstrar como o filtro se comporta mal quando está mal configurado e comprovar a importância de uma boa sintonia.

A Tabela I consolida todas as variáveis utilizadas nos testes: a configuração de movimento do alvo, o nível de ruído físico (σ) simulado nos sensores e os valores numéricos utilizados para sintonizar (ou descalibrar) o EKF em cada um dos seis cenários.

C. Configuração do Estimador e Modelagem do Ruído

O objetivo do filtro é estimar o estado completo do alvo (o vetor PVA $\mathbf{x}_k$, detalhado na Seção III). Para alimentar o algoritmo, o sistema mede a distância do robô até quatro estações rádio-base fixadas nos cantos da arena.

Como nenhum sensor no mundo real é perfeito, o simulador precisa "sujar" as medidas ideais do *Ground Truth*. Para imitar a imprecisão real, o sistema injeta um erro aleatório em cada canal: soma-se à distância exata um ruído gaussiano branco de média zero e desvio padrão σ (valores indicados na Tabela I).

Isso resulta no vetor de observação $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$, que contém as quatro distâncias ruidosas que o EKF efetivamente recebe como entrada, conforme a Equação (26):

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (26)$$

É importante destacar que o EKF trabalha diretamente com essas distâncias puras na sua forma não-linear ($\mathbf{z}_k$). No entanto, para que possamos desenhar a posição lida pelos

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Circular	Quadrada	Tanh	Lemniscata	Nav. Aleatória	Oclusão Cíclica
Movimento	$v = 10,0 \text{ m/s}$	$v = 10 \text{ m/s}$	$A_y = 20,0 \text{ m}$	$v = 10,0 \text{ m/s}$	$v_0 = 8,0 \text{ m/s}$	$v = 5,0 \text{ m/s}$
	$r = 30,0 \text{ m}$	$L = 40,0 \text{ m}$	$v = 10,0 \text{ m/s}$	$A = 35,0 \text{ m}$	$\epsilon_v = 0,5 \text{ m/s}$	30 fr/occlusão
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Tempo de Simulação	40 s					
Taxa de Quadros (FPS)	30					
Semente Aleatória (Seed)	42					
Ruído nas Torres (σ)	0,30 m	0,40 m	0,40 m	0,40 m	0,40 m	0,40 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,9I_4$	$0,9I_4$	$0,9I_4$	$0,9I_4$	$0,9I_4$	$0,9I_4$
Matriz Processo $Q_{6 \times 6}$	$1I_6$	$1I_6$	$1I_6$	$1I_6$	$1I_6$	$1I_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1I_4$	$0,1I_4$	$0,01I_4$	$0,01I_4$	$0,01I_4$	$0,01I_4$
Matriz Processo $Q_{6 \times 6}$	$0,01I_6$ (Sub.)	$0,01I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,3I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,05I_6$ (Sub.)

Nota: I_n representa a matriz identidade de dimensão $n \times n$, denotando configurações diagonais. A matriz R apresenta um superdimensionamento conservador intencional ($0,9I_4$), não refletindo estritamente a variância do ruído injetado (σ^2). No Cenário 4 (Não Sintonizado), R foi propositalmente mantido inalterado para isolar e avaliar exclusivamente o efeito da subestimação de Q . (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.

sensores na interface gráfica do simulador, o sistema realiza um cálculo paralelo. Ele pega essas quatro distâncias com ruído e aplica um algoritmo numérico de multilateração por Mínimos Quadrados para estimar uma coordenada cartesiana $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$. Essa coordenada 2D serve estritamente como apoio visual para a tela e para a validação externa, não interferindo nas contas do Filtro de Kalman.

D. Ambiente Computacional e Infraestrutura de Simulação

Figura 4: Diagrama da arquitetura de software da aplicação de simulação.

Para automatizar a execução dos cenários e garantir a reprodutibilidade dos dados, o simulador foi desenvolvido em *Python* (versão 3.10) utilizando uma arquitetura modular, conforme ilustrado na Figura 4. O processamento matricial e a computação vetorizada do EKF foram implementados com a biblioteca *NumPy*.

Para facilitar a sintonia das matrizes Q_k e R_k , integrou-se uma interface gráfica (GUI) em *PyQt*. A plataforma permite ajustar parâmetros em tempo real via *sliders* e renderiza

instantaneamente a trajetória estimada, o vetor de observações e a elipse de covariância da região de interesse (ROI).

A interface gráfica serve apenas para inspeção visual e validação qualitativa. O núcleo numérico do simulador opera de forma independente, permitindo que as campanhas de teste e a exportação dos dados brutos ocorram de forma automatizada (ver Figura 6).

E. Métodos de Avaliação e Consistência

O desempenho do EKF é avaliado por meio da precisão espacial e da consistência estatística do estimador. A acurácia é quantificada comparando as estimativas *a posteriori* ($\hat{x}_{k|k}, \hat{y}_{k|k}$) com o *Ground Truth* através da Raiz do Erro Quadrático Médio (RMSE). Conforme o caso geral definido teoricamente na revisão da literatura (Seção II), o cálculo do erro é aplicado e monitorado de forma independente para os eixos operacionais X e Y . Adicionalmente, o erro médio com sinal (ME) é extraído para identificar eventuais tendências sistemáticas (viés) no rastreamento.

Além da métrica espacial, a consistência estatística é auditada. Um filtro bem sintonizado deve apresentar erros de estimativa que se comportem como ruído branco. Em condições ideais de calibração, o histograma dos erros nos eixos X e Y deve convergir para uma distribuição Normal (Gaussiana) de média zero. Complementarmente, a validade das matrizes de covariância Q_k e R_k é aferida pela métrica NIS (*Normalized Innovation Squared*). Como abordado na Seção II-G, valores de NIS conformes à distribuição χ^2 atestam que a incerteza calculada pelo filtro condiz com a inovação observada [8].

1) *Validação da Crença do Estimador (Inlier Rate)*: A convergência da crença (*belief*) é avaliada pela taxa de *inliers*. Conforme preconizado por [4], a crença *a priori* $bel(\mathbf{x}_{k|k-1})$ é centrada na predição resultante do modelo dinâmico antes da atualização via observações. Esta métrica de diagnóstico

mede a proporção de medições de suporte ($\mathbf{m}_k$) que residem dentro da região de incerteza projetada pelo estimador.

A verificação analítica baseia-se na distância de Mahalanobis associada à submatriz de covariância de posição $\mathbf{P}_{\text{pos}} = \mathbf{P}_{k|k-1}^{(1:2,1:2)}$. Definindo o resíduo posicional como $\tilde{\mathbf{p}}_k = [m_{x,k} - \hat{x}_{k|k-1}, m_{y,k} - \hat{y}_{k|k-1}]^T$, um ponto é contabilizado como *inlier* caso obedeça à Equação (27):

$$\tilde{\mathbf{p}}_k^T (\mathbf{P}_{\text{pos}})^{-1} \tilde{\mathbf{p}}_k \leq M \quad (27)$$

em que M é o limiar de aceitação extraído da distribuição χ^2 com 2 graus de liberdade.

Para visualização, a incerteza é representada por uma *bounding box* baseada no critério 3σ , cujos desvios-padrão teóricos são calculados pelas Equações (28) e (29):

$$\sigma_{x,\text{pred}} = \sqrt{\max(10^{-6}, P_{k|k-1}^{(1,1)})} \quad (28)$$

$$\sigma_{y,\text{pred}} = \sqrt{\max(10^{-6}, P_{k|k-1}^{(2,2)})} \quad (29)$$

Os limites da janela (L_x, L_y), definidos pelas Equações (30) e (31), garantem uma visualização estável através da constante $\tau_{\min}$:

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{pred}}) \quad (30)$$

$$L_y = \max(\tau_{\min}, 3\sigma_{y,\text{pred}}) \quad (31)$$

A Figura 5 ilustra a fronteira elíptica baseada na Equação (27) e a janela delimitadora dada pelas Equações (30) e (31), evidenciando a relação entre a teoria estatística e a representação geométrica.




Figura 5: Representação da métrica de *inliers*. A elipse valida estatisticamente a convergência, enquanto a janela retangular delimita a incerteza para fins de visualização.

V. RESULTADOS E DISCUSSÃO

Este capítulo detalha a avaliação experimental do Filtro de Kalman Estendido (EKF) ao longo dos seis cenários de navegação propostos na Seção IV. A análise fundamenta-se em métricas de acurácia posicional (RMSE e Erro Máximo), consistência estatística (NIS) e validação espacial (Taxa de

Inliers). Para avaliar a sensibilidade do algoritmo, os ensaios comparam o EKF com matrizes devidamente sintonizadas (variância de processo adequada e ruído de medição conservador) em contraponto a uma configuração intencionalmente descalibrada. A Tabela II consolida os indicadores quantitativos obtidos na simulação.

Devido a restrições de formatação, as composições gráficas completas (painéis comparativos de todas as trajetórias estimadas e históricos da métrica NIS para os seis cenários) foram alocadas no Apêndice A. Além disso, o código-fonte do simulador, os dados brutos e as imagens em alta resolução estão publicamente disponíveis no repositório do projeto no GitHub¹.

A. Interface Gráfica e Ambiente de Simulação

A Figura 6 exhibe o ambiente de simulação desenvolvido para este estudo. A interface gráfica integra a renderização espacial da arena, a telemetria das posições estimadas face ao *ground truth* e os painéis de monitoramento temporal de RMSE e NIS. Essa estrutura permite a manipulação direta das matrizes de covariância $\mathbf{Q}$ e $\mathbf{R}$, viabilizando a análise empírica do impacto da calibração nas elipses de incerteza do filtro.

B. Análise de Acurácia Posicional e Distribuição de Erros

A parametrização do EKF apresentou correlação direta com a mitigação do ruído de observação. Conforme os dados consolidados (Tabela II) e as trajetórias detalhadas no Apêndice A, a configuração sintonizada manteve o RMSE_x e o RMSE_y em níveis sub-métricos (abaixo de 0,32 m) nos cenários sem oclusão. No Cenário 2 (Trajetória Quadrada), que impõe descontinuidades de aceleração ortogonal, o Erro Máximo situou-se em 1,06 m sob calibração adequada. Em contrapartida, a configuração não sintonizada registrou picos de erro de 2,27 m devido ao atraso de convergência.

A evolução temporal dessa métrica é detalhada na Figura 7, onde a curva de erro da condição calibrada permanece contida dentro da margem operacional prevista.

Para aprofundar a avaliação da estabilidade do filtro ótimo, a Figura 8 apresenta o comportamento estocástico dos resíduos de predição. Nos gráficos de dispersão e histogramas associados à condição sintonizada, nota-se que os erros de estimacão em X e Y se distribuem assintoticamente como uma normal bivariada, com viés médio estatisticamente nulo ($\mu_x \approx +0,01$ m). Quando a sintonia falha, a distribuição perde a sua característica gaussiana e exhibe caudas pesadas, refletindo o descompasso geométrico.

C. Consistência Estatística e Monitoramento do NIS

A adequação entre a incerteza teórica modelada e a variância real observada foi quantificada pela estatística *Normalized Innovation Squared* (NIS). Considerando o modelo de quatro balizas, o limite superior da distribuição χ^2 (para 95% de confiança) é 9,49.

¹Disponível em: <https://github.com/SauloJose/PASKalmanTraj> - Acesso em: 20 jun. 2026.

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	$RMSE_x$ [m]	$RMSE_y$ [m]	E_{max} [m]	μ_x [m]	NIS	$NIS > 9,49$ (%)	TD (%)	TI (%)
CONDIÇÃO SINTONIZADA (Q = 1.0; R = 0.9)								
Cenário 1	0,09	0,15	0,57	+0,01	0,40	0,00%	100,00%	100,00%
Cenário 2	0,22	0,32	1,06	-0,01	0,96	0,00%	100,00%	95,22%
Cenário 3	0,11	0,14	0,61	+0,00	0,66	0,00%	100,00%	99,50%
Cenário 4	0,10	0,15	0,54	+0,01	0,66	0,00%	100,00%	99,83%
Cenário 5	0,14	0,21	0,71	+0,00	0,75	0,00%	100,00%	99,25%
Cenário 6	0,21	0,38	2,69	+0,02	0,70	0,00%	90,00%	99,54%
CONDIÇÃO NÃO SINTONIZADA (Ex. Q reduzido e R subestimado)								
Cenário 1	0,23	0,35	0,85	+0,01	9,47	42,58%	100,00%	13,75%
Cenário 2	0,61	0,82	2,27	-0,02	26,84	62,99%	100,00%	13,31%
Cenário 3	0,22	0,26	1,05	+0,00	42,39	91,00%	100,00%	42,25%
Cenário 4	0,19	0,26	0,98	+0,01	45,33	91,83%	100,00%	35,33%
Cenário 5	0,20	0,28	0,97	+0,01	42,76	91,08%	100,00%	45,00%
Cenário 6	0,22	0,43	2,49	-0,01	42,39	89,17%	90,00%	45,83%

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limite do NIS a 95% de confiança (4 G.L.) é $\approx 9,49$.




Figura 6: Ambiente gráfico desenvolvido em Python. O painel central exibe a cinemática do alvo, ladeado pelos controles de simulação à esquerda e gráficos de monitoramento temporal à direita.

Como ilustra a Figura 9, o EKF sintonizado não apresentou violação desse limite. A média operacional manteve-se abaixo de 1,0, configurando uma abordagem conservadora. Esse superdimensionamento mitigou a divergência da matriz Jacobiana. Por outro lado, o perfil não sintonizado incorreu em subestimação severa, com taxas de violação ultrapassando os 91% (ver gráficos completos no Apêndice A).

D. Região de Confiança (ROI) e Taxa de Inliers

A métrica Taxa de Inliers (TI) atua como um mecanismo complementar de diagnóstico. Nos cenários sintonizados, a TI apresentou valores superiores a 95%, confirmando que a

região de confiança gerada abarca de forma realista o entorno estocástico do agente. Quando as matrizes foram restringidas (perfil não sintonizado), a TI caiu abruptamente para a faixa dos 13% a 45%, atestando a desconexão do modelo perante a física da simulação.

E. Resposta Transitória sob Oclusão (Cenário 6)

O Cenário 6 ativou a propagação preditiva em malha aberta, limitando a Taxa de Detecção global a 90%. A Figura 10 detalha o instante de perda de sinal. A inércia retida nas estimativas de velocidade permitiu a progressão coerente do alvo. O erro pontual alcançou 2,69 m, contudo, o sistema não






Figura 7: Evolução temporal do RMSE (Cenário 2). A estabilidade da curva reflete a consistência do filtro quando devidamente sintonizado frente a manobras evasivas.



(a) Condição Sintonizada



(b) Condição Não Sintonizada

Figura 8: Histogramas e dispersão dos erros de previsão (Cenário 2). Em (a), a condição sintonizada converge para uma distribuição normal centrada no zero. Em (b), a ausência de calibração induz dispersão irregular e acúmulo de erros de fase.




Figura 9: Comportamento temporal da métrica NIS. A calibração adequada mantém o parâmetro abaixo do limite estatístico (9,49).

sofreu colapso numérico e readquiriu convergência imediatamente após a restauração do sinal das balizas.




Figura 10: Recorte do Cenário 6 sob oclusão temporária. O EKF propaga a cinemática em malha aberta sem divergência crítica.

VI. CONCLUSÃO

A. Resumo

Este trabalho apresentou o desenvolvimento e a análise experimental de um Filtro de Kalman Estendido (EKF) para o rastreamento bidimensional de alvos móveis, utilizando medições não lineares de distância (*range-only*). Através de um ambiente de simulação consolidado em Python, o estimador foi submetido a seis cenários cinemáticos fundamentados no modelo contínuo de Posição-Velocidade-Aceleração (PVA). O estudo focou em quantificar o impacto direto da parametrização estocástica (matrizes $\mathbf{Q}$ e $\mathbf{R}$) sobre a acurácia posicional, a consistência estatística e a estabilidade operacional do filtro.

B. Principais Constatções

Os resultados comprovaram a eficácia do EKF sintonizado na mitigação de ruídos de medição, mantendo a acurácia em níveis estritamente submétricos (com RMSE variando entre 0,09 m e 0,38 m) em todos os cenários. O Cenário 6 (oclusão temporária) atestou a robustez da formulação PVA, que permitiu ao sistema reter a inércia cinemática do alvo e evitar o colapso numérico durante apagões sensoriais, propagando a trajetória coerentemente em malha aberta.

Em contrapartida, constatou-se a sensibilidade crítica do filtro à calibração: a subestimação combinada do ruído de processo e da medição na configuração não sintonizada induziu inércia matricial excessiva. Isso gerou distribuições de erro não gaussianas, distanciamento espacial e atraso de fase nas curvas, com o erro máximo duplicando em trajetórias com acelerações ortogonais abruptas (como o salto de 1,06 m para 2,27 m no Cenário Quadrado).

C. Contribuições

As principais contribuições empíricas e analíticas deste trabalho incluem:

- A consolidação de uma arquitetura de simulação para o monitoramento contínuo das matrizes de covariância e renderização espacial das elipses de incerteza em tempo de execução.
- O mapeamento do *Normalized Innovation Squared* (NIS) como um validador estatístico de consistência. O trabalho evidenciou matematicamente a divergência estrutural de filtros descalibrados, cujas inovações violaram o limite teórico de 9,49 em mais de 91% do tempo de simulação nas trajetórias de alta manobrabilidade.
- A formulação da Taxa de *Inliers* baseada na crença *a priori* (ROI Dinâmica). Esta métrica confirmou seu valor como um diagnóstico passivo e explícito da saúde do filtro: enquanto a sintonia ideal garantiu taxas superiores a 95%, o colapso paramétrico foi imediatamente denunciado pela queda abrupta das taxas para níveis críticos (cerca de 13% a 45%).

D. Limitações

A avaliação dependeu da injeção de ruído estritamente gaussiano. Em aplicações de rádio-localização no mundo real, o erro sensorial apresenta componentes de cauda longa e vieses severos provocados por caminhos múltiplos (*multipath*) e perdas de visada direta (*Non-Line-of-Sight* - NLOS). Além disso, a calibração heurística das matrizes atendeu com sucesso aos propósitos de diagnóstico desta análise comparativa, mas não garante matematicamente o encontro do ótimo global da função de custo para as matrizes $\mathbf{Q}$ e $\mathbf{R}$.

E. Trabalhos Futuros

Para suprir as limitações identificadas e avançar na robustez do sistema, sugerem-se como extensões diretas:

- **Validação Experimental:** Substituir os dados sintéticos por medições físicas em ambiente *indoor*, utilizando redes de sensores *Ultra-Wideband* (UWB), avaliando assim o

comportamento do filtro sob ruídos reais de reflexão e atenuação.

- **Filtros Livres de Derivadas:** Comparar a eficiência computacional e a acurácia preditiva do EKF com técnicas que dispensam a aproximação linear (cálculo de matrizes Jacobianas), como o Filtro de Kalman *Unscented* (UKF) ou Filtros de Partículas (PF).
- **Sintonia Adaptativa:** Implementar métodos de ajuste estocástico dinâmico (como *Fuzzy Logic* ou *Reinforcement Learning*), permitindo que o sistema dimensione o ruído de processo em tempo real conforme a intensidade da manobra detectada.

F. Conclusão Final

O estudo demonstra de maneira categórica que a eficácia da filtragem não linear depende substancialmente do rigor na modelagem estocástica prévia. A associação de métricas estatísticas rígidas (como o NIS) a validadores geométricos de crença (Taxa de *Inliers*) estabeleceu um arcabouço robusto para auditar o estimador. Conclui-se que assegurar a fidedignidade da matriz de covariância é tão imperativo quanto o cálculo da própria posição, configurando-se como o requisito primário para a integração segura de algoritmos de estimação em malhas de controle de veículos e sistemas de navegação autônoma.

APÊNDICE

Este apêndice compila o mapeamento visual detalhado das simulações, apresentando as estimativas espaciais e a evolução temporal do *Normalized Innovation Squared* (NIS) para todos os seis cenários de navegação. O sequenciamento das imagens permite contrastar diretamente a precisão e a consistência do EKF operando em sua condição sintonizada contra a degradação estrutural gerada pela ausência de calibração.

Para assegurar a transparência da pesquisa e fomentar a reprodutibilidade dos ensaios conduzidos, o código-fonte integral da ferramenta de simulação foi disponibilizado em um repositório público. O material suplementar compreende a implementação da Interface Gráfica (GUI) em Python, a formulação matricial do Filtro de Kalman Estendido (EKF) e os *scripts* responsáveis pela geração das trajetórias e das malhas de ruído.

Além dos códigos-fonte, o repositório hospeda o conjunto completo de resultados gráficos em alta resolução (abrangendo todas as configurações paramétricas, métricas de inovações e trajetórias espaciais) que, por restrições de formatação e limites de página, não puderam ser expostos na íntegra no escopo deste documento.

O acesso à plataforma simuladora e à base de dados suplementar pode ser realizado por meio do seguinte endereço eletrônico:

<https://github.com/SauloJose/PASKalmanTra>

Os leitores são instigados a acessar o repositório supracitado [10] para executar o motor de simulação localmente. O ambiente possibilita a inspeção interativa da sintonia fina das matrizes de covariância $\mathbf{Q}$ e $\mathbf{R}$, além da visualização dinâmica




Figura 11: Trajetórias estimadas na **condição sintonizada**. Observa-se o rastreamento adequado da dinâmica do alvo e a mitigação contínua do ruído de observação.

da Região de Interesse (ROI) adaptativa e da propagação cinemática das elipses de incerteza do agente no plano bidimensional.

REFERÊNCIAS

- [1] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [6] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [7] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [8] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [9] D. Simon, *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.




Figura 12: Trajetórias estimadas na **condição não sintonizada**. Notam-se distanciamentos do *ground truth*, atrasos de fase evidentes nas curvas e ultrapassagens bruscas.




Figura 13: Evolução temporal da métrica NIS para a **condição sintonizada**. A estatística mantém-se estritamente abaixo do limite de confiança de 95% (linha tracejada em 9,49), comprovando a consistência interna do estimador.




Figura 14: Evolução temporal da métrica NIS para a **condição não sintonizada**. O rompimento abrupto do limiar estatístico atesta o colapso estrutural da confiança da matriz preditiva.