

Filtragem de Kalman em Sistemas de Visão Computacional: Rastreamento Bidimensional de Alvos Sob Oclusão

Saulo José Almeida Silva, *Mestrando, UFCG*,

Resumo—Este trabalho apresenta o desenvolvimento e a validação experimental de um sistema de rastreamento bidimensional baseado na fusão de visão computacional e Filtragem de Kalman. O sistema utiliza um algoritmo de segmentação por cor para detectar as coordenadas X e Y de um objeto alvo laranja sobre um fundo preto. Para mitigar os efeitos de ruídos de medição e, principalmente, lidar com situações de oclusão temporária do alvo, o Filtro de Kalman foi implementado para estimar e prever a trajetória contínua do objeto. Os resultados demonstram a robustez da abordagem, que mantém a precisão da localização robótica mesmo durante a perda completa do sinal visual, validando o método para aplicações em ambientes práticos e dinâmicos.

Index Terms—Filtro de Kalman, Visão Computacional, Rastreamento de Objetos, Oclusão, Robótica Móvel.

I. INTRODUÇÃO

ALGO

A. Notação e Convenções

Ao longo deste trabalho, adota-se um rigor matemático onde escalares são indicados por letras minúsculas em itálico (*a*), vetores por letras minúsculas em negrito (**a** ou **μ**) e matrizes por letras maiúsculas em negrito (**A** ou **Σ**).

No domínio do tempo discreto, o subscrito k denota o instante amostral atual (e.g., $\mathbf{x}_k$). Para os estimadores de estado, a notação subscrita $k|k-1$ ou o uso do símbolo superior em barra (como em $\bar{\mathbf{x}}_k$ ou $\bar{\mu}_k$) representam a estimativa *a priori* (etapa de predição), calculada com base no histórico até o instante $k-1$. Por sua vez, a notação $k|k$, ou o uso do índice k sem a barra ($\mathbf{x}_k$ ou μ_k), indica a estimativa *a posteriori* (estado corrigido), obtida após a incorporação da medição do instante atual.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

As metodologias de localização e rastreamento em robótica evoluíram significativamente nas últimas décadas, impulsionadas pelo avanço da visão computacional [1]. Esta seção revisa os conceitos de sistemas estocásticos e suas discretizações, a formulação matemática da robótica probabilística e detalha o Filtro de Kalman (linear e estendido), estabelecendo a base teórica para o desenvolvimento deste trabalho.

S. J. A. Silva é mestrando no Programa de Pós-Graduação em Engenharia Elétrica (PPgEE) da Universidade Federal de Campina Grande (UFCG), Campina Grande, PB, Brasil. E-mail: saulo.jose.silva@ee.ufcg.edu.br.

A. Sistemas Dinâmicos Estocásticos

Sistemas robóticos operam em ambientes físicos e são modelados no espaço de estados. Contudo, devido a perturbações ambientais e limitações mecânicas, tornam-se estocásticos. A evolução do estado de um sistema em tempo discreto é regida por equações de transição e de medição, representadas abstratamente pelas leis de probabilidade dadas nas Equações (1) e (2):

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (1)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (2)$$

onde k é o índice do passo temporal discreto, $\mathbf{x}_k$ é o vetor de estado, $\mathbf{u}_k$ o comando de controle aplicado, e $\mathbf{z}_k$ a medição observada (como as coordenadas cartesianas advindas da visão).

B. Incertezas na Medição e no Modelo

A natureza estocástica descrita na Seção II-A manifesta-se através de dois ruídos principais [2]:

- 1) **Ruído de Processo:** Modela forças externas não mapeadas e imperfeições físicas que afetam a dinâmica do robô.
- 2) **Ruído de Medição:** Engloba as imprecisões inerentes aos sensores. Em sistemas de visão computacional, incluem-se variações de iluminação, ruído de discretização de pixels e desfoque de movimento [1].

O mapeamento rigoroso dessas incertezas é crucial para garantir a estabilidade dos estimadores em trajetórias complexas [3].

C. Discretização do Sistema e das Covariâncias

Os modelos cinemáticos são originalmente contínuos no tempo (t). Contudo, processadores embarcados operam em intervalos discretos de amostragem Δt . Assumindo um controle constante $\mathbf{u}_k$ aplicado no intervalo de amostragem, transforma-se o sistema contínuo linear $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ na sua contraparte discreta, apresentada na Equação (3):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k \quad (3)$$

As matrizes de transição ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) presentes na Equação (3) são obtidas analiticamente por meio da Equação (4):

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{B}_c d\tau \quad (4)$$

Discretização dos Erros (Incertezas): A discretização também afeta as matrizes de covariância dos ruídos discutidos na Seção II-B. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se no tempo interagindo com a dinâmica do sistema. A matriz discreta equivalente $\mathbf{Q}_k$ é dada pela integração na Equação (5):

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (5)$$

Para taxas de amostragem suficientemente rápidas (Δt pequeno), esta integração é comumente aproximada de forma linear por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, indicando que a incerteza do modelo cresce proporcionalmente ao tempo entre as amostras.

Extensão para Sistemas Não-Lineares: Se o sistema for regido por dinâmicas não-lineares, conforme a forma contínua expressa na Equação (6):

$$\dot{\mathbf{x}}(t) = f(\mathbf{x}(t), \mathbf{u}(t)) \quad (6)$$

aproxima-se a discretização por métodos numéricos, como o Método de Euler, resultando no modelo da Equação (7):

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (7)$$

Para estimadores probabilísticos, esse modelo discreto deve ser linearizado via matrizes Jacobianas a cada passo k para permitir a propagação da incerteza [4].

D. Robótica Probabilística e Suposição de Markov

Devido às incertezas já estabelecidas, introduz-se o conceito de *belief* (crença) para representar a distribuição de probabilidade a posteriori sobre o estado, condicionada aos dados passados [4], conforme denotado pela Equação (8):

$$bel(\mathbf{x}_k) = P(\mathbf{x}_k \mid \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (8)$$

Para tornar o cálculo recursivo do *belief* viável, adota-se a **Suposição de Markov**. Ela postula que o estado atual $\mathbf{x}_k$ consolida toda a informação histórica necessária. Logo, o futuro é independente do passado se o estado presente for conhecido, simplificando a probabilidade para a forma da Equação (9):

$$P(\mathbf{x}_k \mid \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (9)$$

Essa suposição permite a quebra da equação do *belief* em etapas iterativas de predição e correção, formando a base algorítmica dos filtros detalhados a seguir [5].

E. Filtro de Kalman

O Filtro de Kalman (FK) [6] é uma implementação analítica do Filtro de Bayes para sistemas de domínio contínuo ou discreto, assumindo linearidade e que os ruídos (Seção II-B) seguem distribuições Gaussianas.

1) Filtro de Kalman Linear: Utilizando o sistema discretizado da Seção II-C, a dinâmica e a medição são descritas nas Equações (10) e (11) com a adição dos vetores de ruído de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (10)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (11)$$

sendo $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O algoritmo estima recursivamente a média μ_k e a covariância Σ_k do *belief*, dividindo o processo nas etapas de predição e correção, conforme estruturado no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \bar{\mu}_k \leftarrow \mathbf{A}_k \mu_{k-1} + \mathbf{B}_k \mathbf{u}_k$$

$$2: \bar{\Sigma}_k \leftarrow \mathbf{A}_k \Sigma_{k-1} \mathbf{A}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$3: \mathbf{K}_k \leftarrow \bar{\Sigma}_k \mathbf{H}_k^T (\mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$4: \mu_k \leftarrow \bar{\mu}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \bar{\mu}_k)$$

$$5: \Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\Sigma}_k (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: μ_k, Σ_k

Em cenários de oclusão visual severa, a etapa de correção (linhas 4 a 6) é omitida, e o filtro opera unicamente via predição, propagando a incerteza do sistema de forma contínua.

2) Filtro de Kalman Estendido (EKF): Se o sistema possuir dinâmica não-linear, aplica-se o EKF [4]. Substituem-se as matrizes lineares por funções generalizadas g e h , como definido nas Equações (12) e (13):

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (12)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (13)$$

A linearização necessária para calcular as matrizes de covariância é obtida por meio de matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$, avaliadas na estimativa atual, de acordo com as Equações (14) e (15):

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \mu_{k-1}} \quad (14)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \mu_k} \quad (15)$$

Estas substituem as matrizes lineares $\mathbf{A}_k$ e $\mathbf{H}_k$ (vistas nas Equações 10 e 11) nas etapas de atualização de covariância e cálculo do ganho de Kalman ($\mathbf{K}_k$), viabilizando o rastreamento em geometrias mais complexas, conforme detalhado no Algoritmo 2.

Algorithm 2 Filtro de Kalman Estendido (EKF)**Require:** $\mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_k$ **Predição (Propagação do Modelo):**

- 1: $\bar{\mu}_k \leftarrow g(\mathbf{u}_k, \mu_{k-1})$
- 2: $\mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \mu_{k-1})$
- 3: $\bar{\Sigma}_k \leftarrow \mathbf{G}_k \Sigma_{k-1} \mathbf{G}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

- 4: $\mathbf{H}_k \leftarrow \text{Jacobiano}(h, \bar{\mu}_k)$
- 5: $\mathbf{K}_k \leftarrow \bar{\Sigma}_k \mathbf{H}_k^T (\mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$
- 6: $\mu_k \leftarrow \bar{\mu}_k + \mathbf{K}_k (\mathbf{z}_k - h(\bar{\mu}_k))$
- 7: $\Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\Sigma}_k (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: μ_k, Σ_k *F. Métricas de Avaliação e Consistência do Estimador*

Para aferir o desempenho de filtros de Kalman, utilizam-se métricas de precisão geométrica e testes de consistência estatística baseados nas propriedades dos resíduos [4].

1) *Root Mean Square Error (RMSE)*: A precisão espacial do estimador em trajetórias bidimensionais é quantificada por meio do Erro Médio Quadrático de Translação (*Root Mean Square Error* - RMSE). O RMSE avalia a distância Euclidiana entre o estado real (ou medição de referência) $\mathbf{x}_k$ e o estado estimado μ_k ao longo de um horizonte temporal de N amostras, conforme definido pela Equação (16):

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \mu_k\|^2} \quad (16)$$

2) *Normalized Innovation Squared (NIS)*: A acurácia geométrica dada pelo RMSE não garante que o filtro esteja estatisticamente consistente. Um filtro é dito consistente se os seus erros de estimação possuírem média nula e covariância condizente com a matriz calculada pelo próprio algoritmo [4]. Essa propriedade é verificada por meio da Inovação Normalizada Quadrática (*Normalized Innovation Squared* - NIS).

A inovação (ou resíduo de medição), denotada por $\tilde{\mathbf{y}}_k$, é definida na Equação (17):

$$\tilde{\mathbf{y}}_k = \mathbf{z}_k - \mathbf{H}_k \bar{\mu}_k \quad (17)$$

A sua covariância teórica correspondente, calculada na etapa de correção, é apresentada na Equação (18):

$$\mathbf{S}_k = \mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k \quad (18)$$

O escalar NIS (ϵ_k) é então obtido pela forma quadrática de Mahalanobis, estabelecida na Equação (19):

$$\epsilon_k = \tilde{\mathbf{y}}_k^T \mathbf{S}_k^{-1} \tilde{\mathbf{y}}_k \quad (19)$$

Sob a hipótese nula de que o modelo linear dinâmico e as matrizes de covariância dos ruídos ($\mathbf{Q}_k$ e $\mathbf{R}_k$) mapeiam perfeitamente a realidade física do sistema, a variável aleatória ϵ_k segue uma distribuição Qui-Quadrado (χ^2) com l graus de liberdade, onde l representa a dimensão do vetor de medição $\mathbf{z}_k$ (neste trabalho, $l = 2$ para as coordenadas espaciais X e Y).

Teoricamente, se o histograma empírico dos valores de NIS obtidos experimentalmente se ajustar de forma aderente à cauda da função de densidade de probabilidade Qui-Quadrado, o filtro é considerado ideal. Desvios sistemáticos indicam que o filtro está subestimando ou superestimando as incertezas do sensor ou do processo [1].

III. VISÃO GERAL DO PROBLEMA

As metodologias de detecção de falhas evoluíram significativamente ao longo das últimas décadas [?]. Esta seção revisa os conceitos fundamentais e as técnicas relevantes para os oito métodos investigados neste trabalho, apresentando uma comparação compatível com estudos benchmarks pretritos.

IV. METODOLOGIA E IMPLEMENTAÇÃO

Esta seção descreve a formulação do problema de rastreamento adaptada ao cenário experimental, detalhando a parametrização do espaço de estados, as transformações geométricas e os critérios numéricos e estatísticos empregados para a avaliação de desempenho do estimador.

A. Formulação do Problema e Parametrização Espacial

O sistema proposto visa rastrear a trajetória contínua de um objeto no plano bidimensional real a partir de coordenadas discretas de pixels extraídas por um algoritmo de visão computacional. O estado dinâmico do sistema no passo k é modelado pelo vetor de estados cinemáticos de ordem cinemática completa (Posição-Velocidade-Aceleração) $\mathbf{x}_k \in \mathbb{R}^6$, definido por:

$$\mathbf{x}_k = [x_k, \dot{x}_k, \ddot{x}_k, y_k, \dot{y}_k, \ddot{y}_k]^T \quad (20)$$

onde os pares (x, y) , $(\dot{x}, \dot{y})$ e $(\ddot{x}, \ddot{y})$ representam, respectivamente, a posição (em metros), a velocidade e a aceleração nos eixos cartesianos correspondentes.

A evolução do sistema baseia-se na dinâmica linear discreta apresentada na Equação (10). A matriz de transição de estados $\mathbf{A}_k \in \mathbb{R}^{6 \times 6}$ é obtida analiticamente via Equação (4), parametrizada pelo período de amostragem do sensor visual $\Delta t = 1/\text{FPS}$. A incerteza do modelo cinemático é encapsulada na matriz de covariância do ruído do processo $\mathbf{Q}_k \in \mathbb{R}^{6 \times 6}$ através da discretização expressa na Equação (5), sendo sua diagonal inicial definida pelo vetor de configuração de sintonia do sistema.

As observações primárias geradas pelo detector de centroide ocorrem no espaço discretizado da imagem $\mathbf{p}_k = [u_k, v_k]^T$ (em pixels). Antes da execução do passo de correção do estimador, executa-se uma transformação geométrica linear invertível $\mathcal{T} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ para converter a posição bidimensional do plano da imagem para a escala métrica real do mundo:

$$\mathbf{z}_k = \mathcal{T}(\mathbf{p}_k) = [m_{x,k}, m_{y,k}]^T \quad (21)$$

O vetor resultante $\mathbf{z}_k \in \mathbb{R}^2$ alimenta a equação de medição (11), onde a matriz de observação $\mathbf{H}_k \in \mathbb{R}^{2 \times 6}$ isola os componentes de posição (x_k, y_k) do vetor de estados, e $\mathbf{R}_k \in \mathbb{R}^{2 \times 2}$ representa a covariância do ruído intrínseco do detector.

B. Métodos de Avaliação e Consistência

Para avaliar o desempenho operacional e validar a consistência estocástica do filtro implementado, adota-se um conjunto de métricas computadas de forma centralizada a cada iteração do algoritmo.

1) *Convergência para o Regime Estacionário*: O estimador atinge o regime estacionário quando a matriz de covariância do erro Σ_k converge para uma estrutura invariante no tempo. Numericamente, esta condição é verificada avaliando o traço da diferença absoluta entre partições consecutivas da matriz de covariância do filtro:

$$\Delta \Sigma_k = \text{Tr}(|\Sigma_k - \Sigma_{k-1}|) < \tau \quad (22)$$

onde estabelece-se o limiar de tolerância $\tau = 10^{-2}$ para decretar a estabilização estatística do erro de estimativa.

2) *Validação de Inliers via Região de Interesse Dinâmica*: Com o intuito de estruturar algoritmos de busca ativa e predição adaptativa de janelas de busca (*Active Vision*), introduz-se a validação de medições baseada na inovação *a posteriori* $\tilde{y}_k^+$, calculada após a etapa de correção:

$$\tilde{y}_k^+ = \mathbf{z}_k - \mathbf{H}_k \boldsymbol{\mu}_k = [\tilde{y}_{x,k}^+, \tilde{y}_{y,k}^+]^T \quad (23)$$

Uma medição é classificada como um *inlier* válido se satisfizer simultaneamente o critério de limiarização multi-sigma (3σ) ancorado na covariância teórica da inovação $\mathbf{S}_k$, expresso separadamente para os eixos através das Equações (24) e (25):

$$|\tilde{y}_{x,k}^+| \leq 3\sqrt{\mathbf{S}_k(1,1)} \quad (24)$$

$$|\tilde{y}_{y,k}^+| \leq 3\sqrt{\mathbf{S}_k(2,2)} \quad (25)$$

3) *Métricas Estatísticas Globais*: A acurácia do rastreamento é decomposta nos eixos ortogonais a partir do erro quadrático médio (RMSE) isolado, definido pelas Equações (26) e (27):

$$\text{RMSE}_x = \sqrt{\frac{1}{N} \sum_{k=1}^N (\mu_{x,k} - m_{x,k})^2} \quad (26)$$

$$\text{RMSE}_y = \sqrt{\frac{1}{N} \sum_{k=1}^N (\mu_{y,k} - m_{y,k})^2} \quad (27)$$

onde $\mu_{x,k}$ e $\mu_{y,k}$ denotam as posições estimadas. Adicionalmente, computa-se o erro médio com sinal (viés de estimação) para quantificar tendências sistemáticas por meio das Equações (28) e (29):

$$\text{ME}_x = \frac{1}{N} \sum_{k=1}^N (\mu_{x,k} - m_{x,k}) \quad (28)$$

$$\text{ME}_y = \frac{1}{N} \sum_{k=1}^N (\mu_{y,k} - m_{y,k}) \quad (29)$$

A consistência estocástica global ao longo da sequência é mensurada por meio do NIS médio ($\bar{\epsilon}$), de acordo com a Equação (30):

$$\bar{\epsilon} = \frac{1}{N_{\text{meas}}} \sum_{k \in \mathcal{K}} \epsilon_k \quad (30)$$

onde $\mathcal{K}$ representa o subconjunto de frames em que medições válidas foram registradas.

Por fim, a eficiência macroscópica do rastreador é avaliada pela taxa de detecção do sensor (DR) na Equação (31) e pela acurácia de inliers na região de interesse (IR) na Equação (32):

$$DR = \left(\frac{N_{\text{meas}}}{N_{\text{total}}} \right) \times 100\% \quad (31)$$

$$IR = \left(\frac{N_{\text{inliers}}}{N_{\text{meas}}} \right) \times 100\% \quad (32)$$

sendo N_{total} o número total de quadros do vídeo, N_{meas} o total de frames lidos e N_{inliers} o montante de amostras validadas restritamente pelas Equações (24) e (25).

C. Geração Sintética de Trajetórias

Para validar os critérios numéricos estabelecidos na Seção IV-B e testar o estimador formulado na Seção IV-A, concebeu-se um gerador de trajetórias sintéticas. Cada modelo gera o estado cinemático $\mathbf{x}_k$ do alvo para diferentes dinâmicas de movimento, conforme descrito a seguir.

1) *Trajetórias Determinísticas*: As trajetórias determinísticas modelam comportamentos geométricos conhecidos. A primeira delas, descrita no Algoritmo 3, simula o movimento circular uniforme. Este cenário avalia a capacidade do filtro de lidar com variações constantes na aceleração centrípeta e a suavidade da resposta.

Algorithm 3 Trajetória circular

Require: $v, r, (x_c, y_c), \Delta t$, índice k

- 1: $\omega \leftarrow v/r$
- 2: $\theta_k \leftarrow \omega k \Delta t$
- 3: $\mathbf{p}_k \leftarrow (x_c + r \cos \theta_k, y_c + r \sin \theta_k)^T$
- 4: $\dot{\mathbf{p}}_k \leftarrow (-\omega r \sin \theta_k, \omega r \cos \theta_k)^T$
- 5: $\ddot{\mathbf{p}}_k \leftarrow (-\omega^2 r \cos \theta_k, -\omega^2 r \sin \theta_k)^T$

Ensure: $\mathbf{x}_k \leftarrow (\mathbf{p}_k, \dot{\mathbf{p}}_k, \ddot{\mathbf{p}}_k)^T$

O Algoritmo 4 gera um movimento linear por trechos (formato quadrado). A transição abrupta de direção nos vértices representa um desafio cinemático, testando a robustez do Filtro de Kalman sob acelerações impulsivas imprevistas pelo modelo de estado.

Algorithm 4 Trajetória quadrada

Require: $v, L, \Delta t$, índice k

- 1: $T_a \leftarrow L/v$
- 2: $i \leftarrow \lfloor k \Delta t / T_a \rfloor \bmod 4$
- 3: $d_a \leftarrow (k \Delta t) \bmod T_a$
- 4: $\mathbf{v}_k \leftarrow \begin{cases} (v, 0)^T & \text{se } i = 0 \\ (0, v)^T & \text{se } i = 1 \\ (-v, 0)^T & \text{se } i = 2 \\ (0, -v)^T & \text{se } i = 3 \end{cases}$
- 5: $\mathbf{p}_k \leftarrow \begin{cases} (d_a, 0)^T & i = 0 \\ (L, d_a)^T & i = 1 \\ (L - d_a, L)^T & i = 2 \\ (0, L - d_a)^T & i = 3 \end{cases}$

Ensure: $\mathbf{x}_k$

Para simular transições de faixa mais suaves e dinâmicas, semelhantes à movimentação fluida de um veículo entre pistas, adota-se o modelo baseado na função tangente hiperbólica (Algoritmo 5).

Algorithm 5 Trajetória de mudança de faixa (tanh)

Require: $A, S, T_{\text{total}}, y_{\text{mid}}, v_x, \Delta t$, índice k

- 1: $t_{\text{norm}} \leftarrow \frac{2k\Delta t}{T_{\text{total}}} - 1$
- 2: $x_k \leftarrow v_x \frac{T_{\text{total}}}{k\Delta t}$
- 3: $y_k \leftarrow y_{\text{mid}} + A \tanh(S t_{\text{norm}})$
- 4: $\dot{y}_k \leftarrow \frac{2AS}{T_{\text{total}}} (1 - \tanh^2(S t_{\text{norm}}))$
- 5: $\ddot{y}_k \leftarrow -\frac{4AS^2}{T_{\text{total}}^2} \tanh(S t_{\text{norm}}) (1 - \tanh^2(S t_{\text{norm}}))$
- 6: $\dot{x}_k \leftarrow v_x, \ddot{x}_k \leftarrow 0$

Ensure: $\mathbf{x}_k = (x_k, y_k, \dot{x}_k, \dot{y}_k, \ddot{x}_k, \ddot{y}_k)^T$

A trajetória lemniscata, também conhecida como "oito deitado", é implementada pelo Algoritmo 6. Ela combina dinâmicas não triviais com acelerações variáveis em ambos os eixos, constituindo um teste rigoroso para a validação da modelagem de processo.

Algorithm 6 Trajetória lemniscata

Require: A, ω , centro (x_c, y_c) , Δt , índice k

- 1: $\theta_k \leftarrow \omega k\Delta t$
- 2: $\mathbf{p}_k \leftarrow (x_c + A \sin \theta_k, y_c + \frac{A}{2} \sin 2\theta_k)^T$
- 3: $\dot{\mathbf{p}}_k \leftarrow (A\omega \cos \theta_k, A\omega \cos 2\theta_k)^T$
- 4: $\ddot{\mathbf{p}}_k \leftarrow (-A\omega^2 \sin \theta_k, -2A\omega^2 \sin 2\theta_k)^T$

Ensure: $\mathbf{x}_k \leftarrow (\mathbf{p}_k, \dot{\mathbf{p}}_k, \ddot{\mathbf{p}}_k)^T$

2) *Trajetórias Estocásticas e Condicionais:* Para mimetizar um ambiente operacional mais realista e imprevisível, os cenários estocásticos e de oclusão avaliam o grau de autonomia e resiliência do filtro. O Algoritmo 7 gera uma navegação puramente aleatória, submetendo o filtro a frequentes alterações de velocidade e direção num regime livre de padrões periódicos.

Algorithm 7 Trajetória de navegação aleatória

Require: $\mathbf{x}_{k-1}, d$ (distância acumulada), $\phi_{\text{alvo}}, v_{\text{alvo}}, \dot{\phi}_{\text{max}}, \Delta t$

- 1: $d \leftarrow d + \|\mathbf{v}_{k-1}\| \Delta t$
- 2: **if** $d > 15 \text{ m}$ **then**
- 3: $\phi_{\text{alvo}} \leftarrow \mathcal{U}(0, 2\pi)$
- 4: $v_{\text{alvo}} \leftarrow \mathcal{U}(v_{\text{min}}, v_{\text{max}})$
- 5: $d \leftarrow 0$
- 6: **end if**
- 7: **if** $\|\mathbf{p}_{k-1}\| > 35 \text{ m}$ **then**
- 8: $\phi_{\text{alvo}} \leftarrow \text{atan2}(-y_{k-1}, -x_{k-1})$
- 9: **end if**
- 10: $\Delta\phi_{\text{max}} \leftarrow \dot{\phi}_{\text{max}} \Delta t$
- 11: $\Delta\phi \leftarrow \text{clamp}(\phi_{\text{alvo}} - \phi_{k-1}, -\Delta\phi_{\text{max}}, \Delta\phi_{\text{max}})$
- 12: $\phi_k \leftarrow \phi_{k-1} + \Delta\phi$
- 13: $\mathbf{v}_k \leftarrow v_{\text{alvo}} (\cos \phi_k, \sin \phi_k)^T$
- 14: $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$
- 15: $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$

Ensure: $\mathbf{x}_k \leftarrow (\mathbf{p}_k, \mathbf{v}_k, \mathbf{a}_k)^T$ e d atualizado

A robustez perante a perda total de medições temporárias (sensor inativo ou alvo obstruído fisicamente) é o objetivo do Algoritmo 8. A lógica introduz interrupções cíclicas na série de tempo observada, forçando o filtro a operar exclusivamente em seu estágio de predição cega por múltiplos *frames*, validando a precisão da matriz de transição estipulada e a evolução livre da covariância do erro.

Algorithm 8 Modelo de oclusão cíclica

Require: $N_{\text{steps}}, O_{\text{frames}}$, gerador de trajetória curta

- 1: $\mathbf{X}_{\text{base}} \leftarrow \text{GeraTrajetoriaCurta}(\leq 20 \text{ m}) \triangleright$ função externa
- 2: $\mathbf{M} \leftarrow \mathbf{1}_{N_{\text{steps}}} \triangleright$ máscara de visibilidade
- 3: **for** $q = 1$ até 4 **do**
- 4: $i_{\text{mid}} \leftarrow \lfloor (q - 0,5) N_{\text{steps}} / 4 \rfloor$
- 5: $\mathbf{M}[i_{\text{mid}} - \lfloor O_{\text{frames}} / 2 \rfloor : i_{\text{mid}} + \lfloor O_{\text{frames}} / 2 \rfloor] \leftarrow 0$
- 6: **end for**
- 7: **if** $M_k = 0$ **then**
- 8: $\mathbf{z}_k \leftarrow \emptyset$
- 9: **else**
- 10: $\mathbf{z}_k \leftarrow$ medição do sensor
- 11: **end if**

Ensure: $\mathbf{x}_k, M_k, \mathbf{z}_k$

V. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados experimentais obtidos com a aplicação de todas as nove abordagens de detecção de falhas ao processo Tennessee Eastman [?], [?]. Métricas abrangentes de desempenho são avaliadas em 21 cenários de falha para permitir uma análise comparativa rigorosa. As implementações seguem a metodologia descrita na Seção IV.

A. Análise Comparativa Geral

B. Resultados por Método

C. Recomendações Práticas

C

VI. CONCLUSÃO

A. Resumo

Este trabalho apresenta uma comparação abrangente de benchmark de nove metodologias distintas de detecção de falhas baseadas em dados aplicadas ao processo Tennessee Eastman [?], [?], [?]. O estudo avaliou tanto métodos estatísticos multivariados clássicos (PCA, DPCA) [?] quanto técnicas avançadas que incorporam dinâmica temporal (ICA, MICA) e objetivos de aprendizado supervisionado (variantes do PLS, FDA).

B. Principais Constatações

C. Contribuições

D. Limitações

E. Trabalhos Futuros

F. Conclusão Final

A detecção de falhas em processos industriais continua sendo um desafio importante, e este trabalho demonstra que não existe um método único “melhor” para todas as aplicações. Em vez disso, a seleção apropriada depende criticamente dos objetivos específicos, dos recursos disponíveis e das características do processo. A análise comparativa apresentada fornece uma base sólida para essa seleção informada, facilitando a implementação de sistemas de monitoramento mais eficazes e confiáveis em aplicações industriais.

REFERÊNCIAS

- [1] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [6] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.