

Filtragem de Kalman em Sistemas de Visão Computacional: Rastreamento Bidimensional de Alvos Sob Oclusão

Saulo José Almeida Silva, *Mestrando, UFCG*,

Resumo—Este trabalho apresenta o desenvolvimento e a validação experimental de um sistema de rastreamento bidimensional baseado na fusão de visão computacional e Filtragem de Kalman. O sistema utiliza um algoritmo de segmentação por cor para detectar as coordenadas X e Y de um objeto alvo laranja sobre um fundo preto. Para mitigar os efeitos de ruídos de medição e, principalmente, lidar com situações de oclusão temporária do alvo, o Filtro de Kalman foi implementado para estimar e prever a trajetória contínua do objeto. Os resultados demonstram a robustez da abordagem, que mantém a precisão da localização robótica mesmo durante a perda completa do sinal visual, validando o método para aplicações em ambientes práticos e dinâmicos.

Index Terms—Filtro de Kalman, Visão Computacional, Rastreamento de Objetos, Oclusão, Robótica Móvel.

I. INTRODUÇÃO

ALGO

A. Notação e Convenções

Ao longo deste trabalho, adota-se um rigor matemático onde escalares são indicados por letras minúsculas em itálico (*a*), vetores por letras minúsculas em negrito (**a** ou **μ**) e matrizes por letras maiúsculas em negrito (**A** ou **Σ**).

No domínio do tempo discreto, o subscrito k denota o instante amostral atual (e.g., $\mathbf{x}_k$). Para os estimadores de estado, a notação subscrita $k|k-1$ ou o uso do símbolo superior em barra (como em $\bar{\mathbf{x}}_k$ ou $\bar{\mu}_k$) representam a estimativa *a priori* (etapa de predição), calculada com base no histórico até o instante $k-1$. Por sua vez, a notação $k|k$, ou o uso do índice k sem a barra ($\mathbf{x}_k$ ou μ_k), indica a estimativa *a posteriori* (estado corrigido), obtida após a incorporação da medição do instante atual.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

As metodologias de localização e rastreamento em robótica evoluíram significativamente nas últimas décadas, impulsionadas pelo avanço da visão computacional [1]. Esta seção revisa os conceitos de sistemas estocásticos e suas discretizações, a formulação matemática da robótica probabilística e detalha o Filtro de Kalman (linear e estendido), estabelecendo a base teórica para o desenvolvimento deste trabalho.

S. J. A. Silva é mestrando no Programa de Pós-Graduação em Engenharia Elétrica (PPgEE) da Universidade Federal de Campina Grande (UFCG), Campina Grande, PB, Brasil. E-mail: saulo.jose.silva@ee.ufcg.edu.br.

A. Sistemas Dinâmicos Estocásticos

Sistemas robóticos operam em ambientes físicos e são modelados no espaço de estados. Contudo, devido a perturbações ambientais e limitações mecânicas, tornam-se estocásticos. A evolução do estado de um sistema em tempo discreto é regida por equações de transição e de medição, representadas abstratamente pelas leis de probabilidade dadas nas Equações (1) e (2):

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (1)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (2)$$

onde k é o índice do passo temporal discreto, $\mathbf{x}_k$ é o vetor de estado, $\mathbf{u}_k$ o comando de controle aplicado, e $\mathbf{z}_k$ a medição observada (como as coordenadas cartesianas advindas da visão).

B. Incertezas na Medição e no Modelo

A natureza estocástica descrita na Seção II-A manifesta-se através de dois ruídos principais [2]:

- 1) **Ruído de Processo:** Modela forças externas não mapeadas e imperfeições físicas que afetam a dinâmica do robô.
- 2) **Ruído de Medição:** Engloba as imprecisões inerentes aos sensores. Em sistemas de visão computacional, incluem-se variações de iluminação, ruído de discretização de pixels e desfoque de movimento [1].

O mapeamento rigoroso dessas incertezas é crucial para garantir a estabilidade dos estimadores em trajetórias complexas [3].

C. Discretização do Sistema e das Covariâncias

Os modelos cinemáticos são originalmente contínuos no tempo (t). Contudo, processadores embarcados operam em intervalos discretos de amostragem Δt . Assumindo um controle constante $\mathbf{u}_k$ aplicado no intervalo de amostragem, transforma-se o sistema contínuo linear $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ na sua contraparte discreta, apresentada na Equação (3):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k \quad (3)$$

As matrizes de transição ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) presentes na Equação (3) são obtidas analiticamente por meio da Equação (4):

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{B}_c d\tau \quad (4)$$

Discretização dos Erros (Incertezas): A discretização também afeta as matrizes de covariância dos ruídos discutidos na Seção II-B. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se no tempo interagindo com a dinâmica do sistema. A matriz discreta equivalente $\mathbf{Q}_k$ é dada pela integração na Equação (5):

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (5)$$

Para taxas de amostragem suficientemente rápidas (Δt pequeno), esta integração é comumente aproximada de forma linear por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, indicando que a incerteza do modelo cresce proporcionalmente ao tempo entre as amostras.

Extensão para Sistemas Não-Lineares: Se o sistema for regido por dinâmicas não-lineares, conforme a forma contínua expressa na Equação (6):

$$\dot{\mathbf{x}}(t) = f(\mathbf{x}(t), \mathbf{u}(t)) \quad (6)$$

aproxima-se a discretização por métodos numéricos, como o Método de Euler, resultando no modelo da Equação (7):

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (7)$$

Para estimadores probabilísticos, esse modelo discreto deve ser linearizado via matrizes Jacobianas a cada passo k para permitir a propagação da incerteza [4].

D. Robótica Probabilística e Suposição de Markov

Devido às incertezas já estabelecidas, introduz-se o conceito de *belief* (crença) para representar a distribuição de probabilidade a posteriori sobre o estado, condicionada aos dados passados [4], conforme denotado pela Equação (8):

$$bel(\mathbf{x}_k) = P(\mathbf{x}_k \mid \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (8)$$

Para tornar o cálculo recursivo do *belief* viável, adota-se a **Suposição de Markov**. Ela postula que o estado atual $\mathbf{x}_k$ consolida toda a informação histórica necessária. Logo, o futuro é independente do passado se o estado presente for conhecido, simplificando a probabilidade para a forma da Equação (9):

$$P(\mathbf{x}_k \mid \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (9)$$

Essa suposição permite a quebra da equação do *belief* em etapas iterativas de predição e correção, formando a base algorítmica dos filtros detalhados a seguir [5].

E. Filtro de Kalman

O Filtro de Kalman (FK) [6] é uma implementação analítica do Filtro de Bayes para sistemas de domínio contínuo ou discreto, assumindo linearidade e que os ruídos (Seção II-B) seguem distribuições Gaussianas.

1) Filtro de Kalman Linear: Utilizando o sistema discretizado da Seção II-C, a dinâmica e a medição são descritas nas Equações (10) e (11) com a adição dos vetores de ruído de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (10)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (11)$$

sendo $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O algoritmo estima recursivamente a média μ_k e a covariância Σ_k do *belief*, dividindo o processo nas etapas de predição e correção, conforme estruturado no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

1: $\bar{\mu}_k \leftarrow \mathbf{A}_k \mu_{k-1} + \mathbf{B}_k \mathbf{u}_k$

2: $\bar{\Sigma}_k \leftarrow \mathbf{A}_k \Sigma_{k-1} \mathbf{A}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

3: $\mathbf{K}_k \leftarrow \bar{\Sigma}_k \mathbf{H}_k^T (\mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$

4: $\mu_k \leftarrow \bar{\mu}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \bar{\mu}_k)$

5: $\Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\Sigma}_k (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: μ_k, Σ_k

Em cenários de oclusão visual severa, a etapa de correção (linhas 4 a 6) é omitida, e o filtro opera unicamente via predição, propagando a incerteza do sistema de forma contínua.

2) Filtro de Kalman Estendido (EKF): Se o sistema possuir dinâmica não-linear, aplica-se o EKF [4]. Substituem-se as matrizes lineares por funções generalizadas g e h , como definido nas Equações (12) e (13):

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (12)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (13)$$

A linearização necessária para calcular as matrizes de covariância é obtida por meio de matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$, avaliadas na estimativa atual, de acordo com as Equações (14) e (15):

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \mu_{k-1}} \quad (14)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \mu_k} \quad (15)$$

Estas substituem as matrizes lineares $\mathbf{A}_k$ e $\mathbf{H}_k$ (vistas nas Equações 10 e 11) nas etapas de atualização de covariância e cálculo do ganho de Kalman ($\mathbf{K}_k$), viabilizando o rastreamento em geometrias mais complexas, conforme detalhado no Algoritmo 2.

Algorithm 2 Filtro de Kalman Estendido (EKF)**Require:** $\mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_k$ **Predição (Propagação do Modelo):**

- 1: $\bar{\mu}_k \leftarrow g(\mathbf{u}_k, \mu_{k-1})$
- 2: $\mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \mu_{k-1})$
- 3: $\bar{\Sigma}_k \leftarrow \mathbf{G}_k \Sigma_{k-1} \mathbf{G}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

- 4: $\mathbf{H}_k \leftarrow \text{Jacobiano}(h, \bar{\mu}_k)$
- 5: $\mathbf{K}_k \leftarrow \bar{\Sigma}_k \mathbf{H}_k^T (\mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$
- 6: $\mu_k \leftarrow \bar{\mu}_k + \mathbf{K}_k (\mathbf{z}_k - h(\bar{\mu}_k))$
- 7: $\Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\Sigma}_k (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: μ_k, Σ_k *F. Métricas de Avaliação e Consistência do Estimador*

Para aferir o desempenho de filtros de Kalman, utilizam-se métricas de precisão geométrica e testes de consistência estatística baseados nas propriedades dos resíduos [4].

1) *Root Mean Square Error (RMSE)*: A precisão espacial do estimador em trajetórias bidimensionais é quantificada por meio do Erro Médio Quadrático de Translação (*Root Mean Square Error* - RMSE). O RMSE avalia a distância Euclidiana entre o estado real (ou medição de referência) $\mathbf{x}_k$ e o estado estimado μ_k ao longo de um horizonte temporal de N amostras, conforme definido pela Equação (16):

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \mu_k\|^2} \quad (16)$$

2) *Normalized Innovation Squared (NIS)*: A acurácia geométrica dada pelo RMSE não garante que o filtro esteja estatisticamente consistente. Um filtro é dito consistente se os seus erros de estimação possuírem média nula e covariância condizente com a matriz calculada pelo próprio algoritmo [4]. Essa propriedade é verificada por meio da Inovação Normalizada Quadrática (*Normalized Innovation Squared* - NIS).

A inovação (ou resíduo de medição), denotada por $\tilde{\mathbf{y}}_k$, é definida na Equação (17):

$$\tilde{\mathbf{y}}_k = \mathbf{z}_k - \mathbf{H}_k \bar{\mu}_k \quad (17)$$

A sua covariância teórica correspondente, calculada na etapa de correção, é apresentada na Equação (18):

$$\mathbf{S}_k = \mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k \quad (18)$$

O escalar NIS (ϵ_k) é então obtido pela forma quadrática de Mahalanobis, estabelecida na Equação (19):

$$\epsilon_k = \tilde{\mathbf{y}}_k^T \mathbf{S}_k^{-1} \tilde{\mathbf{y}}_k \quad (19)$$

Sob a hipótese nula de que o modelo linear dinâmico e as matrizes de covariância dos ruídos ($\mathbf{Q}_k$ e $\mathbf{R}_k$) mapeiam perfeitamente a realidade física do sistema, a variável aleatória ϵ_k segue uma distribuição Qui-Quadrado (χ^2) com l graus de liberdade, onde l representa a dimensão do vetor de medição $\mathbf{z}_k$ (neste trabalho, $l = 2$ para as coordenadas espaciais X e Y).

Teoricamente, se o histograma empírico dos valores de NIS obtidos experimentalmente se ajustar de forma aderente à cauda da função de densidade de probabilidade Qui-Quadrado, o filtro é considerado ideal. Desvios sistemáticos indicam que o filtro está subestimando ou superestimando as incertezas do sensor ou do processo [1].

III. VISÃO GERAL DO PROBLEMA

As metodologias de detecção de falhas evoluíram significativamente ao longo das últimas décadas [?]. Esta seção revisa os conceitos fundamentais e as técnicas relevantes para os oito métodos investigados neste trabalho, apresentando uma comparação compatível com estudos benchmarks pretritos.

IV. METODOLOGIA E IMPLEMENTAÇÃO

Esta seção descreve a formulação do problema de rastreamento adaptada ao cenário experimental, detalhando a parametrização do espaço de estados, as transformações geométricas e os critérios numéricos e estatísticos empregados para a avaliação de desempenho do estimador.

A. Formulação do Problema e Parametrização Espacial

O sistema proposto visa rastrear a trajetória contínua de um objeto no plano bidimensional real a partir de coordenadas discretas de pixels extraídas por um algoritmo de visão computacional. O estado dinâmico do sistema no passo k é modelado pelo vetor de estados cinemáticos de ordem cinemática completa (Posição-Velocidade-Aceleração) $\mathbf{x}_k \in \mathbb{R}^6$, definido por:

$$\mathbf{x}_k = [x_k, \dot{x}_k, \ddot{x}_k, y_k, \dot{y}_k, \ddot{y}_k]^T \quad (20)$$

onde os pares (x, y) , $(\dot{x}, \dot{y})$ e $(\ddot{x}, \ddot{y})$ representam, respectivamente, a posição (em metros), a velocidade e a aceleração nos eixos cartesianos correspondentes.

A evolução do sistema baseia-se na dinâmica linear discreta apresentada na Equação (10). A matriz de transição de estados $\mathbf{A}_k \in \mathbb{R}^{6 \times 6}$ é obtida analiticamente via Equação (4), parametrizada pelo período de amostragem do sensor visual $\Delta t = 1/\text{FPS}$. A incerteza do modelo cinemático é encapsulada na matriz de covariância do ruído do processo $\mathbf{Q}_k \in \mathbb{R}^{6 \times 6}$ através da discretização expressa na Equação (5), sendo sua diagonal inicial definida pelo vetor de configuração de sintonia do sistema.

As observações primárias geradas pelo detector de centroide ocorrem no espaço discretizado da imagem $\mathbf{p}_k = [u_k, v_k]^T$ (em pixels). Antes da execução do passo de correção do estimador, executa-se uma transformação geométrica linear invertível $\mathcal{T} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ para converter a posição bidimensional do plano da imagem para a escala métrica real do mundo:

$$\mathbf{z}_k = \mathcal{T}(\mathbf{p}_k) = [m_{x,k}, m_{y,k}]^T \quad (21)$$

O vetor resultante $\mathbf{z}_k \in \mathbb{R}^2$ alimenta a equação de medição (11), onde a matriz de observação $\mathbf{H}_k \in \mathbb{R}^{2 \times 6}$ isola os componentes de posição (x_k, y_k) do vetor de estados, e $\mathbf{R}_k \in \mathbb{R}^{2 \times 2}$ representa a covariância do ruído intrínseco do detector.

B. Métodos de Avaliação e Consistência

Para avaliar o desempenho operacional e validar a consistência estocástica do filtro implementado, adota-se um conjunto de métricas computadas de forma centralizada a cada iteração do algoritmo.

1) *Convergência para o Regime Estacionário*: O estimador atinge o regime estacionário quando a matriz de covariância do erro Σ_k converge para uma estrutura invariante no tempo. Numericamente, esta condição é verificada avaliando o traço da diferença absoluta entre partições consecutivas da matriz de covariância do filtro:

$$\Delta \Sigma_k = \text{Tr}(|\Sigma_k - \Sigma_{k-1}|) < \tau \quad (22)$$

onde estabelece-se o limiar de tolerância $\tau = 10^{-2}$ para decretar a estabilização estatística do erro de estimativa.

2) *Validação de Inliers via Região de Interesse Dinâmica*: Com o intuito de estruturar algoritmos de busca ativa e predição adaptativa de janelas de busca (*Active Vision*), introduz-se a validação estatística de medições baseada no vetor de inovação *a posteriori* $\tilde{y}_k^+$. Esse vetor é calculado imediatamente após a etapa de correção (Linha 5 do Algoritmo 1), isolando os resíduos dinâmicos para cada um dos eixos ortogonais do sistema:

$$\tilde{y}_{x,k}^+ = m_{x,k} - \mu_{x,k} \quad (23)$$

$$\tilde{y}_{y,k}^+ = m_{y,k} - \mu_{y,k} \quad (24)$$

onde $m_{x,k}$ e $m_{y,k}$ são as coordenadas reais observadas do centroide, enquanto $\mu_{x,k}$ e $\mu_{y,k}$ denotam as respectivas posições estimadas filtradas pelo algoritmo.

Estatisticamente, sob a condição de que o estimador opere de forma consistente e os ruídos associados sigam distribuições Gaussianas, a variância teórica esperada para esses resíduos é fornecida diretamente pelos elementos da diagonal principal da matriz de covariância da inovação S_k , deduzida na Equação (18). Assim, os desvios-padrão teóricos de referência para cada componente espacial são expressos isoladamente por:

$$\sigma_{x,k} = \sqrt{S_k(1,1)} \quad (25)$$

$$\sigma_{y,k} = \sqrt{S_k(2,2)} \quad (26)$$

Para realizar a análise estatística em tempo de execução e discriminar medições legítimas de ruídos espúrios ou falhas de segmentação (*outliers*), estabelece-se uma região de rejeição baseada no critério clássico de limiarização multi-sigma (3σ). Esse método delimita uma janela cinemática de confiança na qual assume-se, com aproximadamente 99,73% de probabilidade, que o objeto rastreado deve se posicionar. Uma medição é classificada rigorosamente como um *inlier* se cumprir simultaneamente as inequações estocásticas:

$$|\tilde{y}_{x,k}^+| \leq 3\sigma_{x,k} \quad (27)$$

$$|\tilde{y}_{y,k}^+| \leq 3\sigma_{y,k} \quad (28)$$

Essas restrições atuam como um filtro estatístico adaptativo de validação. Caso as coordenadas fornecidas pelo sensor visual violem os limites definidos pelas Equações (27) ou

(28), a amostra é estatisticamente descartada por ultrapassar a dispersão probabilística esperada para a dinâmica atual do modelo, mitigando a propagação de erros severos de oclusão e transições abruptas de fundo no estimador.

V. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados experimentais obtidos com a aplicação de todas as nove abordagens de detecção de falhas ao processo Tennessee Eastman [?], [?]. Métricas abrangentes de desempenho são avaliadas em 21 cenários de falha para permitir uma análise comparativa rigorosa. As implementações seguem a metodologia descrita na Seção IV.

A. Análise Comparativa Geral

B. Resultados por Método

C. Recomendações Práticas

C

VI. CONCLUSÃO

A. Resumo

Este trabalho apresenta uma comparação abrangente de benchmark de nove metodologias distintas de detecção de falhas baseadas em dados aplicadas ao processo Tennessee Eastman [?], [?], [?]. O estudo avaliou tanto métodos estatísticos multivariados clássicos (PCA, DPCA) [?] quanto técnicas avançadas que incorporam dinâmica temporal (ICA, MICA) e objetivos de aprendizado supervisionado (variantes do PLS, FDA).

B. Principais Constatações

C. Contribuições

D. Limitações

E. Trabalhos Futuros

F. Conclusão Final

A detecção de falhas em processos industriais continua sendo um desafio importante, e este trabalho demonstra que não existe um método único “melhor” para todas as aplicações. Em vez disso, a seleção apropriada depende criticamente dos objetivos específicos, dos recursos disponíveis e das características do processo. A análise comparativa apresentada fornece uma base sólida para essa seleção informada, facilitando a implementação de sistemas de monitoramento mais eficazes e confiáveis em aplicações industriais.

REFERÊNCIAS

- [1] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] P. Falek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.

- [5] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, "Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions," *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [6] R. E. Kalman, "A new approach to linear filtering and prediction problems," *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.