

# Rastreamento Bidimensional de Alvos via Filtro de Kalman Estendido em Sistemas de Posicionamento por Estações Base

Saulo José Almeida Silva, *Mestrando, UFCG,*

**Resumo**—A localização precisa é um requisito fundamental para a operação autônoma de sistemas robóticos móveis, viabilizando a execução de tarefas críticas como navegação, mapeamento e coordenação. Este trabalho apresenta o desenvolvimento, a implementação e a análise das propriedades do Filtro de Kalman Estendido (EKF) aplicado à localização em tempo real de agentes móveis. O sistema sob análise é caracterizado por um modelo dinâmico linear e um modelo de observação não-linear, o que justifica o emprego da variante estendida do filtro para a estimativa de estado. Para validação, desenvolveu-se uma aplicação computacional em Python com interface gráfica (GUI), a qual permite monitorar os parâmetros internos do algoritmo, a Raiz do Erro Quadrático Médio (RMSE), a evolução da crença (*belief*) do sistema por meio de uma região de interesse (ROI) dinâmica, e a consistência estatística do estimador via análise do NIS (*Normalized Innovation Squared*). Os resultados das simulações avaliam as propriedades teóricas do EKF, evidenciando a estrita dependência do desempenho do filtro em relação à sintonização das matrizes de covariância do processo ( $Q$ ) e de medição ( $R$ ), além dos impactos decorrentes da discretização temporal.

**Index Terms**—Filtro de Kalman Estendido, Localização em Tempo Real, Robótica Móvel, Consistência Estatística.

## I. INTRODUÇÃO

A O passo que os sistemas robóticos autônomos assumem tarefas mais complexas, cresce também a exigência por soluções de navegação precisas e confiáveis. Para mitigar as incertezas inerentes a esse processo, a literatura tem apostado fortemente em arquiteturas de fusão sensorial — que combinam dados de múltiplos sensores — associadas a análises estatísticas das medições. Essa integração tem se mostrado essencial para refinar a estimativa de estado do sistema e viabilizar sua aplicação no mundo real [1], [2].

O grande desafio no desenvolvimento dessas soluções de localização está nos erros instrumentais e nos ruídos estocásticos que afetam a dinâmica do robô. Mesmo sob uma modelagem cinemática detalhada, perturbações ambientais e não-linearidades — presentes tanto na resposta física dos sensores quanto na própria dinâmica veicular — acabam inserindo margens inevitáveis de imprecisão no estado estimado.

Para contornar essa limitação e obter estimativas de alta fidelidade, utiliza-se o Filtro de Kalman (KF), um estimador ótimo iterativo para sistemas lineares sob o critério do erro quadrático mínimo [3]. Como parte da família dos filtros bayesianos, o KF estima variáveis de estado não mensuradas

diretamente, o que viabiliza sua aplicação em cenários de observabilidade incompleta [4]. Essa formulação clássica, no entanto, é limitada em sistemas de posicionamento baseados em distância (alcance), cujas equações de observação são essencialmente não-lineares. Nesses cenários, aplica-se o Filtro de Kalman Estendido (EKF), que contorna a não linearidade por meio da linearização do modelo em torno da estimativa corrente [4], [5].

Embora o EKF possua uma fundamentação teórica consolidada, seu sucesso prático depende diretamente do ajuste das matrizes de covariância do processo ( $Q$ ) e de medição ( $R$ ). A sintonia desses parâmetros requer simulações computacionais detalhadas, etapa essencial no desenvolvimento de sistemas de navegação. Um exemplo dessa abordagem é o trabalho de Falek e Kaniewski [6], que propuseram um ambiente em MATLAB para avaliar o comportamento do EKF em redes de posicionamento baseadas em estações fixas.

Nesse contexto, este trabalho apresenta uma aplicação computacional em Python projetada para simular e analisar o rastreamento bidimensional de um robô a partir de quatro estações base. A ferramenta proposta integra uma interface gráfica (GUI) interativa que, além de computar os erros de estimativa e a Raiz do Erro Quadrático Médio (RMSE), permite validar a consistência estatística do filtro por meio do teste do *Normalized Innovation Squared* (NIS) e monitorar o comportamento da crença (*belief*) em regiões de interesse (ROI) dinâmicas. Desse modo, o trabalho contribui com um ferramental visual e estatístico voltado a sistematizar a parametrização e a validação do EKF.

### A. Notação e Convenções

Neste trabalho, adota-se a seguinte convenção de notação: escalares são representados por letras minúsculas em itálico ( $a$ ), vetores por minúsculas em negrito ( $\mathbf{a}$  ou  $\hat{\mathbf{x}}$ ) e matrizes por maiúsculas em negrito ( $\mathbf{A}$  ou  $\mathbf{P}$ ).

No domínio discreto, o subscrito  $k$  denota a variável física real no instante de tempo atual (como o estado  $\mathbf{x}_k$  ou a medição  $\mathbf{z}_k$ ). Por outro lado, os estados e as covariâncias calculados pelo estimador utilizam uma notação composta:

- $k|k-1$ : indica os valores *a priori* (etapa de predição), computados a partir do histórico do sistema até o instante  $k-1$ , tais como o estado predito  $\hat{\mathbf{x}}_{k|k-1}$  e a covariância do erro  $\mathbf{P}_{k|k-1}$ .
- $k|k$ : representa os valores *a posteriori* (etapa de correção), atualizados após a incorporação da nova

medição, tais como o estado corrigido  $\hat{\mathbf{x}}_{k|k}$  e a covariância do erro  $\mathbf{P}_{k|k}$ .

## II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta a base teórica para o problema de estimativa de estados em robótica. O texto parte da modelagem determinística ideal e avança para os filtros probabilísticos usados na mitigação de incertezas em sistemas reais. Inicialmente, são apresentados os conceitos de sistemas dinâmicos e as fontes de ruído que afetam o comportamento do robô. Em seguida, introduz-se a definição de crença (*belief*) sob a suposição de Markov, o que fundamenta a relação geométrica entre a matriz de covariância e a região de incerteza do agente. Por fim, são discutidos o modelo Gauss-Markov, a discretização temporal, as formulações do Filtro de Kalman (Linear e Estendido) e as métricas para validação do estimador.

### A. Sistemas Dinâmicos e Modelagem Determinística

A modelagem de robôs móveis para navegação e controle costuma utilizar a representação em espaço de estados. No domínio do tempo contínuo, a evolução do vetor de estados ocultos  $\mathbf{x}(t) \in \mathbb{R}^n$  e as medições ideais do sistema são descritas por equações diferenciais e algébricas [7], na forma:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{h}(\mathbf{x}(t)) \quad (1)$$

onde  $\mathbf{u}(t) \in \mathbb{R}^m$  é o vetor de entradas de controle e  $\mathbf{z}(t) \in \mathbb{R}^d$  é o vetor de medições. Se as funções  $\mathbf{f}$  e  $\mathbf{h}$  forem lineares, o sistema pode ser escrito em sua forma canônica:

$$\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{H}_c \mathbf{x}(t) \quad (2)$$

As matrizes  $\mathbf{A}_c$ ,  $\mathbf{B}_c$  e  $\mathbf{H}_c$  definem a dinâmica, a entrada e a observação contínuas [7]. Essa abordagem determinística assume sensores perfeitos e um modelo físico exato, desconsiderando os ruídos e distúrbios comuns em ambientes reais.

### B. Sistemas Estocásticos e Fontes de Incerteza

Na prática, os sistemas robóticos sofrem perturbações que inviabilizam o uso de modelos puramente determinísticos. Essas incertezas vêm de duas fontes principais [2]:

- 1) **Ruído de Processo ( $\epsilon$ ):** Representa distúrbios dinâmicos, forças ambientais (como atrito variante, irregularidades no solo e correntes de ar) e erros de modelagem que afetam a locomoção do robô.
- 2) **Ruído de Medição ( $\delta$ ):** Agrupa as incertezas dos próprios sensores. Em sistemas de localização por radiofrequência ou acústicos, decorre de efeitos de multicaminho, ruído térmico nos circuitos, atenuação de sinal e falhas de calibração [8].

Com a inclusão desses ruídos, o estado deixa de ser um ponto exato e passa a ser tratado como uma variável aleatória. A evolução temporal do sistema e as leituras dos sensores passam a ser modeladas por densidades de probabilidade condicionais:

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (3)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (4)$$

onde  $k \in \mathbb{N}$  indica o passo de tempo discreto. O tratamento matemático dessas incertezas garante que os estimadores operem de forma estável mesmo sob condições severas [6].

### C. Robótica Probabilística, Suposição de Markov e a Crença (*Belief*)

Para lidar com as incertezas de modelos e sensores, a robótica probabilística calcula a crença (*belief*) do robô a respeito de seu próprio estado. O *belief* é a distribuição de probabilidade a posteriori do vetor de estados  $\mathbf{x}_k$ , condicionada ao histórico de comandos enviados e medições recebidas [4]:

$$\text{bel}(\mathbf{x}_k) = P(\mathbf{x}_k | \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (5)$$

Para viabilizar o cálculo dessa distribuição em tempo real, aplica-se a **Suposição de Markov**. Esse postulado assume que o estado atual  $\mathbf{x}_k$  é uma estatística suficiente do sistema, contendo toda a informação do passado. Assim, o estado futuro depende apenas do estado presente e da ação atual, o que simplifica a probabilidade condicional para:

$$P(\mathbf{x}_k | \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (6)$$

A propriedade de Markov permite dividir o cálculo do *belief* de forma recursiva em duas etapas: predição e correção, que formam a estrutura dos filtros de estimação sequenciais [4].

### D. O Modelo Gauss-Markov

O cálculo das distribuições probabilísticas torna-se tratável quando o sistema segue o Modelo Gauss-Markov. Esse modelo define um processo que obedece à propriedade de Markov e cujos ruídos de processo e medição ( $\epsilon_k$  e  $\delta_k$ ) são gaussianos, brancos e com média nula [9].

A principal vantagem dessa modelagem está na conservação das propriedades estatísticas: transformações lineares aplicadas a variáveis gaussianas geram novas variáveis gaussianas [8]. Com isso, o *belief*  $\text{bel}(\mathbf{x}_k)$  permanece estritamente gaussiano ao longo do tempo.

Como uma distribuição gaussiana é definida apenas pelo seu vetor de médias ( $\hat{\mathbf{x}}$ ) e por sua matriz de covariância ( $\mathbf{P}$ ), o problema de rastrear uma função contínua de dimensão infinita resume-se a atualizar esses dois parâmetros a cada passo de tempo discreto.

### E. Discretização do Sistema e das Covariâncias

Embora os modelos cinemáticos baseiem-se no tempo contínuo ( $t$ ), os processadores digitais operam em intervalos discretos  $\Delta t$ . Considerando o vetor de controle  $\mathbf{u}(t)$  constante dentro de cada intervalo de amostragem, o sistema linear contínuo  $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$  é convertido para sua forma discreta equivalente sob o modelo Gauss-Markov [9]:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (7)$$

As matrizes discretas de transição de estados ( $\mathbf{A}_k$ ) e de entrada ( $\mathbf{B}_k$ ) são obtidas a partir das matrizes contínuas pelas relações:

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \left( \int_0^{\Delta t} e^{\mathbf{A}_c \tau} d\tau \right) \mathbf{B}_c \quad (8)$$

*Discretização das Covariâncias de Ruído:* A amostragem digital também exige a discretização das matrizes de covariância dos ruídos [9]. A matriz de covariância do ruído de processo contínuo,  $\mathbf{Q}_c$ , propaga-se de acordo com a própria dinâmica do sistema. A matriz discreta equivalente,  $\mathbf{Q}_k$ , é calculada pela integral:

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (9)$$

Para taxas de amostragem altas ( $\Delta t \ll 1$ ), pode-se aproximar essa relação por  $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$ , assumindo um crescimento linear da incerteza [9]. No entanto, em modelos cinemáticos de ordem superior — como o espaço de estados Posição-Velocidade-Aceleração (PVA) deste trabalho —, a resolução analítica da Equação (9) é necessária para manter o acoplamento cruzado das incertezas, gerando os termos polinomiais apresentados na Seção III.

*Extensão para Sistemas Não Lineares:* Se a dinâmica do sistema contínuo for não linear, utilizam-se métodos de integração numérica para a discretização. O método de Euler, por exemplo, resulta na aproximação:

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (10)$$

Para propagar a incerteza gaussiana nesses casos, o modelo aproximado deve ser linearizado localmente por meio de matrizes Jacobianas a cada passo  $k$  [4].

### F. Filtros de Estimação Baseados em Kalman

O Filtro de Kalman é a solução ótima para propagar e corrigir o *belief* gaussiano em sistemas lineares sob a suposição de Markov. O algoritmo não estima o estado como um ponto fixo, mas rastreia os parâmetros que definem sua distribuição de probabilidade.

1) *Filtro de Kalman Linear:* Com base no modelo Gauss-Markov discreto, a dinâmica e o modelo de observação incorporam os ruídos de processo ( $\epsilon_k$ ) e medição ( $\delta_k$ ):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (11)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (12)$$

onde  $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$  e  $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$ . O filtro calcula recursivamente o estado corrigido  $\hat{\mathbf{x}}_{k|k}$  (média) e sua matriz de covariância  $\mathbf{P}_{k|k}$  (incerteza). O processo é dividido em etapas de predição e correção, conforme descrito no Algoritmo 1 [4].

---

#### Algorithm 1 Filtro de Kalman Linear

---

**Require:**  $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

**Predição (Propagação do Modelo):**

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$$

$$2: \mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$$

**Correção (Atualização pela Medição):**

$$3: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$4: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

**Ensure:**  $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

---

Se houver oclusão de sinal ou indisponibilidade dos sensores, a etapa de correção (linhas 4 a 6) não é executada. Nessas situações, o filtro opera em malha aberta apenas com a predição cinemática. Como consequência, a covariância  $\mathbf{P}_{k|k-1}$  cresce a cada passo, resultando no aumento contínuo do ROI Dinâmico.

2) *Filtro de Kalman Estendido (EKF):* Quando o sistema de localização utiliza distâncias radiais em relação a estações com coordenadas conhecidas, as equações de observação tornam-se não lineares devido à geometria do problema. Nesses cenários, utiliza-se o Filtro de Kalman Estendido (EKF) [4], que aceita funções não lineares genéricas  $g$  e  $h$ :

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (13)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (14)$$

Para propagar as matrizes de incerteza, o algoritmo utiliza uma expansão em série de Taylor de primeira ordem. Essa linearização local exige o cálculo das matrizes Jacobianas  $\mathbf{G}_k$  e  $\mathbf{H}_k$  em torno das estimativas atuais:

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \hat{\mathbf{x}}_{k-1|k-1}} \quad (15)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (16)$$

Essas matrizes Jacobianas substituem as matrizes fixas do caso linear na propagação das incertezas e no cálculo do ganho de Kalman ( $\mathbf{K}_k$ ), permitindo o rastreamento em sistemas com não linearidades geométricas (Algoritmo 2).

---

#### Algorithm 2 Filtro de Kalman Estendido (EKF)

---

**Require:**  $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

**Predição (Propagação do Modelo):**

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow g(\mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$2: \mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$3: \mathbf{P}_{k|k-1} \leftarrow \mathbf{G}_k \mathbf{P}_{k-1|k-1} \mathbf{G}_k^T + \mathbf{Q}_k$$

**Correção (Atualização pela Medição):**

$$4: \mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$6: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}))$$

$$7: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

**Ensure:**  $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

---

### G. Métricas de Avaliação e Consistência Estocástica

O desempenho do estimador é avaliado por meio de métricas de precisão geométrica e testes estatísticos baseados nos resíduos da inovação [8].

1) *Root Mean Square Error (RMSE)*: A precisão geométrica espacial nas trajetórias bidimensionais é medida pela Raiz do Erro Quadrático Médio (RMSE). O RMSE calcula a distância euclidiana média entre o estado real  $\mathbf{x}_k$  e o estado corrigido  $\hat{\mathbf{x}}_{k|k}$  em um horizonte de  $N$  amostras:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (17)$$

Essa métrica também pode ser calculada de forma independente para os eixos cartesianos ( $X$  e  $Y$ ) para identificar a direção de eventuais falhas de rastreamento.

2) *Normalized Innovation Squared (NIS)*: A precisão medida pelo RMSE não garante que o estimador seja consistente do ponto de vista estatístico. Um filtro é consistente se seus erros de estimação tiverem média nula e covariância compatível com os valores teóricos calculados pelo próprio algoritmo [8]. O teste do quadrado da inovação normalizada (NIS) verifica se a incerteza estimada na matriz  $\mathbf{P}_k$  condiz com o comportamento real das medições.

A inovação  $\boldsymbol{\nu}_k \in \mathbb{R}^d$  representa a diferença entre a medição real e a predição calculada pelo filtro:

$$\boldsymbol{\nu}_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}) \quad (18)$$

A matriz de covariância teórica da inovação, obtida na etapa de correção, é dada por:

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k \quad (19)$$

O escalar NIS ( $\epsilon_k$ ) é calculado pela forma quadrática baseada na distância de Mahalanobis:

$$\epsilon_k = \boldsymbol{\nu}_k^T \mathbf{S}_k^{-1} \boldsymbol{\nu}_k \quad (20)$$

Se o modelo cinemático e as matrizes de ruído ( $\mathbf{Q}_k$  e  $\mathbf{R}_k$ ) estiverem corretos, a variável  $\epsilon_k$  segue uma distribuição Qui-Quadrado ( $\chi^2$ ) com  $n_z$  graus de liberdade, onde  $n_z$  é a dimensão do vetor de medições  $\mathbf{z}_k$  [8].

Quando o histograma empírico dos resultados se mantém dentro dos limites de aceitação da distribuição Qui-Quadrado, o filtro e o ROI Dinâmico são considerados consistentes. Desvios prolongados para fora desses limites indicam erros de parametrização, sinalizando que o filtro está subestimando ou superestimando as incertezas reais do sistema [8].

### III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Para analisar o comportamento do EKF quanto à convergência, ajuste de parâmetros e consistência estatística, este estudo delinea um cenário de rastreamento bidimensional baseado exclusivamente em dados de distância (*range-only tracking*) [8]. Essa modelagem expande o método sugerido em [6], descrevendo a movimentação do agente por meio de um modelo cinemático estruturado no espaço de estados de Posição, Velocidade e Aceleração (PVA).

### A. Descrição do Problema

O problema abordado consiste em estimar a trajetória de um robô móvel que opera em um plano bidimensional. O agente se desloca dentro de uma arena monitorada por uma infraestrutura de localização local, composta por  $M = 4$  estações fixas (âncoras) instaladas em posições conhecidas, denotadas por  $\mathbf{p}_i = [X_i, Y_i]^T$  para  $i = 1, \dots, 4$ . O arranjo completo desse ambiente operacional encontra-se esquematizado na Figura 1.

O robô não possui sensores de odometria ou de velocidade própria, dependendo exclusivamente de medições escalares de distância obtidas via radiofrequência ou ondas acústicas em relação a cada uma das estações. O objetivo do estimador é processar essas observações ruidosas e reconstruir, a cada passo temporal, a posição horizontal ( $X$ ) e vertical ( $Y$ ) do agente, estimando também suas componentes de velocidade e aceleração instantâneas.




Figura 1: Representação geométrica do sistema de posicionamento: o agente móvel no espaço bidimensional e os raios de medição (*range-only*) oriundos das quatro estações base fixas nos vértices da arena.

### B. Modelo Cinemático de Processo (Espaço de Estados PVA)

Diferentemente de abordagens simplificadas de velocidade constante, o estado do agente móvel no instante discreto  $k$  passa a ser representado por um vetor expandido de seis dimensões:  $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$ . Nessa estrutura,  $(x_k, y_k)$  correspondem às coordenadas de posição cartesiana,  $(v_{x,k}, v_{y,k})$  às componentes da velocidade linear e  $(a_{x,k}, a_{y,k})$  às acelerações instantâneas nos eixos  $X$  e  $Y$ , respectivamente.

A dinâmica temporal do sistema sob regime de aceleração constante (CA) é integrada ao longo do intervalo de amostragem  $\Delta t$ . Essa operação dá origem à matriz de transição de estados  $\mathbf{A}_k$  ( $6 \times 6$ ), especificada na Equação (21):



$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (21)$$

Fatores práticos como o escorregamento de rodas, desalinhamentos mecânicos e irregularidades do terreno introduzem erros cumulativos na navegação [4]. Na formulação PVA escolhida, esse comportamento estocástico é transposto para o modelo admitindo que as perturbações ajam de forma independente sobre os componentes de posição, velocidade e aceleração. Essas fontes de incerteza são sintetizadas pela matriz de densidade espectral de potência contínua  $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$ .

Ao calcular a discretização analítica desse termo, ponderada pela própria dinâmica veicular no intervalo  $\Delta t$ , obtém-se uma matriz de covariância discreta  $\mathbf{Q}_k$  caracterizada por ser esparsa e simétrica. O perfil estritamente diagonal de  $\mathbf{Q}_c$  garante o desacoplamento estocástico entre as dinâmicas dos eixos horizontal ( $X$ ) e vertical ( $Y$ ). Os elementos não nulos associados aos estados do eixo  $X$  (índices 0, 2 e 4) são calculados conforme as relações dispostas na Equação (22):

$$\begin{cases} Q_{0,0} = q_1 \Delta t + q_3 \frac{\Delta t^3}{3} + q_5 \frac{\Delta t^5}{20} \\ Q_{0,2} = Q_{2,0} = q_3 \frac{\Delta t^2}{2} + q_5 \frac{\Delta t^4}{8} \\ Q_{0,4} = Q_{4,0} = q_5 \frac{\Delta t^3}{6} \\ Q_{2,2} = q_3 \Delta t + q_5 \frac{\Delta t^3}{3} \\ Q_{2,4} = Q_{4,2} = q_5 \frac{\Delta t^2}{2} \\ Q_{4,4} = q_5 \Delta t \end{cases} \quad (22)$$

De maneira análoga, os componentes vinculados ao eixo  $Y$  (índices 1, 3 e 5) replicam essa mesma estrutura algébrica, utilizando as variâncias espectrais específicas  $\{q_2, q_4, q_6\}$  detalhadas na Equação (23):

$$\begin{cases} Q_{1,1} = q_2 \Delta t + q_4 \frac{\Delta t^3}{3} + q_6 \frac{\Delta t^5}{20} \\ Q_{1,3} = Q_{3,1} = q_4 \frac{\Delta t^2}{2} + q_6 \frac{\Delta t^4}{8} \\ Q_{1,5} = Q_{5,1} = q_6 \frac{\Delta t^3}{6} \\ Q_{3,3} = q_4 \Delta t + q_6 \frac{\Delta t^3}{3} \\ Q_{3,5} = Q_{5,3} = q_6 \frac{\Delta t^2}{2} \\ Q_{5,5} = q_6 \Delta t \end{cases} \quad (23)$$

### C. Modelo de Observação e Geometria das Estações Base

A partir do arranjo de infraestrutura detalhado na Seção III-A, o vetor de observações obtido a cada passo amostral é estruturado como  $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$ . A relação geométrica entre o estado cinemático estimado do robô e a distância escalar real até a  $i$ -ésima estação fixa é governada por uma função de observação não linear  $h_i(\mathbf{x}_k)$ , descrita na Equação (24):

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (24)$$

Como o vetor de estado possui seis dimensões e as leituras dependem estritamente das coordenadas de posição  $(x_k, y_k)$ ,

as derivadas parciais da função de medição associadas aos componentes de velocidade e aceleração anulam-se por completo [8]. Sob essas condições, a matriz Jacobiana  $\mathbf{H}_k$  ( $4 \times 6$ ) avaliada a cada iteração assume o formato estabelecido na Equação (25):

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_k | k-1} \quad (25)$$

Para concluir a modelagem matemática do sensor, a matriz de covariância do ruído de medição é definida como  $\mathbf{R}_k = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$ , em que cada termo diagonal reflete a variância do erro instrumental intrínseco de sua respectiva âncora de leitura.

### D. Cenário de Desafio: Modelagem de Oclusão Temporal

Para avaliar os limites do estimador e a utilidade prática da região de interesse (ROI) dinâmica e do teste NIS, projetou-se uma janela de oclusão severa no ambiente de simulação. Dentro de um intervalo cronometrado  $t \in [t_{\text{start}}, t_{\text{end}}]$ , as leituras vindas das quatro estações base são intencionalmente suprimidas ( $\mathbf{z}_{i,k} \rightarrow \emptyset$ ).


Esse bloqueio — cujo comportamento é ilustrado na Figura 2 — força o algoritmo a depender apenas das projeções geradas pela matriz de transição PVA (21). Sob condições normais de operação com o filtro atualizando as medições, a elipse mantém-se estável e restrita (Figura 2a). Contudo, sem o suporte das correções trazidas pelos sensores durante a oclusão, as incertezas de aceleração modeladas em  $\mathbf{Q}_k$  acumulam-se rapidamente. O resultado direto é uma expansão geométrica acentuada na matriz de covariância predita ( $\mathbf{P}_{k|k-1}$ ), que se traduz no alargamento progressivo da elipse de confiança (ROI) ao longo do deslocamento do robô, variando conforme a trajetória realizada (Figuras 2b e 2c).

## IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo detalha a metodologia utilizada para avaliar o desempenho, a sensibilidade e a robustez à oclusão do estimador proposto. A apresentação segue a ordem lógica dos experimentos: inicialmente, descreve-se a geração cinemática das trajetórias de referência. Em seguida, detalham-se os cenários de teste e a modelagem do filtro. Por fim, definem-se as métricas estatísticas aplicadas na avaliação do Filtro de Kalman Estendido (EKF) sob diferentes parametrizações.

### A. Síntese Cinemática das Trajetórias de Referência

Para que a precisão do Filtro de Kalman Estendido (EKF) possa ser avaliada, é indispensável compará-lo a um referencial absoluto e livre de ruídos, o *Ground Truth*. Nessa etapa, o simulador atua como um gerador de gabaritos: ele calcula a física exata do alvo para cada instante discreto  $k$  e armazena essas informações no vetor de estado  $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$ , que engloba as posições, velocidades e acelerações reais nos eixos ortogonais.



(a) Operação nominal: predição e atualização. (b) Oclusão: trajetória 1 (predição pura). (c) Oclusão: trajetória 2 (predição pura).

Figura 2: Representação visual da incerteza do EKF (ROI dinâmica): a elipse em cinza denota a incerteza predita ( $\mathbf{P}_{k|k-1}$ ), enquanto a elipse em verde representa a incerteza atualizada após a correção ( $\mathbf{P}_{k|k}$ ). (a) Regime de operação estável sob observações contínuas; (b) e (c) expansão da incerteza e degradação da precisão decorrentes da supressão das medições (occlusão temporal) em distintos perfis de trajetória.

Como um alvo em uma aplicação real pode apresentar desde um trajeto altamente previsível até manobras bruscas, o simulador foi projetado para testar os limites do estimador utilizando duas abordagens distintas de movimento:

- **Curvas paramétricas analíticas (Determinísticas):** Simulam cenários onde o alvo obedece a regras geométricas bem definidas e contínuas. Servem para testar o filtro sob dinâmicas estáveis e previsíveis.
- **Modelos numéricos comportamentais (Estocásticos):** Inserem aleatoriedade na navegação do alvo. Servem para testar a capacidade de adaptação do EKF quando o objeto realiza trajetórias erráticas ou mudanças repentinas de direção.

O conjunto completo dessas trajetórias, abrangendo todos os perfis cinemáticos abordados nos testes, pode ser visualizado na Figura 3.

1) *Geração de Curvas Paramétricas e Analíticas:* Para os testes com movimentos contínuos e regulares, as posições do alvo no simulador são ditadas por funções trigonométricas e hiperbólicas dependentes do tempo. Um cuidado fundamental nessa etapa foi evitar o cálculo numérico das derivadas. Para garantir que o *Ground Truth* seja matematicamente perfeito e livre de erros de discretização, a velocidade e a aceleração do alvo são extraídas a partir da diferenciação analítica exata das equações de posição, conforme detalha o Algoritmo 3.

As trajetórias com quinas, como o percurso quadrado, obedecem a esse mesmo rigor determinístico. A única diferença é que a modelagem utiliza segmentos de reta conectados para formar as arestas, aplicando-se uma restrição geométrica de fechamento para garantir que o alvo retorne exatamente à coordenada onde iniciou o percurso.

2) *Geração de Navegação Aleatória e Oclusões:* Para aproximar a simulação do comportamento estocástico de um alvo real, desenvolveu-se um algoritmo de navegação aleatória. O agente (UGV - Unmanned Ground Vehicle) move-se em linha reta por distâncias mínimas antes de realizar deflexões suaves. Se o robô atinge os limites da arena (raio superior a 35 metros), um mecanismo de evasão direciona o movimento de volta ao centro, mantendo o robô na área útil.

### Algorithm 3 Geração de Trajetórias Paramétricas Analíticas

**Require:** Tempo contínuo  $t_k = k\Delta t$ , Parâmetros geométricos (Amplitude  $A$ , Frequência  $\omega$ )

```

1: for cada instante  $k$  do
2:   if Perfil = Circular then
3:      $\mathbf{p}_k \leftarrow [c_x + R \cos(\omega t_k), c_y + R \sin(\omega t_k)]^T$ 
4:   else if Perfil = Mudança de Faixa (Tanh) then
5:      $\mathbf{p}_k \leftarrow [v_x t_k, c_y + A \tanh(S \cdot t_k)]^T$ 
6:   else if Perfil = Lemniscata then
7:      $\mathbf{p}_k \leftarrow [c_x + A \sin(\omega t_k), c_y + \frac{A}{2} \sin(2\omega t_k)]^T$ 
8:   end if
9:    $\mathbf{v}_k \leftarrow \frac{d}{dt} \mathbf{p}_k$ 
10:   $\mathbf{a}_k \leftarrow \frac{d}{dt} \mathbf{v}_k$ 
11:   $\mathbf{x}_k \leftarrow [\mathbf{p}_k^T, \mathbf{v}_k^T, \mathbf{a}_k^T]^T$ 
12: end for

```

**Ensure:** Sequência de estados reais  $\mathbf{x}_{1:N}$

Como as mudanças de direção são aleatórias, a aceleração de referência é calculada por diferenciação numérica discreta, conforme estruturado no Algoritmo 4.

### B. Cenários de Simulação e Estratégia de Sintonia

Para avaliar o estimador na prática, a campanha de testes foi dividida em **6 cenários cinemáticos** (ilustrados na Figura 3), abrangendo diferentes perfis de aceleração e condições de oclusão. Além do movimento do alvo, o comportamento do EKF depende diretamente das suas matrizes de covariância ( $\mathbf{Q}_k$  para o processo e  $\mathbf{R}_k$  para a medição). Para testar a sensibilidade do algoritmo a esses parâmetros, cada cenário foi simulado sob **duas condições distintas**:

- 1) **Situação Sintonizada (Filtro Calibrado):** Representa a condição de funcionamento ideal do rastreador. Os valores das matrizes foram ajustados de forma empírica (por tentativa e erro), avaliando o comportamento do filtro até que ele apresentasse um desempenho considerado "bom". O critério de sucesso foi a minimização do erro de posição aliada a elipses de confiança visualmente e estatisticamente coerentes com a trajetória.




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos.

#### Algorithm 4 Geração de Navegação Dinâmica Aleatória

**Require:** Vetor posição central  $\mathbf{p}_c$ , Limite da arena  $R_{\max}$ , Ruído cinemático  $w$

```

1: for cada instante  $k$  do
2:   if Distância percorrida  $> D_{\min}$  then
3:     if  $\|\mathbf{p}_{k-1} - \mathbf{p}_c\| > R_{\max}$  then
4:        $\theta_{\text{alvo}} \leftarrow$  Ângulo forçado em direção a  $\mathbf{p}_c$ 
5:     else
6:        $\theta_{\text{alvo}} \leftarrow \theta_{k-1} + \mathcal{U}(-\frac{\pi}{3}, \frac{\pi}{3})$ 
7:     end if
8:      $v_{\text{alvo}} \leftarrow v_{\text{base}} + \mathcal{U}(-w, w)$ 
9:   end if
10:   $\theta_k \leftarrow \text{SuavizarTransição}(\theta_{k-1}, \theta_{\text{alvo}})$ 
11:   $v_k \leftarrow \text{SuavizarTransição}(v_{k-1}, v_{\text{alvo}})$ 
12:   $\mathbf{v}_k \leftarrow [v_k \cos(\theta_k), v_k \sin(\theta_k)]^T$ 
13:   $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$ 
14:   $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$ 
15: end for

Configuração Especial para Oclusão Cíclica:
16: if Modo Oclusão then
17:   Emite uma máscara binária atribuindo valor Falso
   (Oculito) no segmento temporal central de 4 blocos.
18: end if

```

2) **Situação Não Sintonizada (Filtro Descalibrado):** Representa falhas severas na configuração do projeto. Nessa etapa, os valores das matrizes foram intencionalmente sabotados, sendo superestimados ou subestimados. O objetivo de impor essas condições anormais é

demonstrar como o filtro se comporta mal quando está mal configurado e comprovar a importância de uma boa sintonia.

A Tabela I consolida todas as variáveis utilizadas nos testes: a configuração de movimento do alvo, o nível de ruído físico ( $\sigma$ ) simulado nos sensores e os valores numéricos utilizados para sintonizar (ou descalibrar) o EKF em cada um dos seis cenários.

#### C. Configuração do Estimador e Modelagem do Ruído

O objetivo do filtro é estimar o estado completo do alvo (o vetor PVA  $\mathbf{x}_k$ , detalhado na Seção III). Para alimentar o algoritmo, o sistema mede a distância do robô até quatro estações rádio-base fixadas nos cantos da arena.

Como nenhum sensor no mundo real é perfeito, o simulador precisa "sujar" as medidas ideais do *Ground Truth*. Para imitar a imprecisão real, o sistema injeta um erro aleatório em cada canal: soma-se à distância exata um ruído gaussiano branco de média zero e desvio padrão  $\sigma$  (valores indicados na Tabela I).

Isso resulta no vetor de observação  $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$ , que contém as quatro distâncias ruidosas que o EKF efetivamente recebe como entrada, conforme a Equação (26):

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (26)$$

É importante destacar que o EKF trabalha diretamente com essas distâncias puras na sua forma não-linear ( $\mathbf{z}_k$ ). No entanto, para que possamos desenhar a posição lida pelos

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

| Parâmetro                                                      | Cenário 1              | Cenário 2            | Cenário 3              | Cenário 4              | Cenário 5                      | Cenário 6             |
|----------------------------------------------------------------|------------------------|----------------------|------------------------|------------------------|--------------------------------|-----------------------|
| <b>Perfil</b>                                                  | Circular               | Quadrada             | Tanh                   | Lemniscata             | Nav. Aleatória                 | Oclusão Cíclica       |
| <b>Movimento</b>                                               | $v = 10,0 \text{ m/s}$ | $v = 10 \text{ m/s}$ | $A_y = 20,0 \text{ m}$ | $v = 10,0 \text{ m/s}$ | $v_0 = 8,0 \text{ m/s}$        | $v = 5,0 \text{ m/s}$ |
|                                                                | $r = 30,0 \text{ m}$   | $L = 40,0 \text{ m}$ | $v = 10,0 \text{ m/s}$ | $A = 35,0 \text{ m}$   | $\epsilon_v = 0,5 \text{ m/s}$ | 30 fr/occlusão        |
| <b>Variáveis do Ambiente Simulado (Adição de Ruído Físico)</b> |                        |                      |                        |                        |                                |                       |
| <b>Tempo de Simulação</b>                                      | 40 s                   |                      |                        |                        |                                |                       |
| <b>Taxa de Quadros (FPS)</b>                                   | 30                     |                      |                        |                        |                                |                       |
| <b>Semente Aleatória (Seed)</b>                                | 42                     |                      |                        |                        |                                |                       |
| <b>Ruído nas Torres (<math>\sigma</math>)</b>                  | 0,30 m                 | 0,40 m               | 0,40 m                 | 0,40 m                 | 0,40 m                         | 0,40 m                |
| <b>Sintonia do EKF: Condição Sintonizada</b>                   |                        |                      |                        |                        |                                |                       |
| <b>Matriz Medição <math>R_{4 \times 4}</math></b>              | $0,9I_4$               | $0,9I_4$             | $0,9I_4$               | $0,9I_4$               | $0,9I_4$                       | $0,9I_4$              |
| <b>Matriz Processo <math>Q_{6 \times 6}</math></b>             | $1I_6$                 | $1I_6$               | $1I_6$                 | $1I_6$                 | $1I_6$                         | $1I_6$                |
| <b>Sintonia do EKF: Condição Não Sintonizada</b>               |                        |                      |                        |                        |                                |                       |
| <b>Matriz Medição <math>R_{4 \times 4}</math></b>              | $0,1I_4$               | $0,1I_4$             | $0,01I_4$              | $0,01I_4$              | $0,01I_4$                      | $0,01I_4$             |
| <b>Matriz Processo <math>Q_{6 \times 6}</math></b>             | $0,01I_6$<br>(Sub.)    | $0,01I_6$<br>(Sub.)  | $0,5I_6$<br>(Sub.)     | $0,3I_6$<br>(Sub.)     | $0,5I_6$<br>(Sub.)             | $0,05I_6$<br>(Sub.)   |

Nota:  $I_n$  representa a matriz identidade de dimensão  $n \times n$ , denotando configurações diagonais. A matriz  $R$  apresenta um superdimensionamento conservador intencional ( $0,9I_4$ ), não refletindo estritamente a variância do ruído injetado ( $\sigma^2$ ). No Cenário 4 (Não Sintonizado),  $R$  foi propositalmente mantido inalterado para isolar e avaliar exclusivamente o efeito da subestimação de  $Q$ . (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.

sensores na interface gráfica do simulador, o sistema realiza um cálculo paralelo. Ele pega essas quatro distâncias com ruído e aplica um algoritmo numérico de multilateração por Mínimos Quadrados para estimar uma coordenada cartesiana  $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$ . Essa coordenada 2D serve estritamente como apoio visual para a tela e para a validação externa, não interferindo nas contas do Filtro de Kalman.

#### D. Ambiente Computacional e Infraestrutura de Simulação

Figura 4: Diagrama da arquitetura de software da aplicação de simulação.

Para automatizar a execução dos cenários e garantir a reprodutibilidade dos dados, o simulador foi desenvolvido em *Python* (versão 3.10) utilizando uma arquitetura modular, conforme ilustrado na Figura 4. O processamento matricial e a computação vetorizada do EKF foram implementados com a biblioteca *NumPy*.

Para facilitar a sintonia das matrizes  $Q_k$  e  $R_k$ , integrou-se uma interface gráfica (GUI) em *PyQt*. A plataforma permite ajustar parâmetros em tempo real via *sliders* e renderiza

instantaneamente a trajetória estimada, o vetor de observações e a elipse de covariância da região de interesse (ROI).

A interface gráfica serve apenas para inspeção visual e validação qualitativa. O núcleo numérico do simulador opera de forma independente, permitindo que as campanhas de teste e a exportação dos dados brutos ocorram de forma automatizada (ver Figura 8).

#### E. Métodos de Avaliação e Consistência

O desempenho do EKF é avaliado por meio da precisão espacial e da consistência estatística do estimador. A acurácia é quantificada comparando as estimativas *a posteriori* ( $\hat{x}_{k|k}, \hat{y}_{k|k}$ ) com o *Ground Truth* através da Raiz do Erro Quadrático Médio (RMSE). Conforme o caso geral definido teoricamente na revisão da literatura (Seção II), o cálculo do erro é aplicado e monitorado de forma independente para os eixos operacionais  $X$  e  $Y$ . Adicionalmente, o erro médio com sinal (ME) é extraído para identificar eventuais tendências sistemáticas (viés) no rastreamento.

Além da métrica espacial, a consistência estatística é auditada. Um filtro bem sintonizado deve apresentar erros de estimativa que se comportem como ruído branco. Em condições ideais de calibração, o histograma dos erros nos eixos  $X$  e  $Y$  deve convergir para uma distribuição Normal (Gaussiana) de média zero. Complementarmente, a validade das matrizes de covariância  $Q_k$  e  $R_k$  é aferida pela métrica NIS (*Normalized Innovation Squared*). Como abordado na Seção II-G, valores de NIS conformes à distribuição  $\chi^2$  atestam que a incerteza calculada pelo filtro condiz com a inovação observada [8].

1) *Validação da Crença do Estimador (Inlier Rate)*: A convergência da crença (*belief*) é avaliada pela taxa de *inliers*. Conforme preconizado por [4], a crença *a priori*  $bel(\mathbf{x}_{k|k-1})$  é centrada na predição resultante do modelo dinâmico antes da atualização via observações. Esta métrica de diagnóstico



mede a proporção de medições de suporte ( $\mathbf{m}_k$ ) que residem dentro da região de incerteza projetada pelo estimador.

A verificação analítica baseia-se na distância de Mahalanobis associada à submatriz de covariância de posição  $\mathbf{P}_{\text{pos}} = \mathbf{P}_{k|k-1}^{(1:2,1:2)}$ . Definindo o resíduo posicional como  $\tilde{\mathbf{p}}_k = [m_{x,k} - \hat{x}_{k|k-1}, m_{y,k} - \hat{y}_{k|k-1}]^T$ , um ponto é contabilizado como *inlier* caso obedeça à Equação (27):

$$\tilde{\mathbf{p}}_k^T (\mathbf{P}_{\text{pos}})^{-1} \tilde{\mathbf{p}}_k \leq M \quad (27)$$

em que  $M$  é o limiar de aceitação extraído da distribuição  $\chi^2$  com 2 graus de liberdade.

Para visualização, a incerteza é representada por uma *bounding box* baseada no critério  $3\sigma$ , cujos desvios-padrão teóricos são calculados pelas Equações (28) e (29):

$$\sigma_{x,\text{pred}} = \sqrt{\max(10^{-6}, P_{k|k-1}^{(1,1)})} \quad (28)$$

$$\sigma_{y,\text{pred}} = \sqrt{\max(10^{-6}, P_{k|k-1}^{(2,2)})} \quad (29)$$

Os limites da janela ( $L_x, L_y$ ), definidos pelas Equações (30) e (31), garantem uma visualização estável através da constante  $\tau_{\min}$ :

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{pred}}) \quad (30)$$

$$L_y = \max(\tau_{\min}, 3\sigma_{y,\text{pred}}) \quad (31)$$

A Figura 5 ilustra a fronteira elíptica baseada na Equação (27) e a janela delimitadora dada pelas Equações (30) e (31), evidenciando a relação entre a teoria estatística e a representação geométrica.




Figura 5: Representação da métrica de *inliers*. A elipse valida estatisticamente a convergência, enquanto a janela retangular delimita a incerteza para fins de visualização.

## V. RESULTADOS E DISCUSSÃO

Este capítulo apresenta a avaliação experimental do Filtro de Kalman Estendido (EKF) nos seis cenários de navegação descritos na Seção IV. A análise baseia-se em métricas de acurácia (RMSE e Erro Máximo), consistência estatística (NIS) e validação espacial (Taxa de *Inliers*). Para analisar

a sensibilidade do filtro à parametrização estocástica, os ensaios comparam o EKF operando com matrizes devidamente sintonizadas (alta variância de processo e medição conservadora) contra uma configuração intencionalmente subestimada (Não Sintonizada, com parâmetros agressivos). A Tabela II consolida os resultados quantitativos obtidos pelo motor de simulação.

### A. Interface Gráfica e Ambiente de Simulação Funcional

A Figura 8 ilustra o ambiente de simulação desenvolvido em Python. A interface gráfica (GUI) consolida a renderização espacial da arena, a telemetria das posições estimadas em comparação ao *Ground Truth* e os painéis de monitoramento de RMSE e NIS em tempo real. Esta ferramenta interativa permite a alteração dinâmica das matrizes de covariância  $\mathbf{Q}$  e  $\mathbf{R}$ , facilitando a observação direta do impacto da sintonia na morfologia das elipses de incerteza do filtro.

### B. Análise de Acurácia Posicional, Erros e Convergência

Conforme a Tabela II e as Figuras 6 e 7, o EKF sintonizado atenuou o ruído de forma eficaz. Nos Cenários de 1 a 5, o  $\text{RMSE}_x$  manteve-se estritamente entre 0,09 m e 0,22 m, enquanto o  $\text{RMSE}_y$  variou de 0,14 m a 0,32 m, indicando precisão submétrica notavelmente estável. No Cenário 2 (Trajetória Quadrada), que exige adaptação a variações bruscas de aceleração, o Erro Máximo foi contido em 1,06 m sob sintonia adequada, ao passo que a configuração não sintonizada ultrapassou 2,27 m devido à inércia excessiva da matriz preditiva frente a descontinuidades ortogonais.

**Análise de Distribuição e Dispersão de Erros:** A evolução temporal do RMSE reforça essa resiliência da configuração calibrada. Adicionalmente, ao observarmos os histogramas de erro e os gráficos de dispersão (erros de previsão em X e Y), nota-se uma característica fundamental do filtro ótimo: na condição sintonizada, o espalhamento dos erros aproxima-se marcadamente de uma distribuição normal bidimensional em torno do zero (viés muito próximo à nulidade, como  $\mu_x \approx +0,01$  m). Já em cenários não sintonizados, a distribuição perde a gaussianidade, apresentando caudas pesadas e comportamento bimodal causado pelo atraso de fase recorrente (o filtro sistematicamente "corre atrás" do alvo em trajetórias não lineares).

### C. Consistência Estatística e Comportamento do NIS

A consistência interna foi validada por meio da estatística NIS (Figura ??). Com um vetor de observação de quatro balizas, o sistema possui 4 graus de liberdade. O limiar da distribuição  $\chi^2$  com 95% de confiança é 9,49.

Na condição sintonizada, foi atestada estabilidade absoluta: houve 0,00% de violação desse limite em **todos** os cenários. A média global do NIS variou entre 0,40 e 0,96. Este valor bastante inferior ao limite teórico evidencia um superdimensionamento conservador, estratégia adotada para controlar a distância de Mahalanobis e evitar a divergência nas não linearidades do processo.

Em contraste abissal, a configuração não sintonizada demonstrou completa divergência estatística. Em cenários mais




Figura 6: Trajetórias Sintonizadas para os seis cenários simulados. Observa-se que o filtro acompanha adequadamente a dinâmica do alvo, atenuando os ruídos de medição e convergindo rapidamente, mesmo diante de oclusões parciais (Cenário 6).

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

| Cenário                                                                                    | $RMSE_x$ [m] | $RMSE_y$ [m] | $E_{max}$ [m] | $\mu_x$ [m] | $NIS$ | $NIS > 9,49$ (%) | $TD$ (%) | $TI$ (%) |
|--------------------------------------------------------------------------------------------|--------------|--------------|---------------|-------------|-------|------------------|----------|----------|
| <b>CONDIÇÃO SINTONIZADA (<math>Q = 1.0</math>; <math>R = 0.9</math>)</b>                   |              |              |               |             |       |                  |          |          |
| Cenário 1                                                                                  | 0,09         | 0,15         | 0,57          | +0,01       | 0,40  | 0,00%            | 100,00%  | 100,00%  |
| Cenário 2                                                                                  | 0,22         | 0,32         | 1,06          | -0,01       | 0,96  | 0,00%            | 100,00%  | 95,22%   |
| Cenário 3                                                                                  | 0,11         | 0,14         | 0,61          | +0,00       | 0,66  | 0,00%            | 100,00%  | 99,50%   |
| Cenário 4                                                                                  | 0,10         | 0,15         | 0,54          | +0,01       | 0,66  | 0,00%            | 100,00%  | 99,83%   |
| Cenário 5                                                                                  | 0,14         | 0,21         | 0,71          | +0,00       | 0,75  | 0,00%            | 100,00%  | 99,25%   |
| Cenário 6                                                                                  | 0,21         | 0,38         | 2,69          | +0,02       | 0,70  | 0,00%            | 90,00%   | 99,54%   |
| <b>CONDIÇÃO NÃO SINTONIZADA (Ex. <math>Q</math> reduzido e <math>R</math> subestimado)</b> |              |              |               |             |       |                  |          |          |
| Cenário 1                                                                                  | 0,23         | 0,35         | 0,85          | +0,01       | 9,47  | 42,58%           | 100,00%  | 13,75%   |
| Cenário 2                                                                                  | 0,61         | 0,82         | 2,27          | -0,02       | 26,84 | 62,99%           | 100,00%  | 13,31%   |
| Cenário 3                                                                                  | 0,22         | 0,26         | 1,05          | +0,00       | 42,39 | 91,00%           | 100,00%  | 42,25%   |
| Cenário 4                                                                                  | 0,19         | 0,26         | 0,98          | +0,01       | 45,33 | 91,83%           | 100,00%  | 35,33%   |
| Cenário 5                                                                                  | 0,20         | 0,28         | 0,97          | +0,01       | 42,76 | 91,08%           | 100,00%  | 45,00%   |
| Cenário 6                                                                                  | 0,22         | 0,43         | 2,49          | -0,01       | 42,39 | 89,17%           | 90,00%   | 45,83%   |

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limite do NIS a 95% de confiança (4 G.L.) é  $\approx 9,49$ .

dinâmicos (como Lemniscata e Aleatória), os valores médios de NIS dispararam para acima de 42, e a taxa de falha superou os 91% de violação do limite. Isso evidencia matematicamente a ruptura da matriz de incerteza em relação à escala real dos resíduos.

#### D. Eficácia do ROI Dinâmico e Taxa de Inliers

A sintonia correta afeta diretamente o monitoramento passivo do filtro, expresso pela Taxa de Inliers (TI). Nos testes calibrados, a região de confiança estipulada pela *Region of Interest* englobou os dados brutos com excepcional precisão, mantendo uma TI entre 95,22% e 100,00%.

Porém, quando subestimado, a taxa desabou para patamares




Figura 7: Trajetórias Não Sintonizadas (Incerteza Subestimada). A configuração rígida do filtro resulta em inércia excessiva, gerando atrasos significativos nas curvas, ultrapassagens e dificuldade de adaptação à cinemática não linear do agente.

críticos (chegando a ínfimos 13,31% no Cenário Quadrado). Este declínio serve como diagnóstico explícito do EKF: a matriz projetada deixou de acompanhar a física real do agente. Combinada com o NIS baixo e os erros perfeitamente gaussianos discutidos anteriormente, a alta Taxa de Inliers atesta conclusivamente a robustez da parametrização sintonizada do modelo desenvolvido.

#### E. Estabilidade Operacional sob Oclusão (Cenário 6)

O Cenário 6 reduziu a Taxa de Detecção (TD) para 90,00%, forçando o EKF a operar pontualmente em malha aberta puramente por sua formulação cinemática Posição-Velocidade-Aceleração (PVA).

Conforme evidenciado, o EKF manteve uma retenção inercial aceitável durante as perdas de sinal. O erro máximo alcançou 2,69 m, um valor esperado e coerente com a ausência momentânea de dados corretivos. Porém, foi a parametrização correta das variáveis de transição que garantiu que a convergência fosse reconquistada sem "saltos" ou estouros matriciais assim que a conectividade com as balizas foi restaurada.

## VI. CONCLUSÃO

### A. Resumo

Este trabalho apresentou o desenvolvimento e a análise experimental de um Filtro de Kalman Estendido (EKF) para

o rastreamento bidimensional de alvos móveis, utilizando medições não lineares de distância (*range-only*). Através de um ambiente de simulação em Python, o estimador foi submetido a seis cenários cinemáticos fundamentados no modelo contínuo de Posição-Velocidade-Aceleração (PVA). O estudo quantificou o impacto direto da parametrização estocástica (matrizes  $\mathbf{Q}$  e  $\mathbf{R}$ ) sobre a acurácia posicional e a estabilidade do filtro.

### B. Principais Constatações

Os resultados comprovaram a eficácia do EKF na mitigação de ruídos de medição, mantendo erros submétricos em condições ideais de sintonia. O cenário de oclusão (Cenário 6) atestou a robustez da formulação PVA, que permitiu ao sistema reter a inércia do alvo e sustentar o rastreamento preditivo em malha aberta durante apagões temporários de sinal. Constatou-se também a extrema sensibilidade do filtro à calibração: a subestimação do ruído de processo induziu atraso de fase e divergência geométrica nas curvas, evidenciando que uma matriz  $\mathbf{Q}$  subdimensionada torna o estimador incapaz de acompanhar a dinâmica real.

### C. Contribuições

As principais contribuições empíricas e analíticas deste trabalho incluem:




Figura 8: Ambiente gráfico integrado em Python para monitoramento e validação do EKF. O painel central exibe a arena e a trajetória do alvo, o painel esquerdo são os inputs da simulação e o painel direito gráficos para monitorar a evolução temporal.

- A consolidação de uma arquitetura de simulação para monitoramento contínuo das matrizes de covariância (elipses de confiança) em tempo de execução.
- O mapeamento do *Normalized Innovation Squared* (NIS) como um validador estatístico implacável de consistência frente a erros de modelagem.
- A formulação da Taxa de *Inliers* baseada na crença *a priori* (ROI Dinâmica). Corrigindo abordagens convencionais, esta métrica foi consolidada como um diagnóstico passivo que quantifica a aderência geométrica da incerteza à realidade física, contornando a complexidade de validações no espaço dos sensores.

#### D. Limitações

A avaliação dependeu da injeção de ruído estritamente gaussiano. Em aplicações de rádio-localização reais, o ruído apresenta componentes não gaussianos e vieses severos provocados por caminhos múltiplos (*multipath*). Além disso, o cômputo da métrica geométrica requer a posição pré-calculada por Mínimos Quadrados; logo, em oclusões profundas com menos de três estações visíveis, o diagnóstico espacial direto fica temporariamente indisponível. Por fim, a calibração heurística das matrizes atendeu aos propósitos de análise, mas não garante matematicamente o encontro do ótimo global.

#### E. Trabalhos Futuros

Para suprir as limitações identificadas e avançar na robustez do sistema, sugerem-se como extensões diretas:

- **Validação Experimental:** Substituir os dados simulados por medições físicas em ambiente *indoor*, utilizando

redes de sensores *Ultra-Wideband* (UWB) para avaliar o comportamento do filtro sob ruídos reais de reflexão.

- **Filtros Livres de Derivadas:** Comparar a eficiência computacional e a acurácia do EKF com técnicas que dispensam o cálculo de matrizes Jacobianas, como o Filtro de Kalman *Unscented* (UKF).
- **Sintonia Adaptativa:** Implementar métodos de ajuste dinâmico para as matrizes de ruído, permitindo que o sistema atualize as variâncias em tempo de execução conforme a degradação do sinal.

#### F. Conclusão Final

O estudo demonstra que a eficácia da filtragem não linear depende substancialmente do rigor na modelagem estocástica. A associação de métricas estatísticas (NIS) a validadores geométricos de crença estabeleceu um arcabouço rigoroso para auditar o estimador. Conclui-se que monitorar a confiabilidade da matriz de covariância é tão essencial quanto o cálculo da própria posição, sendo este o principal requisito para o emprego seguro de estimadores em sistemas de navegação autônoma.

#### APÊNDICE A

##### MATERIAL SUPLEMENTAR E FERRAMENTA DE SIMULAÇÃO

Para fins de reprodutibilidade e transparência da pesquisa, o código-fonte integral da ferramenta desenvolvida está disponível em um repositório público. O material suplementar inclui a implementação da Interface Gráfica (GUI) em Python, os algoritmos do Filtro de Kalman Estendido (EKF) e os *scripts* de geração dos ambientes virtuais.

Além do código, o repositório hospeda o conjunto completo de resultados gráficos exaustivos (todas as configurações de parâmetros e trajetórias simuladas) que, por restrições de espaço, não foram integralmente apresentados no escopo deste artigo.

O acesso à ferramenta e aos dados suplementares pode ser realizado por meio do seguinte endereço eletrônico:

<https://github.com/SauloJose/PASKalmanTra>

Os leitores são encorajados a acessar o repositório [10] para executar as simulações localmente, inspecionar a sintonia fina das matrizes de covariância  $Q$  e  $R$ , e visualizar de forma interativa a dinâmica da Região de Interesse (ROI) e as elipses de incerteza do agente móvel.

#### REFERÊNCIAS

- [1] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [6] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [7] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [8] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [9] D. Simon, *Optimal State Estimation: Kalman,  $H_\infty$ , and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.