

Rastreamento Bidimensional de Alvos via Filtro de Kalman Estendido em Sistemas de Posicionamento por Estações Base

Saulo José Almeida Silva, *Mestrando, UFCG,*

Resumo—A localização precisa é um requisito fundamental para a operação autônoma de sistemas robóticos móveis, viabilizando a execução de tarefas críticas como navegação, mapeamento e coordenação. Este trabalho apresenta o desenvolvimento, a implementação e a análise das propriedades do Filtro de Kalman Estendido (EKF) aplicado à localização em tempo real de agentes móveis. O sistema sob análise é caracterizado por um modelo dinâmico linear e um modelo de observação não-linear, o que justifica o emprego da variante estendida do filtro para a estimativa de estado. Para validação, desenvolveu-se uma aplicação computacional em Python com interface gráfica (GUI), a qual permite monitorar os parâmetros internos do algoritmo, a Raiz do Erro Quadrático Médio (RMSE), a evolução da crença (*belief*) do sistema por meio de uma região de interesse (ROI) dinâmica, e a consistência estatística do estimador via análise do NIS (*Normalized Innovation Squared*). Os resultados das simulações avaliam as propriedades teóricas do EKF, evidenciando a estrita dependência do desempenho do filtro em relação à sintonização das matrizes de covariância do processo (Q) e de medição (R), além dos impactos decorrentes da discretização temporal.

Index Terms—Filtro de Kalman Estendido, Localização em Tempo Real, Robótica Móvel, Consistência Estatística.

I. INTRODUÇÃO

A O passo que os sistemas robóticos autônomos assumem tarefas mais complexas, cresce também a exigência por soluções de navegação precisas e confiáveis. Para mitigar as incertezas inerentes a esse processo, a literatura tem apostado fortemente em arquiteturas de fusão sensorial — que combinam dados de múltiplos sensores — associadas a análises estatísticas das medições. Essa integração tem se mostrado essencial para refinar a estimativa de estado do sistema e viabilizar sua aplicação no mundo real [1], [2].

O grande desafio no desenvolvimento dessas soluções de localização está nos erros instrumentais e nos ruídos estocásticos que afetam a dinâmica do robô. Mesmo sob uma modelagem cinemática detalhada, perturbações ambientais e não-linearidades — presentes tanto na resposta física dos sensores quanto na própria dinâmica veicular — acabam inserindo margens inevitáveis de imprecisão no estado estimado.

Para contornar essa limitação e obter estimativas de alta fidelidade, utiliza-se o Filtro de Kalman (KF), um estimador ótimo iterativo para sistemas lineares sob o critério do erro quadrático mínimo [3]. Como parte da família dos filtros bayesianos, o KF estima variáveis de estado não mensuradas

diretamente, o que viabiliza sua aplicação em cenários de observabilidade incompleta [4]. Essa formulação clássica, no entanto, é limitada em sistemas de posicionamento baseados em distância (alcance), cujas equações de observação são essencialmente não-lineares. Nesses cenários, aplica-se o Filtro de Kalman Estendido (EKF), que contorna a não linearidade por meio da linearização do modelo em torno da estimativa corrente [4], [5].

Embora o EKF possua uma fundamentação teórica consolidada, seu sucesso prático depende diretamente do ajuste das matrizes de covariância do processo (Q) e de medição (R). A sintonia desses parâmetros requer simulações computacionais detalhadas, etapa essencial no desenvolvimento de sistemas de navegação. Um exemplo dessa abordagem é o trabalho de Falek e Kaniewski [6], que propuseram um ambiente em MATLAB para avaliar o comportamento do EKF em redes de posicionamento baseadas em estações fixas.

Nesse contexto, este trabalho apresenta uma aplicação computacional em Python projetada para simular e analisar o rastreamento bidimensional de um robô a partir de quatro estações base. A ferramenta proposta integra uma interface gráfica (GUI) interativa que, além de computar os erros de estimativa e a Raiz do Erro Quadrático Médio (RMSE), permite validar a consistência estatística do filtro por meio do teste do *Normalized Innovation Squared* (NIS) e monitorar o comportamento da crença (*belief*) em regiões de interesse (ROI) dinâmicas. Desse modo, o trabalho contribui com um ferramental visual e estatístico voltado a sistematizar a parametrização e a validação do EKF.”

A. Notação e Convenções

Neste trabalho, adota-se a seguinte convenção de notação: escalares são representados por letras minúsculas em itálico (a), vetores por minúsculas em negrito ($\mathbf{a}$ ou $\hat{\mathbf{x}}$) e matrizes por maiúsculas em negrito ($\mathbf{A}$ ou $\mathbf{P}$).

No domínio discreto, o subscrito k denota a variável física real no instante de tempo atual (como o estado $\mathbf{x}_k$ ou a medição $\mathbf{z}_k$). Por outro lado, os estados e as covariâncias calculados pelo estimador utilizam uma notação composta:

- $k|k-1$: indica os valores *a priori* (etapa de predição), computados a partir do histórico do sistema até o instante $k-1$, tais como o estado predito $\hat{\mathbf{x}}_{k|k-1}$ e a covariância do erro $\mathbf{P}_{k|k-1}$.
- $k|k$: representa os valores *a posteriori* (etapa de correção), atualizados após a incorporação da nova

medição, tais como o estado corrigido $\hat{\mathbf{x}}_{k|k}$ e a covariância do erro $\mathbf{P}_{k|k}$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta a base teórica para o problema de estimativa de estados em robótica. O texto parte da modelagem determinística ideal e avança para os filtros probabilísticos usados na mitigação de incertezas em sistemas reais. Inicialmente, são apresentados os conceitos de sistemas dinâmicos e as fontes de ruído que afetam o comportamento do robô. Em seguida, introduz-se a definição de crença (*belief*) sob a suposição de Markov, o que fundamenta a relação geométrica entre a matriz de covariância e a região de incerteza do agente. Por fim, são discutidos o modelo Gauss-Markov, a discretização temporal, as formulações do Filtro de Kalman (Linear e Estendido) e as métricas para validação do estimador.

A. Sistemas Dinâmicos e Modelagem Determinística

A modelagem de robôs móveis para navegação e controle costuma utilizar a representação em espaço de estados. No domínio do tempo contínuo, a evolução do vetor de estados ocultos $\mathbf{x}(t) \in \mathbb{R}^n$ e as medições ideais do sistema são descritas por equações diferenciais e algébricas [7], na forma:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{h}(\mathbf{x}(t)) \quad (1)$$

onde $\mathbf{u}(t) \in \mathbb{R}^m$ é o vetor de entradas de controle e $\mathbf{z}(t) \in \mathbb{R}^d$ é o vetor de medições. Se as funções $\mathbf{f}$ e $\mathbf{h}$ forem lineares, o sistema pode ser escrito em sua forma canônica:

$$\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{H}_c \mathbf{x}(t) \quad (2)$$

As matrizes $\mathbf{A}_c$, $\mathbf{B}_c$ e $\mathbf{H}_c$ definem a dinâmica, a entrada e a observação contínuas [7]. Essa abordagem determinística assume sensores perfeitos e um modelo físico exato, desconsiderando os ruídos e distúrbios comuns em ambientes reais.

B. Sistemas Estocásticos e Fontes de Incerteza

Na prática, os sistemas robóticos sofrem perturbações que inviabilizam o uso de modelos puramente determinísticos. Essas incertezas vêm de duas fontes principais [2]:

- 1) **Ruído de Processo (ϵ):** Representa distúrbios dinâmicos, forças ambientais (como atrito variante, irregularidades no solo e correntes de ar) e erros de modelagem que afetam a locomoção do robô.
- 2) **Ruído de Medição (δ):** Agrupa as incertezas dos próprios sensores. Em sistemas de localização por radiofrequência ou acústicos, decorre de efeitos de multicaminho, ruído térmico nos circuitos, atenuação de sinal e falhas de calibração [8].

Com a inclusão desses ruídos, o estado deixa de ser um ponto exato e passa a ser tratado como uma variável aleatória. A evolução temporal do sistema e as leituras dos sensores passam a ser modeladas por densidades de probabilidade condicionais:

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (3)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (4)$$

onde $k \in \mathbb{N}$ indica o passo de tempo discreto. O tratamento matemático dessas incertezas garante que os estimadores operem de forma estável mesmo sob condições severas [6].

C. Robótica Probabilística, Suposição de Markov e a Crença (*Belief*)

Para lidar com as incertezas de modelos e sensores, a robótica probabilística calcula a crença (*belief*) do robô a respeito de seu próprio estado. O *belief* é a distribuição de probabilidade a posteriori do vetor de estados $\mathbf{x}_k$, condicionada ao histórico de comandos enviados e medições recebidas [4]:

$$\text{bel}(\mathbf{x}_k) = P(\mathbf{x}_k | \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (5)$$

Para viabilizar o cálculo dessa distribuição em tempo real, aplica-se a **Suposição de Markov**. Esse postulado assume que o estado atual $\mathbf{x}_k$ é uma estatística suficiente do sistema, contendo toda a informação do passado. Assim, o estado futuro depende apenas do estado presente e da ação atual, o que simplifica a probabilidade condicional para:

$$P(\mathbf{x}_k | \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (6)$$

A propriedade de Markov permite dividir o cálculo do *belief* de forma recursiva em duas etapas: predição e correção, que formam a estrutura dos filtros de estimação sequenciais [4].

D. O Modelo Gauss-Markov

O cálculo das distribuições probabilísticas torna-se tratável quando o sistema segue o Modelo Gauss-Markov. Esse modelo define um processo que obedece à propriedade de Markov e cujos ruídos de processo e medição (ϵ_k e δ_k) são gaussianos, brancos e com média nula [9].

A principal vantagem dessa modelagem está na conservação das propriedades estatísticas: transformações lineares aplicadas a variáveis gaussianas geram novas variáveis gaussianas [8]. Com isso, o *belief* $\text{bel}(\mathbf{x}_k)$ permanece estritamente gaussiano ao longo do tempo.

Como uma distribuição gaussiana é definida apenas pelo seu vetor de médias ($\hat{\mathbf{x}}$) e por sua matriz de covariância ($\mathbf{P}$), o problema de rastrear uma função contínua de dimensão infinita resume-se a atualizar esses dois parâmetros a cada passo de tempo discreto.

E. Discretização do Sistema e das Covariâncias

Embora os modelos cinemáticos baseiem-se no tempo contínuo (t), os processadores digitais operam em intervalos discretos Δt . Considerando o vetor de controle $\mathbf{u}(t)$ constante dentro de cada intervalo de amostragem, o sistema linear contínuo $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ é convertido para sua forma discreta equivalente sob o modelo Gauss-Markov [9]:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (7)$$

As matrizes discretas de transição de estados ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) são obtidas a partir das matrizes contínuas pelas relações:

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \left(\int_0^{\Delta t} e^{\mathbf{A}_c \tau} d\tau \right) \mathbf{B}_c \quad (8)$$

Discretização das Covariâncias de Ruído: A amostragem digital também exige a discretização das matrizes de covariância dos ruídos [9]. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se de acordo com a própria dinâmica do sistema. A matriz discreta equivalente, $\mathbf{Q}_k$, é calculada pela integral:

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (9)$$

Para taxas de amostragem altas ($\Delta t \ll 1$), pode-se aproximar essa relação por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, assumindo um crescimento linear da incerteza [9]. No entanto, em modelos cinemáticos de ordem superior — como o espaço de estados Posição-Velocidade-Aceleração (PVA) deste trabalho —, a resolução analítica da Equação (9) é necessária para manter o acoplamento cruzado das incertezas, gerando os termos polinomiais apresentados na Seção III.

Extensão para Sistemas Não Lineares: Se a dinâmica do sistema contínuo for não linear, utilizam-se métodos de integração numérica para a discretização. O método de Euler, por exemplo, resulta na aproximação:

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (10)$$

Para propagar a incerteza gaussiana nesses casos, o modelo aproximado deve ser linearizado localmente por meio de matrizes Jacobianas a cada passo k [4].

F. Filtros de Estimação Baseados em Kalman

O Filtro de Kalman é a solução ótima para propagar e corrigir o *belief* gaussiano em sistemas lineares sob a suposição de Markov. O algoritmo não estima o estado como um ponto fixo, mas rastreia os parâmetros que definem sua distribuição de probabilidade.

1) *Filtro de Kalman Linear:* Com base no modelo Gauss-Markov discreto, a dinâmica e o modelo de observação incorporam os ruídos de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (11)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (12)$$

onde $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O filtro calcula recursivamente o estado corrigido $\hat{\mathbf{x}}_{k|k}$ (média) e sua matriz de covariância $\mathbf{P}_{k|k}$ (incerteza). O processo é dividido em etapas de predição e correção, conforme descrito no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$$

$$2: \mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$3: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$4: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

Se houver oclusão de sinal ou indisponibilidade dos sensores, a etapa de correção (linhas 4 a 6) não é executada. Nessas situações, o filtro opera em malha aberta apenas com a predição cinemática. Como consequência, a covariância $\mathbf{P}_{k|k-1}$ cresce a cada passo, resultando no aumento contínuo do ROI Dinâmico.

2) *Filtro de Kalman Estendido (EKF):* Quando o sistema de localização utiliza distâncias radiais em relação a estações com coordenadas conhecidas, as equações de observação tornam-se não lineares devido à geometria do problema. Nesses cenários, utiliza-se o Filtro de Kalman Estendido (EKF) [4], que aceita funções não lineares genéricas g e h :

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (13)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (14)$$

Para propagar as matrizes de incerteza, o algoritmo utiliza uma expansão em série de Taylor de primeira ordem. Essa linearização local exige o cálculo das matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$ em torno das estimativas atuais:

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \hat{\mathbf{x}}_{k-1|k-1}} \quad (15)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (16)$$

Essas matrizes Jacobianas substituem as matrizes fixas do caso linear na propagação das incertezas e no cálculo do ganho de Kalman ($\mathbf{K}_k$), permitindo o rastreamento em sistemas com não linearidades geométricas (Algoritmo 2).

Algorithm 2 Filtro de Kalman Estendido (EKF)

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow g(\mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$2: \mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$3: \mathbf{P}_{k|k-1} \leftarrow \mathbf{G}_k \mathbf{P}_{k-1|k-1} \mathbf{G}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$4: \mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$6: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}))$$

$$7: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1}$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

G. Métricas de Avaliação e Consistência Estocástica

O desempenho do estimador é avaliado por meio de métricas de precisão geométrica e testes estatísticos baseados nos resíduos da inovação [8].

1) *Root Mean Square Error (RMSE)*: A precisão geométrica espacial nas trajetórias bidimensionais é medida pela Raiz do Erro Quadrático Médio (RMSE). O RMSE calcula a distância euclidiana média entre o estado real $\mathbf{x}_k$ e o estado corrigido $\hat{\mathbf{x}}_{k|k}$ em um horizonte de N amostras:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (17)$$

Essa métrica também pode ser calculada de forma independente para os eixos cartesianos (X e Y) para identificar a direção de eventuais falhas de rastreamento.

2) *Normalized Innovation Squared (NIS)*: A precisão medida pelo RMSE não garante que o estimador seja consistente do ponto de vista estatístico. Um filtro é consistente se seus erros de estimação tiverem média nula e covariância compatível com os valores teóricos calculados pelo próprio algoritmo [8]. O teste do quadrado da inovação normalizada (NIS) verifica se a incerteza estimada na matriz $\mathbf{P}_k$ condiz com o comportamento real das medições.

A inovação $\nu_k \in \mathbb{R}^d$ representa a diferença entre a medição real e a predição calculada pelo filtro:

$$\nu_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}) \quad (18)$$

A matriz de covariância teórica da inovação, obtida na etapa de correção, é dada por:

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k \quad (19)$$

O escalar NIS (ϵ_k) é calculado pela forma quadrática baseada na distância de Mahalanobis:

$$\epsilon_k = \nu_k^T \mathbf{S}_k^{-1} \nu_k \quad (20)$$

Se o modelo cinemático e as matrizes de ruído ($\mathbf{Q}_k$ e $\mathbf{R}_k$) estiverem corretos, a variável ϵ_k segue uma distribuição Qui-Quadrado (χ^2) com n_z graus de liberdade, onde n_z é a dimensão do vetor de medições $\mathbf{z}_k$ [8].

Quando o histograma empírico dos resultados se mantém dentro dos limites de aceitação da distribuição Qui-Quadrado, o filtro e o ROI Dinâmico são considerados consistentes. Desvios prolongados para fora desses limites indicam erros de parametrização, sinalizando que o filtro está subestimando ou superestimando as incertezas reais do sistema [8].

III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Com o propósito de analisar o comportamento do EKF quanto à convergência, ajuste de parâmetros e consistência estatística, este estudo delinea um cenário de rastreamento bidimensional baseado exclusivamente em dados de distância (*range-only tracking*) [8]. Essa modelagem expande o arcabouço metodológico sugerido em [6], descrevendo a

movimentação do agente por meio de um modelo cinemático de processo estruturado no espaço de estados de Posição, Velocidade e Aceleração (PVA).

A. Descrição do Problema

O problema abordado consiste em estimar a trajetória de um robô móvel que opera em um plano bidimensional. O agente se desloca dentro de uma arena monitorada por uma infraestrutura de localização local, composta por $M = 4$ estações fixas (âncoras) instaladas em posições conhecidas, denotadas por $\mathbf{p}_i = [X_i, Y_i]^T$ para $i = 1, \dots, 4$. O arranjo completo desse ambiente operacional encontra-se esquematizado na Figura 1.

O robô não possui sensores de odometria ou de velocidade própria, dependendo exclusivamente de medições escalares de distância obtidas via radiofrequência ou ondas acústicas em relação a cada uma das estações. O objetivo do estimador é processar essas observações ruidosas e reconstruir, a cada passo temporal, a posição horizontal (X) e vertical (Y) do agente, estimando também suas componentes de velocidade e aceleração instantâneas.




Figura 1: Representação geométrica do sistema de posicionamento: o agente móvel no espaço bidimensional e os raios de medição (*range-only*) oriundos das quatro estações base fixas nos vértices da arena.

B. Modelo Cinemático de Processo (Espaço de Estados PVA)

Distanciando-se de abordagens cinemáticas simplificadas de velocidade constante, o estado do agente móvel no instante discreto k passa a ser representado por um vetor expandido de seis dimensões: $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$. Nessa estrutura, (x_k, y_k) correspondem às coordenadas de posição cartesiana, $(v_{x,k}, v_{y,k})$ às componentes da velocidade linear e $(a_{x,k}, a_{y,k})$ às acelerações instantâneas nos eixos X e Y , respectivamente.

A dinâmica temporal do sistema sob regime de aceleração constante (CA) é integrada ao longo do intervalo de amostragem Δt . Essa operação dá origem à matriz de transição de estados $\mathbf{A}_k$ (6×6), especificada na Equação (21):

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (21)$$

Fatores práticos como o escorregamento de rodas, desalinhamentos mecânicos e irregularidades do terreno introduzem, inevitavelmente, erros cumulativos na navegação [4]. Na formulação PVA escolhida, esse comportamento estocástico é transposto para o modelo admitindo que as perturbações ajam de forma independente sobre os componentes de posição, velocidade e aceleração. Essas fontes de incerteza são sintetizadas pela matriz de densidade espectral de potência contínua $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$.

Ao calcular a discretização analítica desse termo, ponderada pela própria dinâmica veicular no intervalo Δt , obtém-se uma matriz de covariância discreta $\mathbf{Q}_k$ caracterizada por ser esparsa e simétrica. O perfil estritamente diagonal fixado para $\mathbf{Q}_c$ assegura que haja um desacoplamento estocástico completo entre as dinâmicas dos eixos horizontal (X) e vertical (Y). Os elementos não nulos associados aos estados do eixo X (índices 0, 2 e 4) são calculados conforme as relações dispostas na Equação (22):

$$\begin{cases} Q_{0,0} = q_1 \Delta t + q_3 \frac{\Delta t^3}{3} + q_5 \frac{\Delta t^5}{20} \\ Q_{0,2} = Q_{2,0} = q_3 \frac{\Delta t^2}{2} + q_5 \frac{\Delta t^4}{8} \\ Q_{0,4} = Q_{4,0} = q_5 \frac{\Delta t^3}{6} \\ Q_{2,2} = q_3 \Delta t + q_5 \frac{\Delta t^3}{3} \\ Q_{2,4} = Q_{4,2} = q_5 \frac{\Delta t^2}{2} \\ Q_{4,4} = q_5 \Delta t \end{cases} \quad (22)$$

De maneira análoga, os componentes vinculados ao eixo Y (índices 1, 3 e 5) replicam essa mesma estrutura algébrica, utilizando as variâncias espectrais específicas $\{q_2, q_4, q_6\}$ detalhadas na Equação (23):

$$\begin{cases} Q_{1,1} = q_2 \Delta t + q_4 \frac{\Delta t^3}{3} + q_6 \frac{\Delta t^5}{20} \\ Q_{1,3} = Q_{3,1} = q_4 \frac{\Delta t^2}{2} + q_6 \frac{\Delta t^4}{8} \\ Q_{1,5} = Q_{5,1} = q_6 \frac{\Delta t^3}{6} \\ Q_{3,3} = q_4 \Delta t + q_6 \frac{\Delta t^3}{3} \\ Q_{3,5} = Q_{5,3} = q_6 \frac{\Delta t^2}{2} \\ Q_{5,5} = q_6 \Delta t \end{cases} \quad (23)$$

C. Modelo de Observação e Geometria das Estações Base

A partir do arranjo de infraestrutura detalhado na Seção III-A, o vetor de observações obtido a cada passo amostral é estruturado como $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$. A relação geométrica entre o estado cinemático estimado do robô e a distância escalar real até a i -ésima estação fixa é governada por uma função de observação não-linear $h_i(\mathbf{x}_k)$, descrita na Equação (24):

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (24)$$

Como o vetor de estado possui seis dimensões e as leituras dependem estritamente das coordenadas de posição (x_k, y_k) , as derivadas parciais da função de medição associadas aos componentes de velocidade e aceleração anulam-se por completo [8]. Sob essas condições, a matriz Jacobiana $\mathbf{H}_k$ (4×6) avaliada a cada iteração assume o formato estabelecido na Equação (25):

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (25)$$

Para concluir a modelagem matemática do sensor, a matriz de covariância do ruído de medição é definida como $\mathbf{R}_k = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$, em que cada termo diagonal reflete a variância do erro instrumental intrínseco de sua respectiva âncora de leitura.

D. Cenário de Desafio: Modelagem de Oclusão Temporal

Com o intuito de testar os limites do estimador expandido e validar a utilidade prática tanto da região de interesse (ROI) dinâmica quanto do teste estatístico NIS, projetou-se uma janela de oclusão parcial severa no ambiente de simulação. Dentro de um intervalo cronometrado $t \in [t_{\text{start}}, t_{\text{end}}]$, as leituras vindas das quatro estações base são intencionalmente suprimidas ($\mathbf{z}_{i,k} \rightarrow \emptyset$).


Esse bloqueio — cujo comportamento é ilustrado na Figura 2 — força o algoritmo a depender apenas das projeções geradas pela matriz de transição PVA (21). Sob condições normais de operação com o filtro atualizando as medições, a elipse mantém-se estável e restrita (Figura 2a). Contudo, sem o suporte das correções trazidas pelos sensores durante a oclusão, as incertezas de aceleração modeladas em $\mathbf{Q}_k$ acumulam-se rapidamente. O resultado direto é uma expansão geométrica acentuada na matriz de covariância predita ($\mathbf{P}_{k|k-1}$), que se traduz no alargamento progressivo da elipse de confiança (ROI) ao longo do deslocamento do robô, variando conforme a trajetória realizada (Figuras 2b e 2c).

IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo detalha a metodologia utilizada para avaliar o desempenho, a sensibilidade e a robustez à oclusão do estimador proposto. A apresentação segue a ordem lógica dos experimentos: inicialmente, descreve-se a geração cinemática das trajetórias de referência. Em seguida, detalham-se os cenários de teste e a modelagem do filtro. Por fim, definem-se as métricas estatísticas aplicadas na avaliação do Filtro de Kalman Estendido (EKF) sob diferentes parametrizações.

A. Síntese Cinemática das Trajetórias de Referência

Para que a precisão do Filtro de Kalman Estendido (EKF) possa ser avaliada, é indispensável compará-lo a um referencial absoluto e livre de ruídos, o *Ground Truth*. Nessa etapa, o simulador atua como um gerador de gabaritos: ele calcula a física exata do alvo para cada instante discreto



(a) Operação nominal: predição e atualização. (b) Oclusão: trajetória 1 (predição pura). (c) Oclusão: trajetória 2 (predição pura).

Figura 2: Representação visual da incerteza do EKF (ROI dinâmica): a elipse em cinza denota a incerteza predita ($\mathbf{P}_{k|k-1}$), enquanto a elipse em verde representa a incerteza atualizada após a correção ($\mathbf{P}_{k|k}$). (a) Regime de operação estável sob observações contínuas; (b) e (c) expansão da incerteza e degradação da precisão decorrentes da supressão das medições (occlusão temporal) em distintos perfis de trajetória.

k e armazena essas informações no vetor de estado $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$, que engloba as posições, velocidades e acelerações reais nos eixos ortogonais.

Como um alvo em uma aplicação real pode apresentar desde um trajeto altamente previsível até manobras bruscas, o simulador foi projetado para testar os limites do estimador utilizando duas abordagens distintas de movimento:

- **Curvas paramétricas analíticas (Determinísticas):** Simulam cenários onde o alvo obedece a regras geométricas bem definidas e contínuas. Servem para testar o filtro sob dinâmicas estáveis e previsíveis.
- **Modelos numéricos comportamentais (Estocásticos):** Inserem aleatoriedade na navegação do alvo. Servem para testar a capacidade de adaptação do EKF quando o objeto realiza trajetórias erráticas ou mudanças repentinas de direção.

O conjunto completo dessas trajetórias, abrangendo todos os perfis cinemáticos abordados nos testes, pode ser visualizado na Figura 3.

1) *Geração de Curvas Paramétricas e Analíticas:* Para os testes com movimentos contínuos e regulares, as posições do alvo no simulador são ditadas por funções trigonométricas e hiperbólicas dependentes do tempo. Um cuidado fundamental nessa etapa foi evitar o cálculo numérico das derivadas. Para garantir que o *Ground Truth* seja matematicamente perfeito e livre de erros de discretização, a velocidade e a aceleração do alvo são extraídas a partir da diferenciação analítica exata das equações de posição, conforme detalha o Algoritmo 3.

As trajetórias com quinas, como o percurso quadrado, obedecem a esse mesmo rigor determinístico. A única diferença é que a modelagem utiliza segmentos de reta conectados para formar as arestas, aplicando-se uma restrição geométrica de fechamento para garantir que o alvo retorne exatamente à coordenada onde iniciou o percurso.

2) *Geração de Navegação Aleatória e Oclusões:* Para aproximar a simulação do comportamento estocástico de um alvo real, desenvolveu-se um algoritmo de navegação aleatória. O agente (UGV - Unmanned Ground Vehicle) move-se em linha reta por distâncias mínimas antes de realizar deflexões suaves. Se o robô atinge os limites da arena (raio superior a

Algorithm 3 Geração de Trajetórias Paramétricas Analíticas

Require: Tempo contínuo $t_k = k\Delta t$, Parâmetros geométricos (Amplitude A , Frequência ω)

```

1: for cada instante  $k$  do
2:   if Perfil = Circular then
3:      $\mathbf{p}_k \leftarrow [c_x + R \cos(\omega t_k), c_y + R \sin(\omega t_k)]^T$ 
4:   else if Perfil = Mudança de Faixa (Tanh) then
5:      $\mathbf{p}_k \leftarrow [v_x t_k, c_y + A \tanh(S \cdot t_k)]^T$ 
6:   else if Perfil = Lemniscata then
7:      $\mathbf{p}_k \leftarrow [c_x + A \sin(\omega t_k), c_y + \frac{A}{2} \sin(2\omega t_k)]^T$ 
8:   end if
9:    $\mathbf{v}_k \leftarrow \frac{d}{dt} \mathbf{p}_k$ 
10:   $\mathbf{a}_k \leftarrow \frac{d}{dt} \mathbf{v}_k$ 
11:   $\mathbf{x}_k \leftarrow [\mathbf{p}_k^T, \mathbf{v}_k^T, \mathbf{a}_k^T]^T$ 
12: end for

```

Ensure: Sequência de estados reais $\mathbf{x}_{1:N}$

35 metros), um mecanismo de evasão direciona o movimento de volta ao centro, mantendo o robô na área útil.

Como as mudanças de direção são aleatórias, a aceleração de referência é calculada por diferenciação numérica discreta, conforme estruturado no Algoritmo 4.

B. Cenários de Simulação e Estratégia de Sintonia

Para avaliar o estimador na prática, a campanha de testes foi dividida em **6 cenários cinemáticos** (ilustrados na Figura 3), abrangendo diferentes perfis de aceleração e condições de oclusão. Além do movimento do alvo, o comportamento do EKF depende diretamente das suas matrizes de covariância ($\mathbf{Q}_k$ para o processo e $\mathbf{R}_k$ para a medição). Para testar a sensibilidade do algoritmo a esses parâmetros, cada cenário foi simulado sob **duas condições distintas**:

- 1) **Situação Sintonizada (Filtro Calibrado):** Representa a condição de funcionamento ideal do rastreador. Os valores das matrizes foram ajustados de forma empírica (por tentativa e erro), avaliando o comportamento do filtro até que ele apresentasse um desempenho considerado "bom". O critério de sucesso foi a minimização do erro




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos.

Algorithm 4 Geração de Navegação Dinâmica Aleatória

Require: Vetor posição central $\mathbf{p}_c$, Limite da arena $R_{\max}$, Ruído cinemático w

```

1: for cada instante  $k$  do
2:   if Distância percorrida  $> D_{\min}$  then
3:     if  $\|\mathbf{p}_{k-1} - \mathbf{p}_c\| > R_{\max}$  then
4:        $\theta_{\text{alvo}} \leftarrow$  Ângulo forçado em direção a  $\mathbf{p}_c$ 
5:     else
6:        $\theta_{\text{alvo}} \leftarrow \theta_{k-1} + \mathcal{U}(-\frac{\pi}{3}, \frac{\pi}{3})$ 
7:     end if
8:      $v_{\text{alvo}} \leftarrow v_{\text{base}} + \mathcal{U}(-w, w)$ 
9:   end if
10:   $\theta_k \leftarrow \text{SuavizarTransição}(\theta_{k-1}, \theta_{\text{alvo}})$ 
11:   $v_k \leftarrow \text{SuavizarTransição}(v_{k-1}, v_{\text{alvo}})$ 
12:   $\mathbf{v}_k \leftarrow [v_k \cos(\theta_k), v_k \sin(\theta_k)]^T$ 
13:   $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$ 
14:   $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$ 
15: end for

Configuração Especial para Oclusão Cíclica:
16: if Modo Oclusão then
17:   Emite uma máscara binária atribuindo valor Falso
   (Oculito) no segmento temporal central de 4 blocos.
18: end if

```

de posição aliada a elipses de confiança visualmente e estatisticamente coerentes com a trajetória.

- 2) **Situação Não Sintonizada (Filtro Descalibrado):** Representa falhas severas na configuração do projeto. Nessa etapa, os valores das matrizes foram intencional-

mente sabotados, sendo superestimados ou subestimados. O objetivo de impor essas condições anormais é demonstrar como o filtro se comporta mal quando está mal configurado e comprovar a importância de uma boa sintonia.

A Tabela I consolida todas as variáveis utilizadas nos testes: a configuração de movimento do alvo, o nível de ruído físico (σ) simulado nos sensores e os valores numéricos utilizados para sintonizar (ou descalibrar) o EKF em cada um dos seis cenários.

C. Configuração do Estimador e Modelagem do Ruído

O objetivo do filtro é estimar o estado completo do alvo (o vetor PVA $\mathbf{x}_k$, detalhado na Seção III). Para alimentar o algoritmo, o sistema mede a distância do robô até quatro estações rádio-base fixadas nos cantos da arena.

Como nenhum sensor no mundo real é perfeito, o simulador precisa "sujar" as medidas ideais do *Ground Truth*. Para imitar a imprecisão real, o sistema injeta um erro aleatório em cada canal: soma-se à distância exata um ruído gaussiano branco de média zero e desvio padrão σ (valores indicados na Tabela I).

Isso resulta no vetor de observação $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$, que contém as quatro distâncias ruidosas que o EKF efetivamente recebe como entrada, conforme a Equação (26):

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (26)$$

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Circular	Quadrada	Tanh	Lemniscata	Nav. Aleatória	Oclusão Cíclica
Movimento	$v = 10,0 \text{ m/s}$	$v = 10 \text{ m/s}$	$A_y = 20,0 \text{ m}$	$v = 10,0 \text{ m/s}$	$v_0 = 2,0 \text{ m/s}$	$v = 5,0 \text{ m/s}$
	$r = 30,0 \text{ m}$	$L = 40,0 \text{ m}$	$v = 10,0 \text{ m/s}$	$A = 35,0 \text{ m}$	$\epsilon_v = 0,5 \text{ m/s}$	30 fr/occlusão
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Ruído nas Torres (σ)	0,30 m	0,20 m	0,40 m	0,40 m	0,40 m	0,40 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,9\mathbf{I}_4$	$0,9\mathbf{I}_4$	$0,9\mathbf{I}_4$	$0,9\mathbf{I}_4$	$0,9\mathbf{I}_4$	$0,9\mathbf{I}_4$
Matriz Processo $Q_{6 \times 6}$	$\mathbf{I}_6$	$\mathbf{I}_6$	$\mathbf{I}_6$	$\mathbf{I}_6$	$\mathbf{I}_6$	$\mathbf{I}_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1\mathbf{I}_4$	$0,1\mathbf{I}_4$	$0,01\mathbf{I}_4$	$0,9\mathbf{I}_4$	$0,01\mathbf{I}_4$	$0,01\mathbf{I}_4$
Matriz Processo $Q_{6 \times 6}$	$0,01\mathbf{I}_6$ (Sup.)	$0,01\mathbf{I}_6$ (Sup.)	$0,5\mathbf{I}_6$ (Sub.)	$0,5\mathbf{I}_6$ (Sup.)	$0,5\mathbf{I}_6$ (Sub.)	$0,05\mathbf{I}_6$ (Sub.)

Nota: $\mathbf{I}_n$ representa a matriz identidade de dimensão $n \times n$, denotando configurações diagonais. A matriz $\mathbf{R}$ foi configurada baseada na variância real do ruído injetado ($\mathbf{R} = \sigma^2 \mathbf{I}_4$). (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.

É importante destacar que o EKF trabalha diretamente com essas distâncias puras na sua forma não-linear ($\mathbf{z}_k$). No entanto, para que possamos desenhar a posição lida pelos sensores na interface gráfica do simulador, o sistema realiza um cálculo paralelo. Ele pega essas quatro distâncias com ruído e aplica um algoritmo numérico de multilateração por Mínimos Quadrados para estimar uma coordenada cartesiana $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$. Essa coordenada 2D serve estritamente como apoio visual para a tela e para a validação externa, não interferindo nas contas do Filtro de Kalman.

D. Ambiente Computacional e Infraestrutura de Simulação

A interface gráfica serve apenas para inspeção visual e validação qualitativa. O núcleo numérico do simulador opera de forma independente, permitindo que as campanhas de teste e a exportação dos dados brutos ocorram de forma automatizada. Detalhes do *layout* da interface encontram-se no Apêndice ??.

E. Métodos de Avaliação e Consistência

Para garantir que o EKF não apenas acerte a posição, mas também tenha uma noção realista de sua própria incerteza, o desempenho do estimador é avaliado sob duas óticas principais: acurácia espacial e consistência estatística.

A acurácia é medida comparando as estimativas corrigidas *a posteriori* ($\hat{x}_{k|k}, \hat{y}_{k|k}$) com o *Ground Truth*. Para quantificar esse desvio nos eixos ortogonais, utiliza-se a Raiz do Erro Quadrático Médio (RMSE), conforme as Equações (27) e (28):

$$\text{RMSE}_x = \sqrt{\frac{1}{N} \sum_{k=1}^N (x_k - \hat{x}_{k|k})^2} \quad (27)$$

$$\text{RMSE}_y = \sqrt{\frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_{k|k})^2} \quad (28)$$

Figura 4: Diagrama da arquitetura de software da aplicação de simulação.

Para automatizar a execução dos cenários e garantir a reprodutibilidade dos dados, o simulador foi desenvolvido em *Python* (versão 3.10) utilizando uma arquitetura modular, conforme ilustrado na Figura 4. O processamento matricial e a computação vetorizada do EKF foram implementados com a biblioteca *NumPy*.

Para facilitar a sintonia das matrizes $\mathbf{Q}_k$ e $\mathbf{R}_k$, integrou-se uma interface gráfica (GUI) em *PyQt*. A plataforma permite ajustar parâmetros em tempo real via *sliders* e renderiza instantaneamente a trajetória estimada, o vetor de observações e a elipse de covariância da região de interesse (ROI).

Para observar se o filtro apresenta alguma tendência sistemática de errar sempre para o mesmo lado (viés), acompanha-se também o Erro Médio com sinal (ME), definido na Equação (29):

$$\text{ME}_x = \frac{1}{N} \sum_{k=1}^N (x_k - \hat{x}_{k|k}) \quad \text{e} \quad \text{ME}_y = \frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_{k|k}) \quad (29)$$

Além de preciso, um filtro bem sintonizado precisa ser estatisticamente consistente. Isso significa que os erros de predição em relação à realidade devem se comportar puramente como ruído branco. Para atestar isso, avalia-se o histograma dos erros nos eixos X e Y ; em condições ideais de calibração, esses erros devem seguir rigorosamente uma distribuição Normal (Gaussiana) de média zero.

Complementarmente, a consistência global da matriz de covariância é auditada através da métrica NIS (*Normalized Innovation Squared*). O NIS quantifica o quão compatível a inovação real está com a incerteza calculada pelo filtro. Quando as matrizes $\mathbf{Q}$ e $\mathbf{R}$ estão perfeitamente ajustadas, os valores de NIS devem respeitar uma distribuição Qui-quadrado (χ^2).

1) Validação da Crença do Estimador (*Inlier Rate*):

De forma análoga ao NIS, implementou-se uma métrica geométrica mais visual para atestar a consistência da previsão: a Taxa de *Inliers* (*Inlier Rate*). O objetivo dessa métrica não é filtrar ou rejeitar dados, mas sim verificar, percentualmente, quanto tempo as novas medições "nasceram" dentro da região de crença (*belief*) que o modelo acabou de prever.

A lógica consiste em checar se a coordenada cartesiana de apoio calculada pela multilateração ($\mathbf{m}_k$) encontra-se dentro dos limites estatísticos projetados para aquela iteração. Os desvios-padrão teóricos para os eixos X e Y são extraídos diretamente da matriz de covariância predita $\mathbf{P}_{k|k-1}$. Para evitar problemas numéricos com valores muito próximos de zero, aplica-se um limite inferior de segurança fixado em 10^{-6} :

$$\sigma_{x,\text{pred}} = \sqrt{\max(10^{-6}, P_{k|k-1}^{(1,1)})} \quad (30)$$

$$\sigma_{y,\text{pred}} = \sqrt{\max(10^{-6}, P_{k|k-1}^{(2,2)})} \quad (31)$$

Os limites físicos dessa janela de verificação utilizam o critério de 3σ , que teoricamente deve englobar cerca de 99,7% das medições válidas em uma distribuição normal. Esses limites ficam condicionados a uma abertura mínima de projeto $\tau_{\min}$, garantindo que a janela não feche caso a incerteza do filtro colapse para perto de zero:

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{pred}}) \quad \text{e} \quad L_y = \max(\tau_{\min}, 3\sigma_{y,\text{pred}}) \quad (32)$$

Calculando-se a inovação cartesiana pelas diferenças $\tilde{x}_k = m_{x,k} - \hat{x}_{k|k-1}$ e $\tilde{y}_k = m_{y,k} - \hat{y}_{k|k-1}$, o ponto recém-chegado é contabilizado como um *inlier* caso obedeça à Equação (33):

$$|\tilde{x}_k| \leq L_x \quad \wedge \quad |\tilde{y}_k| \leq L_y \quad (33)$$

A contagem final gera uma porcentagem de sucesso que serve como um termômetro direto sobre a qualidade do rastreamento. A intuição visual dessa métrica, com as medições caindo dentro dos limites da crença predita, é exemplificada na Figura 5.

V. RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados experimentais obtidos a partir das simulações computacionais do Filtro de Kalman Estendido (EKF) submetido aos seis cenários de navegação descritos na Seção IV. O desempenho do estimador é avaliado quantitativamente por meio de métricas de acurácia posicional (RMSE e Erro Máximo), consistência estatística (NIS) e eficácia de validação espacial (Taxa de *Inliers*).

Para evidenciar o impacto da parametrização estocástica nas propriedades dinâmicas do filtro, os resultados de cada cenário são contrastados sob duas condições: matrizes ideais (Sintonizado) e matrizes intencionalmente degradadas (Não




Figura 5: Representação visual da métrica de *Inliers*, ilustrando as medições que se encontram dentro dos limites da crença predita pelo estimador.

Sintonizado). Cabe ressaltar que a condição não sintonizada serve exclusivamente como uma base de comparação analítica, com o propósito de ilustrar a sensibilidade e a possível divergência do estimador frente a uma configuração subestimada do ruído de processo. A Tabela II consolida as principais estatísticas globais extraídas do motor de simulação.

A. Interface Gráfica e Ambiente de Simulação Funcional

Antes do detalhamento das curvas temporais, a Figura 6 apresenta o ambiente computacional integrado, desenvolvido em Python, para a validação do estimador. A interface gráfica (GUI) consolida em uma única tela a renderização espacial da arena de testes, a telemetria em tempo real das posições estimadas em contraste com o *Ground Truth*, e os painéis de atualização dinâmica para o monitoramento acumulado do RMSE e do NIS.

Esta ferramenta interativa opera como o motor de visualização síncrona do sistema, permitindo que o operador altere dinamicamente as ordens de grandeza das matrizes de covariância $\mathbf{Q}$ e $\mathbf{R}$, observando de imediato os reflexos visuais na morfologia e na área das elipses de incerteza geradas ao redor do agente em movimento.

Figura 6: Ambiente gráfico integrado em Python desenvolvido para o monitoramento e a validação do EKF. O painel central exibe a arena com as estações base e a trajetória do alvo, enquanto os módulos adjacentes computam os indicadores de erro (RMSE) e consistência (NIS) sob execução contínua.

B. Análise de Acurácia Posicional e Convergência

Os dados da Tabela II demonstram que, sob a condição sintonizada, o EKF atenuou substancialmente o ruído intrínseco do sistema de localização. Para os cenários de 1 a 5, o RMSE manteve-se restrito à faixa de 0,11 m a 0,20 m no eixo X e

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	$RMSE_x$ [m]	$RMSE_y$ [m]	E_{max} [m]	μ_x [m]	NIS	$NIS > 9,49$ (%)	TD (%)	TI (%)
CONDIÇÃO SINTONIZADA								
Cenário 1	0,11	0,14	0,46	+0,01	0,42	0,00%	100,00%	100,00%
Cenário 2	0,20	0,28	0,97	-0,00	0,47	0,00%	100,00%	99,58%
Cenário 3	0,11	0,13	0,46	+0,00	0,68	0,00%	100,00%	98,83%
Cenário 4	0,12	0,15	0,50	+0,01	0,66	0,00%	100,00%	99,83%
Cenário 5	0,11	0,15	0,58	+0,01	0,66	0,00%	100,00%	99,83%
Cenário 6	0,19	0,27	2,44	+0,00	0,72	0,00%	90,00%	99,81%
CONDIÇÃO NÃO SINTONIZADA (Exemplo Comparativo)								
Cenário 1	0,24	0,34	0,62	+0,00	6,82	23,17%	100,00%	18,58%
Cenário 2	0,59	0,80	2,17	-0,03	23,97	56,34%	100,00%	20,17%
Cenário 3	0,12	0,14	0,47	+0,00	10,09	38,58%	100,00%	97,75%
Cenário 4	0,23	0,30	0,97	-0,01	41,06	87,75%	100,00%	69,50%
Cenário 5	0,23	0,30	1,01	+0,00	40,20	88,67%	100,00%	74,92%
Cenário 6	0,33	0,40	2,41	-0,03	39,25	88,43%	90,00%	75,09%

Cenários: 1: Circular; 2: Quadrada; 3: Tangente Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limite do NIS a 95% de confiança (4 G.L.) é $\approx 9,49$.

Legenda das métricas: $RMSE_x$, $RMSE_y$: Raiz do Erro Quadrático Médio em X e Y; E_{max} : Erro Máximo Absoluto; μ_x : Viés Médio em X;

NIS : Média do *Normalized Innovation Squared* (limite teórico $\approx 9,49$ para 4 G.L. a 95% de confiança);

$NIS > 9,49$: Percentual de frames que excederam o limite; TD : Taxa de Detecção; TI : Taxa de Inliers na Região de Interesse (ROI).

de 0,13 m a 0,28 m no eixo Y. Esta margem de erro sub-métrica é um indicativo de elevada precisão, especialmente em ambientes cujas incertezas de medição brutas superam tais valores.


Destaca-se o comportamento no Cenário 2 (Trajetória Quadrada), no qual a descontinuidade abrupta nas acelerações resultou em um ligeiro e esperado aumento do Erro Máximo Absoluto (0,97 m), refletindo a inércia transitória do filtro frente a mudanças ortogonais de direção.

A finalidade de incluir a condição não sintonizada é justificar a necessidade da etapa de calibração e demonstrar as consequências de uma parametrização inadequada, conforme ilustrado na Figura 7. Quando o filtro operou com subestimação severa da variância do processo (matriz Q), observou-se uma acentuada degradação da acurácia. O erro apresentou um crescimento expressivo, evidenciado pelo RMSE do eixo Y no Cenário 2, que escalou de 0,28 m para 0,80 m, com o Erro Máximo atingindo 2,17 m. Este comportamento ilustra a sensibilidade topológica do EKF: ao depositar uma confiança excessiva no modelo cinemático interno e minimizar o peso das inovações sensoriais, o filtro torna-se excessivamente "rígido" e incapaz de acompanhar a manobrabilidade real do alvo.


C. Consistência Estatística e Comportamento do NIS

A avaliação da consistência interna do estimador fundamentou-se no teste estatístico da inovação normalizada (*Normalized Innovation Squared* – NIS). Considerando um vetor de observação proveniente de quatro torres de rádio, o sistema possui 4 graus de liberdade. Conforme a distribuição Qui-Quadrado (χ^2), a região de confiança a 95% de probabilidade estabelece um limiar teórico de aceitação em 9,49.

Sob a condição sintonizada (Figura 8), todos os cenários apresentaram um percentual de violação desse limite perfeitamente nulo (0,00%). Esse resultado atesta que a matriz de



(a) Condição Sintonizada



(b) Condição Não Sintonizada

Figura 7: Comparativo da evolução temporal do erro posicional de rastreamento (RMSE) para o Cenário 2. Em (a), o filtro opera com calibração ótima, mantendo o erro contido mesmo nas curvas. Em (b), evidencia-se a degradação da acurácia sob condições de calibração inadequada (subestimação da variância do processo).

covariância do erro ($\mathbf{P}$) dimensionou a incerteza de maneira analiticamente coerente ao longo de todo o trajeto. Nota-se, ainda, que o NIS médio global assumiu um perfil mais conservador, variando entre 0,42 e 0,72 (abaixo da média teórica de 4,0). Esta característica decorre de um ligeiro superdimensionamento intencional no ganho da covariância preditiva, estratégia que mantém a distância de Mahalanobis contida e confere maior estabilidade numérica contra divergências de linearização.




Figura 8: Histórico da métrica *Normalized Innovation Squared* (NIS) para o Cenário 2 Sintonizado. A linha de corte pontilhada demarca o limite estatístico teórico de 9,49 para um intervalo de confiança de 95%.

Em contraste, os dados da Tabela II deixam evidente a grave inconsistência estocástica dos exemplos não sintonizados. Nos Cenários 4 (Lemniscata) e 5 (Navegação Aleatória), 87,75% e 88,67% das inovações, respectivamente, ultrapassaram a barreira crítica dos 9,49. O NIS médio atingiu patamares próximos a 40, indicando que a matriz de incerteza gerada pelo algoritmo perdeu totalmente o vínculo probabilístico com os resíduos reais de rastreamento, caracterizando a divergência estatística do estimador.

D. Estabilidade Operacional sob Oclusão (Cenário 6)

O Cenário 6 impõe uma condição de estresse severo ao algoritmo ao simular a interrupção intencional do sinal de medição em trechos específicos do percurso, reduzindo a Taxa de Detecção global (TD) para 90,00%. Durante esses intervalos de oclusão temporária, o estágio de correção do filtro de Kalman é mandatoriamente suprimido. Consequentemente, o sistema é forçado a propagar o estado de maneira puramente preditiva (em regime de malha aberta), fiando-se de forma estrita à matriz de transição do modelo Posição-Velocidade-Aceleração (PVA).

Os resultados quantitativos, aliados à visualização espacial da trajetória projetada na Figura 9, comprovam a excelente capacidade de retenção inercial do sistema. Embora internamente o algoritmo experimente um acúmulo contínuo de incerteza devido à ausência de ancoragem sensorial, a estimativa do estado não divergiu de forma descontrolada. Houve, de fato, um aumento pontual no RMSE do eixo Y (0,27 m) e o Erro Máximo registrou um pico isolado de 2,44 m próximo ao fim dos ciclos de cegueira; entretanto, a formulação PVA demonstrou sua eficácia ao atuar como uma robusta memória cinemática.




Figura 9: Comportamento espacial do estimador durante o Cenário 6. Observa-se a ausência de atualizações sensoriais nos trechos ocultos, mantendo-se a continuidade suave da estimativa PVA projetada em malha aberta.

O gráfico ilustra claramente como o filtro consegue preencher as lacunas topológicas mantendo o momento (velocidade e aceleração) do alvo, garantindo uma reaquisição imediata e suave assim que o sinal dos sensores é restabelecido.

E. Eficácia da ROI e Taxa de Inliers

A implementação de um limiar multi-sigma dinâmico, baseado na covariância da inovação *a posteriori* (avaliado pela métrica de Taxa de Inliers na Região de Interesse – *TI*), apresentou resultados altamente satisfatórios como ferramenta de diagnóstico de confiabilidade em tempo real. Com o filtro devidamente sintonizado, a Taxa de Inliers alcançou proporções quase absolutas, mantendo-se restrita à margem de 98,83% a 100,00%. Esse dado prático comprova que a janela espacial de busca, calculada internamente pela predição, engloba adequadamente a dispersão dos desvios mecânicos simulados do ambiente.

A relevância funcional desta métrica é reiterada de forma enfática ao se examinar as configurações falhas. Tomando como base a versão não sintonizada do Cenário 1, a Taxa de Inliers sofre um colapso, despencando para 18,58%. Sob essa condição degradada, a região de confiança delimitada pela matriz de covariância residual $\mathbf{S}$ torna-se matematicamente incompatível com as perturbações do mundo físico. O filtro, acreditando cegamente em sua estimativa falha, passa a rejeitar leituras reais e válidas por rotulá-las equivocadamente como anomalias estocásticas (*outliers*). Desse modo, consolida-se a métrica *TI* como um indicador estrutural de altíssimo valor: quedas abruptas nessa taxa sinalizam prontamente que o estimador perdeu a aderência geométrica ao fenômeno e necessita de intervenção de calibração iminente.

VI. CONCLUSÃO

A. Resumo

Este trabalho apresentou o desenvolvimento, a implementação computacional e a análise crítica de um

Filtro de Kalman Estendido (EKF) aplicado ao rastreamento bidimensional de alvos móveis. O sistema operou sob um regime de medições não-lineares de distância (*range-only*), adquiridas a partir de quatro estações base fixas. Para avaliar o estimador de forma rigorosa, construiu-se um motor de simulação customizado em ambiente Python capaz de gerar seis trajetórias cinemáticas distintas (Cenários 1 a 6) baseadas no modelo de estado contínuo de Posição-Velocidade-Aceleração (PVA). O estudo avaliou o impacto direto da parametrização estocástica (matrizes $\mathbf{Q}$ e $\mathbf{R}$) sobre a precisão do filtro, contrastando situações de sintonia empírica otimizada contra casos de severa descalibração de projeto.

B. Principais Constatações

Os resultados experimentais demonstraram que o EKF é altamente eficaz na mitigação de ruídos gaussianos de medição, desde que suas matrizes de projeto reflitam fielmente a dinâmica do sistema. Constatou-se que a subestimação do ruído de processo ($\tilde{q}$) força o filtro a ignorar as inovações, resultando em inércia e divergência geométrica nas curvas (como evidenciado no aumento do RMSE). Por outro lado, a superestimação de $\tilde{q}$ torna o filtro excessivamente reativo, amplificando o ruído de alta frequência nas estimativas.

O teste estatístico do *Normalized Innovation Squared* (NIS) provou ser um indicador *offline* implacável para validar a integridade da matriz de covariância ($\mathbf{P}$). Além disso, o cenário de oclusão (Cenário 6) atestou a robustez da cinemática PVA expandida, que permitiu ao filtro sustentar o rastreamento em malha aberta (*predição pura*) durante os apagões temporários de sinal sem que a trajetória divergisse catastróficamente.

C. Contribuições

As principais contribuições deste trabalho incluem:

- A concepção de uma arquitetura de simulação interativa e transparente, que permite monitorar visualmente o comportamento interno das matrizes do EKF (elipses de confiança) em tempo de execução.
- A introdução de uma métrica geométrica de validação baseada na crença predita do estimador (ROI Dinâmica). Essa abordagem permitiu rejeitar *outliers* e mensurar a Taxa de *Inliers* operando diretamente no espaço cartesiano, contornando a complexidade de validações no espaço não-linear dos sensores.
- O mapeamento detalhado da sensibilidade geométrica e estocástica do EKF frente a diferentes arranjos de movimento de alvos.

D. Limitações

Apesar dos resultados robustos, o arranjo metodológico apresenta algumas limitações. Primeiramente, o ruído injetado no motor de simulação foi estritamente gaussiano e de média nula. Em ambientes de rádio-localização do mundo real (como UWB ou Wi-Fi), o ruído costuma apresentar componentes não-gaussianos e vieses severos causados por efeitos de propagação *multipath* (multicaminho) e reflexões.

Em segundo lugar, a validação espacial via ROI depende do vetor $\mathbf{m}_k$, gerado pelo algoritmo auxiliar de Mínimos Quadrados. Isso significa que, em situações onde menos de três antenas possuem linha de visada (como em oclusões profundas), a métrica de Taxa de *Inliers* não pode ser computada momentaneamente. Por fim, a sintonia das matrizes $\mathbf{Q}$ e $\mathbf{R}$ foi realizada de forma empírica (heurística), o que, embora prático, não garante matematicamente o encontro do ótimo global do sistema.

E. Trabalhos Futuros

Com base nas limitações identificadas, abrem-se diversas frentes para trabalhos futuros:

- **Otimização Algorítmica:** Substituir a sintonia empírica por algoritmos de calibração automática *offline* (como Algoritmos Genéticos, Otimização por Enxame de Partículas ou o método de Zhang et al.) para encontrar as matrizes $\mathbf{Q}$ e $\mathbf{R}$ ótimas.
- **Visão Computacional Ativa:** Implementar a matriz predita $\mathbf{P}_{k|k-1}$ e seus respectivos limites dinâmicos (L_x, L_y) como um *gating* espacial (recorte de imagem) para sistemas de rastreamento visual baseados em câmera, reduzindo drasticamente o esforço computacional em inferências de Redes Neurais.
- **Filtros Avançados:** Comparar o EKF desenvolvido com estimadores que não exigem a linearização via Jacobi-anada, como o Filtro de Kalman *Unscented* (UKF) e o Filtro de Partículas (PF), avaliando o custo-benefício computacional em trajetórias altamente não-lineares.
- **Dados Reais:** Validar o modelo em um laboratório físico utilizando plataformas robóticas embarcadas com *beacons Ultra-Wideband* (UWB) ou sensores LiDAR.

F. Conclusão Final

O rastreamento de alvos a partir de medições inerentemente ruidosas e não-lineares continua sendo um desafio basilar na robótica móvel. Este trabalho demonstra que a eficácia do Filtro de Kalman Estendido não provém apenas da elegância de suas equações matriciais teóricas, mas sim de um profundo entendimento das propriedades físicas e estocásticas que modelam o problema de engenharia. A análise comparativa, apoiada pela ferramenta computacional desenvolvida e pelas métricas de validação espacial implementadas, fornece uma base sólida para a calibragem informada do estimador, facilitando a implementação de sistemas de navegação autônoma mais seguros, confiáveis e previsíveis.

APÊNDICE A

MATERIAL SUPLEMENTAR E FERRAMENTA DE SIMULAÇÃO

Para fins de reprodutibilidade e transparência da pesquisa, o código-fonte integral da ferramenta desenvolvida está disponível em um repositório público. O material suplementar inclui a implementação da Interface Gráfica (GUI) em Python, os algoritmos do Filtro de Kalman Estendido (EKF) e os *scripts* de geração dos ambientes virtuais.

Além do código, o repositório hospeda o conjunto completo de resultados gráficos exaustivos (todas as configurações de

parâmetros e trajetórias simuladas) que, por restrições de espaço, não foram integralmente apresentados no escopo deste artigo.

O acesso à ferramenta e aos dados suplementares pode ser realizado por meio do seguinte endereço eletrônico:

<https://github.com/seu-usuario/nome-do-repositorio>

Os leitores são encorajados a acessar o repositório [10] para executar as simulações localmente, inspecionar a sintonia fina das matrizes de covariância Q e R , e visualizar de forma interativa a dinâmica da Região de Interesse (ROI) e as elipses de incerteza do agente móvel.

REFERÊNCIAS

- [1] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [6] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [7] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [8] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [9] D. Simon, *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.