

Replicação e expansão de um simulador EKF range-only com foco no modelo PVA e avaliação via NIS e Taxa de Inliers

Saulo José Almeida Silva, *Mestrando, UFCG*

Resumo—Este trabalho replica em Python a aplicação de Falek e Kaniewski para o Filtro de Kalman Estendido (EKF) *range-only* e a expande em três frentes. O estimador emprega o modelo cinemático de Posição-Velocidade-Aceleração (PVA) no rastreamento bidimensional de alvos a partir de medições não lineares de distância. As três expansões propostas e quantificadas são: a validação em três cenários adicionais de movimento (Tangente Hiperbólica, Lemniscata e Navegação Aleatória); a avaliação estatística via *Normalized Innovation Squared* (NIS) baseada em Chen/Bar-Shalom; e a Taxa de Inliers como métrica complementar proposta neste estudo. Os resultados experimentais indicam que, mediante a parametrização adequada das matrizes de covariância de processo (Q) e de medição (R), o EKF atinge precisão submétrica (e.g., $RMSE_X = 0,17$ m) mensurada pelo Erro Quadrático Médio (RMSE) e mantém a predição de estados durante oclusões temporárias. Em condições de descalibração paramétrica, documenta-se um desacoplamento entre as métricas, evidenciando que a subestimação de R produz taxas de inliers artificialmente altas e corrompe a consistência estatística do estimador. Conclui-se que a análise conjunta do NIS e da Taxa de Inliers é indispensável para o diagnóstico preciso de falhas de sintonia, fornecendo diretrizes robustas para o projeto de sistemas de navegação e rastreamento resilientes.

Index Terms—Filtro de Kalman Estendido, Localização em Tempo Real, Posicionamento *Range-Only*, Consistência Estatística.

I. INTRODUÇÃO

O FILTRO de Kalman Estendido (EKF) aplicado ao rastreamento *range-only* lida com a linearização de modelos geométricos estritamente não lineares, configurando uma solução essencial em sistemas de navegação, multilateração aérea [1] e robótica móvel [2]–[4]. Desde o trabalho fundamental de Kalman [5], a literatura de controle e estimação idealiza formulações robustas para lidar com incertezas dinâmicas [6], [7]. Contudo, a avaliação clássica do desempenho desse estimador costuma priorizar critérios puramente geométricos e macroscópicos, como a Raiz do Erro Quadrático Médio (RMSE) [8]. A limitação dessa dependência métrica reside no mascaramento de falhas na consistência estatística interna do algoritmo, impossibilitando diagnosticar discrepâncias entre a covariância calculada e o erro real.

Essa abordagem geométrica baseia o ambiente de simulação original desenvolvido por Falek e Kaniewski [9]. Enquanto Falek e Kaniewski utilizam MATLAB com três trajetórias e foco exclusivo no RMSE e erro máximo sob modelos

variados, este artigo concentra-se na dinâmica de Posição-Velocidade-Aceleração (PVA) e amplia a análise com métricas estatísticas suplementares. A seleção restrita do modelo PVA decorre de sua capacidade estrutural em absorver acelerações instantâneas do alvo sem acumular atrasos de fase severos (*lags*) na estimativa.

O objetivo deste artigo é replicar a aplicação de Falek e Kaniewski em ambiente Python [10], restringir a análise ao modelo PVA e expandir a avaliação com NIS, Taxa de Inliers e três novos cenários. A arquitetura modular desenvolvida possibilita a geração de trajetórias analíticas e de navegação estocástica, associadas à emulação de oclusões parciais de sinal. O diagnóstico da consistência do filtro é quantificado via *Normalized Innovation Squared* (NIS), alinhado ao conceito de consistência fraca estabelecido por Chen *et al.* [11], identificando respostas operacionais de otimismo e pessimismo em cenários de descalibração proposital das matrizes de covariância do processo (Q) e medição (R), fenômeno intimamente ligado aos desafios de sintonia e identificação adaptativa discutidos na literatura recente [12]–[14].

O restante deste artigo estrutura-se da seguinte forma: a Seção II revisa os fundamentos do EKF; a Seção III equaciona os modelos cinemáticos e de observação; a Seção IV estabelece a metodologia de simulação e métricas; a Seção V analisa os dados empíricos de sintonia; e a Seção VI consolida as conclusões finais.

A. Notação e Convenções

Adota-se a seguinte convenção: escalares são representados por letras minúsculas em itálico (a), vetores por minúsculas em negrito ($\mathbf{a}$ ou $\hat{\mathbf{x}}$) e matrizes por maiúsculas em negrito ($\mathbf{A}$ ou $\mathbf{P}$). No domínio discreto, o subscrito k indica a variável no instante iterativo correspondente. Para estimativas e matrizes de covariância, a notação composta $k|k-1$ reporta os valores *a priori* (etapa de predição da dinâmica, e.g., $\hat{\mathbf{x}}_{k|k-1}$ e $\mathbf{P}_{k|k-1}$), e $k|k$ indica os valores *a posteriori* (etapa de correção estocástica após a medição geométrica, e.g., $\hat{\mathbf{x}}_{k|k}$ e $\mathbf{P}_{k|k}$).

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo estabelece a fundamentação matemática do estimador estruturada em três eixos: a representação probabilística de estados, o formalismo do Filtro de Kalman Estendido (EKF) para rastreamento por distância e as métricas de consistência residual.

S. J. A. Silva é mestrando no Programa de Pós-Graduação em Engenharia Elétrica (PPgEE) da Universidade Federal de Campina Grande (UFCG), Campina Grande, PB, Brasil. E-mail: saulo.jose.silva@ee.ufcg.edu.br.

A. Representação do Estado Probabilístico

A modelagem de estados sob incertezas estocásticas baseia-se na formulação de Thrun, Burgard e Fox [2]. O estado do alvo é mapeado pela densidade de probabilidade condicional denominada crença (*belief*):

$$bel(\mathbf{x}_k) = P(\mathbf{x}_k \mid \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (1)$$

onde $\mathbf{x}_k$ representa o vetor de estados no instante discreto k , $\mathbf{z}_{1:k}$ o histórico de medições e $\mathbf{u}_{1:k}$ as ações de controle.

Sob a suposição de Markov e premissas de um sistema Gauss-Markov [7], os ruídos associados são gaussianos, brancos e de média nula. O rastreamento de $bel(\mathbf{x}_k)$ processa-se recursivamente através do vetor de médias ($\hat{\mathbf{x}}$) e da matriz de covariância do erro ($\mathbf{P}$) [8].

B. O Filtro de Kalman Estendido em Observações Range-Only

A formulação matemática do Filtro de Kalman Linear padrão é omitida nesta seção por se tratar de fundamentação consolidada em literatura de controle ótimo [6], [7]. Para o problema de rastreamento com restrições geométricas não lineares (*range-only tracking*), aplica-se o EKF [2], definido pelas equações discretas de transição e observação:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \epsilon_k \quad \text{e} \quad \mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (2)$$

em que $\mathbf{A}_k$ representa a matriz discreta de transição de estados, $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ o ruído de processo e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$ o ruído de medição. A função $h(\mathbf{x}_k)$ computa a distância euclidiana não linear entre o alvo e as âncoras fixas.

A aproximação linear do modelo de medição é obtida via matriz Jacobiana calculada em torno da estimativa predita:

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (3)$$

O fluxo operacional do estimador segue a sequência detalhada no Algoritmo 1. Na ocorrência de oclusões de sinal, o vetor de medições $\mathbf{z}_k$ torna-se indisponível; o algoritmo suspende a execução da etapa de correção (linhas 3 a 8), definindo as estimativas finais diretamente como os valores preditos: $\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1}$ e $\mathbf{P}_{k|k} = \mathbf{P}_{k|k-1}$. Esse procedimento configura a propagação temporária em malha aberta orientada por $\mathbf{Q}_k$.

Algorithm 1 Ciclo de Recursão do EKF

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{z}_k$

Etapa de Predição:

- 1: $\hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1}$
- 2: $\mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$

Etapa de Correção (Se $\mathbf{z}_k$ disponível):

- 3: $\mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$
- 4: $\boldsymbol{\nu}_k \leftarrow \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1})$
- 5: $\mathbf{S}_k \leftarrow \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k$
- 6: $\mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T \mathbf{S}_k^{-1}$
- 7: $\hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \boldsymbol{\nu}_k$
- 8: $\mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1}$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

C. Métricas de Desempenho e Consistência Estatística

A acurácia do vetor espacial em relação ao *Ground Truth* ($\mathbf{x}_k$) sobre um horizonte de N amostras é quantificada pela Raiz do Erro Quadrático Médio (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (4)$$

A avaliação da consistência estatística do EKF é realizada por meio da métrica clássica *Normalized Innovation Squared* (NIS), amplamente empregada na literatura para verificar se a inovação observada é consistente com a covariância de inovação prevista pelo filtro. O NIS é definido pela Equação 5:

$$\epsilon_k = \boldsymbol{\nu}_k^T \mathbf{S}_k^{-1} \boldsymbol{\nu}_k \quad (5)$$

Neste trabalho, adota-se a interpretação do NIS apresentada por Chen et al. [11], que utiliza essa métrica clássica como critério para avaliar a consistência estatística de filtros de Kalman durante o processo de sintonia automática. Sob a hipótese nula de correta sintonia do estimador, o vetor de inovação $\boldsymbol{\nu}_k$ é um processo gaussiano branco de média nula, o que implica que a variável escalar ϵ_k segue uma distribuição qui-quadrado com m graus de liberdade ($\epsilon_k \sim \chi_m^2$), em que m denota a dimensão do vetor de observações $\mathbf{z}_k$ [8].

Do formalismo de Chen et al. [11], decorre que o valor esperado do NIS sob condições nominais é restrito à dimensão do espaço de medição, obedecendo a:

$$E[\epsilon_k] = m \quad (6)$$

Os limites críticos de aceitação estatística para validação da hipótese nula são determinados por meio de um teste bicaudal associado a um nível de significância α . Flutuações sistemáticas de ϵ_k fora do intervalo de confiança χ_m^2 diagnosticam desvios de subestimação (otimismo) ou superestimação (pessimismo) da covariância do erro do filtro. Assim, neste trabalho, o NIS é empregado exclusivamente como ferramenta de diagnóstico da consistência estatística do EKF, não sendo implementado o procedimento de otimização proposto por Chen et al. [11].

III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Este capítulo apresenta a modelagem cinemática e geométrica aplicadas ao rastreamento bidimensional baseado em medições exclusivas de distância (*range-only tracking*) [8]. A infraestrutura matemática toma como referência a configuração de quatro estações de base de Fałek e Kaniewski [9], expandindo-a para simulações sob dinâmicas aceleradas e regimes de restrição sensorial.

O modelo de Posição-Velocidade-Aceleração (PVA) é adotado para incluir as componentes de aceleração diretamente no vetor de estados, permitindo o rastreamento em trajetórias com dinâmicas variáveis. O modelo de Posição-Velocidade (PV), presente no trabalho de referência, é omitido devido à sua restrição a perfis de velocidade constante, o que induziria a erros de atraso de fase frente às manobras aceleradas propostas.

A. Fronteiras do Escopo: Elementos Herdados vs. Expandidos

O delineamento estrutural do ambiente de testes obedece à seguinte divisão:

- **Elementos Herdados:** Geometria da arena contendo quatro estações de base fixas, modelo matemático não linear de observação *range-only* e a estrutura das matrizes de sistema ($\mathbf{A}_k$, $\mathbf{Q}_c$, $\mathbf{R}_k$) provenientes do artigo original [9].
- **Elementos Expandidos:** Restrição exclusiva ao modelo cinemático PVA, inclusão de três novos cenários de movimento (Tanh, Lemniscata e Navegação Aleatória), emulação de oclusão temporal cíclica de sinal e avaliação estatística via NIS e Taxa de Inliers.

B. Descrição do Problema

O sistema consiste na estimativa da trajetória de um agente móvel em um plano bidimensional monitorado por $M = 4$ âncoras com coordenadas conhecidas $\mathbf{p}_i = [X_i, Y_i]^T$, para $i = 1, \dots, 4$, conforme disposto na Figura 1. O estimador processa as leituras escalares de distância ruidosas e calcula a posição cartesiana, velocidade e aceleração instantâneas do alvo.




Figura 1: Representação geométrica do sistema de posicionamento: o agente móvel no espaço bidimensional e os raios de medição (*range-only*) oriundos das quatro estações base fixas nos vértices da arena.

C. Modelo Cinemático de Processo (Espaço de Estados PVA)

No espaço de estados discretizado, o vetor de estados é definido por $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$. Sob a premissa de aceleração constante no intervalo de amostragem Δt ,

a transição determinística é descrita pela matriz $\mathbf{A}_k$ herdada do artigo original [9]:

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (7)$$

O ruído de processo contínuo é parametrizado pela matriz de densidade espectral de potência diagonal $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$, idêntica à formulação adotada no trabalho-base [9]. A matriz de covariância discreta do ruído de processo ($\mathbf{Q}_k$) mapeada no estimador é obtida a partir da integração por convolução estocástica aplicada sobre $\mathbf{Q}_c$, cujo desenvolvimento analítico completo e a estrutura matricial resultante estão alocados no Apêndice B.

D. Modelo de Observação e Geometria das Estações Base

O vetor de medições recebido a cada período é composto por $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$. O mapeamento geométrico não linear entre o vetor de estados e a distância escalar até cada âncora fixa i é determinado por:

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (8)$$

A matriz Jacobiana correspondente $\mathbf{H}_k \in \mathbb{R}^{4 \times 6}$ assume a seguinte estrutura linearizada:

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (9)$$

A variância transdutiva instrumental é parametrizada pela matriz diagonal de covariância de medição $\mathbf{R}_k = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$ adotada do artigo-base [9].

E. Cenário de Desafio: Modelagem de Oclusão Temporal


O regime de restrição sensorial impõe a indisponibilidade completa de dados de medição em intervalos discretos definidos por $k \in [k_{\text{start}}, k_{\text{end}}]$. A modelagem formal do vetor de observações e da etapa de correção sob oclusão é descrita por:

$$\mathbf{z}_k = \emptyset \implies \mathbf{K}_k = \mathbf{0} \quad (10)$$

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} = \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} \quad (11)$$

$$\mathbf{P}_{k|k} = \mathbf{P}_{k|k-1} = \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k \quad (12)$$

A suspensão da atualização propaga a incerteza do filtro em malha aberta, gerando a expansão temporal contínua da matriz $\mathbf{P}_{k|k}$ motivada pela acumulação aditiva de $\mathbf{Q}_k$, conforme ilustrado na Figura 2.



(a) Operação nominal: predição e atualização. (b) Oclusão: trajetória 1 (predição pura). (c) Oclusão: trajetória 2 (predição pura).

Figura 2: Representação visual da incerteza do EKF (ROI dinâmica): a elipse em cinza indica a incerteza predita ($\mathbf{P}_{k|k-1}$), enquanto a verde representa a incerteza atualizada após a correção ($\mathbf{P}_{k|k}$). (a) Operação normal com leituras contínuas; (b) e (c) perda de precisão e expansão da incerteza causadas pela interrupção do sinal dos sensores em diferentes trajetórias.

IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo apresenta o arranjo experimental, os parâmetros das simulações e os critérios estatísticos usados para avaliar o estimador. O objetivo deste trabalho não é necessariamente superar os resultados do artigo de Fałek e Kaniewski [9], visto que a pesquisa original realizava uma análise mais subjetiva. Em vez disso, propõe-se um estudo puramente objetivo utilizando novos valores e condições de teste. O contraste entre as configurações é sintetizado na Tabela I.

O desenho experimental processa-se em três etapas sequenciais: a geração das trajetórias de referência (*Ground Truth*), a aplicação dos cenários sob sintonias nominais e degradadas, e a verificação estatística dos resíduos. O ambiente de testes compreende três trajetórias herdadas do artigo-base (círculo, quadrado e curva complexa) e três trajetórias adicionadas nesta pesquisa (Tanh, Lemniscata e Navegação Aleatória).

A. Síntese Cinemática das Trajetórias de Referência

A avaliação de exatidão do EKF baseia-se na comparação vetorial direta com o *Ground Truth* estruturado em $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$. O motor de simulação divide a geração cinemática em duas categorias operacionais:

- **Curvas paramétricas analíticas (Determinísticas):** Perfis geométricos contínuos em que as funções de posição $\mathbf{p}(t)$ são diferenciadas analiticamente em relação ao tempo para a obtenção exata de velocidade $\mathbf{v}(t) = \dot{\mathbf{p}}(t)$ e aceleração $\mathbf{a}(t) = \ddot{\mathbf{p}}(t)$, eliminando erros de discretização numérica.
- **Modelos numéricos comportamentais (Estocásticos):** Perfis que incorporam variações pseudoaleatórias de direção e velocidade, com cálculo de aceleração por diferenciação finita discreta.

O conjunto das trajetórias executadas está consolidado na Figura 3. A execução matemática dos perfis determinísticos e estocásticos segue a lógica descrita nos Algoritmos 2 e 3, respectivamente.

Algorithm 2 Geração de Trajetórias Paramétricas Analíticas

Require: Tempo contínuo $t_k = k\Delta t$, Parâmetros geométricos (Amplitude A , Frequência ω)

```

1: for cada instante  $k$  do
2:   if Perfil = Círculo then
3:      $\mathbf{p}_k \leftarrow [c_x + R \cos(\omega t_k), c_y + R \sin(\omega t_k)]^T$ 
4:   else if Perfil = Curva Complexa then
5:      $\mathbf{p}_k \leftarrow [v_x t_k, c_y + A \tanh(S \cdot t_k)]^T$ 
6:   else if Perfil = Lemniscata then
7:      $\mathbf{p}_k \leftarrow [c_x + A \sin(\omega t_k), c_y + \frac{A}{2} \sin(2\omega t_k)]^T$ 
8:   end if
9:    $\mathbf{v}_k \leftarrow \mathbf{v}_{analítica}(t_k)$ 
10:   $\mathbf{a}_k \leftarrow \mathbf{a}_{analítica}(t_k)$ 
11:   $\mathbf{x}_k \leftarrow [\mathbf{p}_k^T, \mathbf{v}_k^T, \mathbf{a}_k^T]^T$ 
12: end for

```

Ensure: Sequência de estados reais $\mathbf{x}_{1:N}$

B. Cenários de Simulação e Estratégia de Sintonia

A campanha experimental divide-se em 6 cenários cinemáticos. Os três primeiros são reproduzidos da formulação de Fałek e Kaniewski [9]: Cenário 1 (Círculo), Cenário 2 (Quadrado) e Cenário 3 (Curva Complexa). Os três cenários subsequentes constituem adições deste trabalho: Cenário 4 (Tanh), Cenário 5 (Lemniscata) e Cenário 6 (Navegação Aleatória com protocolo de oclusão temporal).

Cada cenário é submetido a duas condições de parametrização estocástica:

- 1) **Condição Sintonizada (Filtro Calibrado):** Configuração nominal em que as matrizes internas do estimador refletem as variâncias reais do processo e dos sensores. Dado o ruído instrumental de desvio padrão $\sigma = 0,30$ m, fixa-se a matriz de covariância da medição em $\mathbf{R}_k = 0,09\mathbf{I}_4$. A matriz de ruído de processo foi definida empiricamente nesta pesquisa como $\mathbf{Q} = 0,64\mathbf{I}_6$. Essa escolha paramétrica foi determinada a partir de testes preliminares de sintonia para adequar o filtro à dinâmica do modelo PVA adotado.
- 2) **Condição Não Sintonizada (Filtro Descalibrado):**

Tabela I: Comparação do Escopo Experimental da Pesquisa

Dimensão	Falek e Kaniewski [9]	Este Trabalho
Perfis de Trajetória	3 cenários (Círculo, Quadrado, Curva Complexa)	6 cenários (3 originais e 3 adicionais)
Ruído de Medição (σ)	1,0 m	0,30 m e descalibração estocástica
Métricas de Avaliação	RMSE e Erro Máximo	RMSE, Erro Médio, NIS Médio e Taxa de Inliers
Modelos Cinemáticos	PV e PVA	Foco exclusivo no modelo PVA
Posição das Torres	Configuração simétrica original	Nova disposição com coordenadas diferentes
Ambiente Computacional	MATLAB	Python (NumPy)




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos (Apenas ilustrativa).

Inserção intencional de desvios por superestimação (Sup.) ou subestimação (Sub.) para avaliar a sensibilidade adaptativa do filtro sob assimetria estocástica.

A Tabela II consolida as variáveis cinemáticas, as coordenadas das balizas fixas e os parâmetros de calibração das matrizes do EKF para os seis cenários descritos.

C. Configuração do Estimador e Modelagem do Ruído

O vetor de observações $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$ processado pelo estimador é gerado pela adição de uma perturbação gaussiana branca de média nula à distância euclidiana exata calculada a partir do *Ground Truth*:

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (13)$$

O EKF opera de forma restrita sobre as distâncias não lineares puras de $\mathbf{z}_k$. Um bloco paralelo executa uma rotina assíncrona de multilateração por Mínimos Quadrados para gerar coordenadas cartesianas observadas $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$,

utilizadas exclusivamente para fins de diagnóstico externo. A modelagem estocástica preserva os princípios de Falek e Kaniewski [9] e Bar-Shalom *et al.* [8], com parametrização estendida para os novos perfis cinemáticos.

D. Ambiente Computacional e Infraestrutura de Simulação

As ferramentas computacionais e os códigos desenvolvidos para esta pesquisa estão hospedados no repositório do projeto ¹. As simulações foram executadas em linguagem Python (versão 3.10), utilizando a biblioteca NumPy para a computação matricial vetorizada do estimador. O fluxo de dados entre as rotinas de geração cinemática, injeção de ruído e as malhas operacionais do EKF segue a topologia estrutural mapeada no diagrama de arquitetura apresentado na Figura 4.

E. Métodos de Avaliação e Consistência

A acurácia espacial é quantificada pela Raiz do Erro Quadrático Médio (RMSE) nos eixos X e Y , complement-

¹<https://github.com/SauloJose/PASKalmanTraj>

Tabela II: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Círculo	Quadrado	Tanh	Lemniscata	Nav. Aleatória	Nav. Aleatória com Oclusão
Origem	<i>Fatek</i> [9]	<i>Fatek</i> [9]	<i>Fatek</i> [9]	Proposto	Proposto	Proposto
Movimento	$v = 10,0$ m/s $r = 30,0$ m	$v = 10$ m/s $L = 40,0$ m	$A_y = 20,0$ m $v = 10,0$ m/s	$v = 10,0$ m/s $A = 35,0$ m	$v_0 = 8,0$ m/s $\epsilon_v = 0,5$ m/s	$v = 5,0$ m/s Taxa detecção: 90% (10% de oclusão)
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Posição das Torres (x,y)	$B_1[0,0]; B_2[100,0]; B_3[100,100]; B_4[0,100]$					
Tempo de Simulação (s)	40					
Taxa de Quadros (FPS)	30					
Semente Aleatória (<i>Seed</i>)	42					
Ruído nas Torres (σ)	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$
Matriz Processo $Q_{6 \times 6}$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1I_4$ (Sup.)	$0,1I_4$ (Sup.)	$0,01I_4$ (Sub.)	$0,09I_4$	$0,01I_4$ (Sub.)	$0,01I_4$ (Sub.)
Matriz Processo $Q_{6 \times 6}$	$0,01I_6$ (Sub.)	$0,01I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,3I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,05I_6$ (Sub.)

Nota: I_n representa a matriz identidade de dimensão $n \times n$. Na condição sintonizada, a matriz de covariância R reflete a variância teórica do ruído físico injetado ($R = \sigma^2 I_4 = 0,09I_4$). Nos cenários não sintonizados, as descalibrações por superestimação (Sup.) e subestimação (Sub.) atuam como estressores das malhas de ganho. No Cenário 4 (Não Sintonizado), R foi mantido nominal para isolar o efeito da subestimação de Q .

Algorithm 3 Geração de Navegação Dinâmica Aleatória com Máscara de Oclusão

Require: Vetor posição central $\mathbf{p}_c$, Limite da arena $R_{\max}$, Ruído cinemático w , Flag *ModoOclusão*

```

1: for cada instante  $k$  do
2:   if Distância percorrida  $> D_{\min}$  then
3:     if  $\|\mathbf{p}_{k-1} - \mathbf{p}_c\| > R_{\max}$  then
4:        $\theta_{\text{alvo}} \leftarrow \text{Angulo}(\mathbf{p}_c - \mathbf{p}_{k-1})$ 
5:     else
6:        $\theta_{\text{alvo}} \leftarrow \theta_{k-1} + \mathcal{U}(-\frac{\pi}{3}, \frac{\pi}{3})$ 
7:     end if
8:      $v_{\text{alvo}} \leftarrow v_{\text{base}} + \mathcal{U}(-w, w)$ 
9:   end if
10:   $\theta_k \leftarrow \text{SuavizarTransição}(\theta_{k-1}, \theta_{\text{alvo}})$ 
11:   $v_k \leftarrow \text{SuavizarTransição}(v_{k-1}, v_{\text{alvo}})$ 
12:   $\mathbf{v}_k \leftarrow [v_k \cos(\theta_k), v_k \sin(\theta_k)]^T$ 
13:   $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$ 
14:   $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$ 
15:  if ModoOclusão = Verdadeiro e  $k \in [k_{\text{start}}, k_{\text{end}}]$  then
16:     $\text{MascaraVisibilidade}(k) \leftarrow \text{Falso}$ 
17:  else
18:     $\text{MascaraVisibilidade}(k) \leftarrow \text{Verdadeiro}$ 
19:  end if
20: end for

```

Ensure: Estados reais $\mathbf{x}_{1:N}$ e vetor de visibilidade do cenário

tada pelo Erro Médio (ME) com sinal para identificação de tendências sistemáticas de vies.

A consistência estocástica do estimador é avaliada por meio da métrica *Normalized Innovation Squared* (NIS). Conforme




Figura 4: Diagrama da arquitetura de software da aplicação de simulação, destacando o fluxo de dados entre o gerador de trajetórias, o estimador de estados e a camada de aplicação.

formulado por Chen *et al.* [11], o teste do NIS monitora a consistência estatística do filtro baseando-se estritamente nas sequências de inovações residuais captadas pelos sensores, executando o diagnóstico de consistência de forma independente do acesso direto ao estado real do sistema (*ground truth*).

A Taxa de Inliers constitui uma métrica complementar adaptada para este ambiente de simulação. Inspirada na interpretação geométrica das regiões de confiança descritas por Thrun *et al.* [2] e Bar-Shalom *et al.* [8], ela foi implementada neste trabalho para avaliar a consistência espacial das estimativas em relação ao Ground Truth. Por depender do conhecimento da trajetória verdadeira, sua utilização restringe-se ao ambiente simulado, sendo empregada como complemento às métricas RMSE e NIS.

1) *Validação da Crença do Estimador (Inlier Rate)*: A Taxa de Inliers contabiliza a proporção de quadros em que o estado real permanece contido no elipsoide de incerteza da posição *a posteriori* $\mathbf{P}_{\text{pos}} = \mathbf{P}_{k|k}^{(1:2,1:2)}$. Adotando um nível de significância de 95% (ou seja, assumindo uma taxa máxima de erro aceitável de 5%), definimos o vetor de erro real por $\tilde{\mathbf{p}}_k = [x_{GT,k} - \hat{x}_{k|k}, y_{GT,k} - \hat{y}_{k|k}]^T$. O quadro é classificado como um *inlier* caso obedeça à restrição quadrática:

$$\tilde{\mathbf{p}}_k^T (\mathbf{P}_{\text{pos}})^{-1} \tilde{\mathbf{p}}_k \leq 5,991 \quad (14)$$

onde 5,991 denota o valor crítico tabelado da distribuição Qui-Quadrado (χ^2) com 2 graus de liberdade para o nível de confiança escolhido.




Figura 5: Representação da métrica de *inliers*. A elipse validada estatisticamente a convergência frente ao Ground Truth, enquanto a janela retangular delimita a incerteza para fins de visualização na GUI.

Para a projeção geométrica, os desvios-padrão marginais teóricos são dados por:

$$\sigma_{x,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(1,1)})} \quad (15)$$

$$\sigma_{y,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(2,2)})} \quad (16)$$

Os limites semi-eixais da janela (L_x, L_y) incorporam uma constante de salvaguarda inferior $\tau_{\min}$ para evitar o colapso numérico da região de incerteza:

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{filt}}) \quad (17)$$

$$L_y = \max(\tau_{\min}, 3\sigma_{y,\text{filt}}) \quad (18)$$

A inter-relação espacial entre o elipsoide probabilístico e a janela de delimitação ortogonal está representada na Figura 5.

2) *Análise de Estabilidade Estatística via Limites de Confiança do NIS*: O teste do NIS opera sob um intervalo de confiança bicaudal baseado em um nível de significância de 95%, cujos graus de liberdade dependem do número de balizas ativas em cada passo k . Sob operação nominal com 4 graus de liberdade ($DOF = 4$), as fronteiras críticas da distribuição qui-quadrado estabelecem o intervalo fixo de $[0,484; 11,143]$.

Com base nesses limiares, o regime do estimador é classificado de acordo com três perfis:

- **Filtro Consistente**: O valor de NIS se mantém concentrado dentro do intervalo de confiança estabelecido, validando a exatidão da matriz de covariância calculada.
- **Filtro Otimista (Subestimação do Erro)**: O NIS excede de forma sistemática o limite crítico superior (11,143), indicando que os erros reais superam a incerteza computada em $\mathbf{P}_k$.
- **Filtro Pessimista (Superestimação do Erro)**: O NIS decai abaixo da fronteira crítica inferior (0,484), indicando uma expansão injustificada das matrizes de incerteza e consequente lentidão na resposta dinâmica do filtro.

V. RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados experimentais do Filtro de Kalman Estendido (EKF) nos seis cenários definidos na Seção IV. A avaliação utiliza métricas de acurácia geométrica (RMSE e Erro Máximo), consistência estatística (NIS) e validação espacial (Taxa de *Inliers*). Para analisar o comportamento sob perturbações, os testes comparam o EKF com parâmetros calibrados em relação a configurações descalibradas.

A Tabela III consolida as métricas obtidas. Devido a limites de paginação, os gráficos temporais do NIS e os painéis com as trajetórias completas foram inseridos no Apêndice C. O código do simulador e os dados gerados estão disponíveis em [10].

A. Análise Comparativa com o Trabalho-Base

Este estudo compartilha com a referência de Fałek e Kaniowski [9] a mesma formulação: o rastreamento bidimensional de alvos por quatro balizas fixas com base em medições não lineares de distância (*range-only*).

Contudo, uma comparação numérica direta entre os erros absolutos não é metodologicamente viável. O artigo original testa o filtro sob um ruído de medição severo ($\sigma = 1,0$ m), enquanto este trabalho adota uma condição nominal de $\sigma = 0,30$ m e uma sintonia de matrizes ajustada ao modelo PVA. Assim, as diferenças nos valores absolutos refletem as condições de contorno de cada teste, e não a superioridade matemática de um algoritmo sobre o outro.

A contribuição deste trabalho está na expansão diagnóstica e de cenários. A pesquisa original avaliou o desempenho apenas pelo erro de posição geométrico. Este estudo introduz o teste estatístico NIS e a Taxa de *Inliers* para verificar a integridade estocástica do filtro. Além disso, foram incluídos três novos cenários dinâmicos: a curva de Lemniscata, a Navegação Aleatória livre e a Navegação Aleatória com perda temporária de sinal.

B. Interface Gráfica e Ambiente de Simulação

A Figura 6 mostra o simulador desenvolvido. A interface gráfica exibe o mapa da arena em tempo real, a telemetria do alvo em relação à trajetória real (*ground truth*) e os gráficos temporais do RMSE e do NIS. O ambiente permite modificar os valores de $\mathbf{Q}$ e $\mathbf{R}$ para avaliar visualmente o efeito da calibração sobre as elipses de incerteza do filtro.

Tabela III: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	RMSE _x [m]	RMSE _y [m]	E _{max} [m]	μ_x [m]	NIS	NIS ∈ IC [%]	TD [%]	TI [%]
CONDIÇÃO SINTONIZADA (Q = 0,64I₆; R = 0,09I₄)								
Cenário 1	0,11	0,16	0,64	+0,01	3,39	96,33	100,00	100,00
Cenário 2	0,13	0,18	0,58	0,00	3,86	95,84	100,00	96,88
Cenário 3	0,12	0,14	0,58	+0,00	3,34	96,58	100,00	100,00
Cenário 4	0,11	0,15	0,58	+0,01	3,34	97,17	100,00	100,00
Cenário 5	0,11	0,16	0,57	+0,00	3,49	96,58	100,00	100,00
Cenário 6	0,17	0,34	2,62	+0,01	3,40	95,19	90,00	100,00
CONDIÇÃO NÃO SINTONIZADA (Parâmetros Descalibrados)								
Cenário 1	0,23	0,34	0,75	+0,01	6,76	80,25	100,00	10,08
Cenário 2	0,60	0,82	2,24	-0,02	24,07	49,48	100,00	28,07
Cenário 3	0,16	0,20	0,79	+0,00	23,85	26,75	100,00	97,25
Cenário 4	0,14	0,20	0,74	+0,01	25,50	22,67	100,00	93,83
Cenário 5	0,15	0,21	0,73	+0,00	24,14	26,08	100,00	96,25
Cenário 6	0,17	0,33	2,62	+0,01	31,67	15,56	90,00	71,76

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limites bicaudais do NIS a 95% de confiança para 4 G.L. são [0, 484; 11, 143]. TD: Taxa de Detecção; TI: Taxa de *Inliers*.




Figura 6: Ambiente gráfico desenvolvido em Python. O painel central exibe a cinemática do alvo, ladeado pelos controles de simulação à esquerda e gráficos de monitoramento temporal à direita.

C. Análise de Acurácia Posicional e Distribuição de Erros

A parametrização correta das matrizes do EKF reduziu o impacto do ruído nos testes. Como indicado na Tabela III, a configuração sintonizada manteve o RMSE_x e o RMSE_y entre 0,11 m e 0,18 m nos cenários com visibilidade contínua. No Cenário 2 (Trajetória Quadrada), que apresenta mudanças bruscas de direção, o erro máximo com calibração nominal foi de 0,58 m. Sob os mesmos testes dinâmicos, a descalibração ($Q = 0,01$; $R = 0,10$) causou atrasos nas estimativas, elevando o RMSE_y para 0,82 m e o erro máximo para 2,24 m.


Os resultados mostram que o filtro responde aos parâmetros conforme a formulação matemática estável do modelo PVA. Diante do ruído de simulação adotado ($\sigma = 0,30$ m), o filtro seguiu a trajetória real sem divergências. A aproximação com

os dados do artigo-base [9] confirma a convergência qualitativa do algoritmo para trajetórias com acelerações contínuas ou discretas.


A distribuição desses desvios é apresentada nos histogramas da Figura 7. Na condição sintonizada, os erros se aproximam de uma distribuição gaussiana bivariada com média próxima a zero ($\mu_x \approx 0,001$ m). A descalibração do filtro gera assimetrias nos gráficos e aumenta o tamanho das caudas dos histogramas.

D. Consistência Estatística e Monitoramento do NIS

A consistência entre a matriz de covariância teórica e os resíduos reais foi monitorada pela métrica NIS. Utilizando os critérios de Chen et al. e Bar-Shalom [11], [12], a res-



(a) Condição Sintonizada



(b) Condição Não Sintonizada

Figura 7: Histogramas e dispersão dos erros de previsão (Cenário 2). Em (a), a convergência normal de um filtro calibrado. Em (b), o desajuste de parâmetros gera dispersões irregulares e vieses.

posta estatística é definida por sua relação com os limites da distribuição qui-quadrado ($\chi_{0,975,4}^2 = 11,143$). Valores acima do limite superior indicam subestimação da covariância teórica dos estados ($\mathbf{P}_{k|k}$), o que define um regime **otimista**. Concentrações abaixo do limite inferior ($\chi_{0,025,4}^2 = 0,484$) caracterizam uma superestimação das matrizes, definindo um comportamento **pessimista**.

Na condição sintonizada, o EKF manteve-se consistente. A média temporal do NIS ($\overline{NIS}$) variou entre 3,34 e 3,86, valores próximos ao valor teórico esperado para quatro graus de liberdade ($\mathbb{E}[NIS] = 4,0$). O percentual de amostras dentro do intervalo de confiança superou 95% nos cenários com visibilidade direta, confirmando que o estimador modela corretamente a incerteza física do sistema.

A alteração incorreta dos parâmetros comprometeu a consistência estocástica. Nas configurações em que a matriz de covariância de medição foi artificialmente reduzida ($R = 0,01$ nos Cenários 3 a 6), o filtro operou em regime **otimista** conforme definido em [11]. Ao subestimar o ruído, o filtro dá peso excessivo às medições ruidosas. Esse comportamento fez o $\overline{NIS}$ subir para 31,67 no Cenário 6 e reduziu a taxa de acerto no intervalo de confiança para a faixa entre 15,56% e 26,75%. O histórico temporal da Figura 8 ilustra essa transição.

E. Região de Confiança e Taxa de Inliers

A Taxa de Inliers (TI), baseada na distância de Mahalanobis e na estatística NEES [11], avalia a consistência espacial do filtro. Enquanto o RMSE mede o erro geométrico em metros e o NIS analisa os resíduos nos sensores, a TI indica a fração




Figura 8: Comportamento temporal da métrica NIS. A calibração adequada mantém o parâmetro próximo à média teórica (4, 0) e contido nos limites estatísticos.

de tempo em que a trajetória real permanece contida na elipse de incerteza calculada por $\mathbf{P}_{k|k}$. O uso dessas três métricas expõe falhas de consistência que o erro geométrico (RMSE) sozinho não detecta.

Nos testes com calibração nominal, a conformidade espacial foi uniforme. A TI manteve-se em 100,00% na maioria das trajetórias, caindo para 96,88% no Cenário 2 devido às variações inerciais nas curvas do quadrado. Esse resultado valida que os limites probabilísticos calculados pelo EKF cobrem a posição real do alvo.

O uso conjunto das métricas fica evidente na descalibração do Cenário 1. Nessa condição, o RMSE registrou erros contidos (0,23 m em X e 0,34 m em Y), valores próximos ao ruído base que indicariam um rastreamento aceitável. No entanto, a queda da TI para apenas 10,08% revela uma falha de consistência: embora numericamente próximo ao alvo, a elipse de incerteza encolheu excessivamente. O filtro opera com uma falsa certeza matemática, gerando regiões de incerteza sem correspondência física com o erro real.

F. Resposta Transitória sob Oclusão (Cenário 6)

O Cenário 6 avaliou o comportamento do estimador durante interrupções programadas nas medições, operando com uma Taxa de Detecção (TD) de 90% (com 10% de oclusão). Durante as falhas de sinal (Figura 9), o EKF propaga as estimativas em malha aberta. Essa etapa depende apenas da previsão do modelo cinemático PVA, utilizando a velocidade e aceleração calculadas antes da perda de sinal.

A falta temporária de medições aumentou a matriz de covariância de erro, refletindo o ganho de incerteza do sistema. Esse efeito elevou o erro de posição, cujo valor máximo atingiu 2,62 m no centro da oclusão. Contudo, a margem de incerteza definida na matriz de ruído de processo $\mathbf{Q}$ impediu o travamento numérico do filtro. Ao recuperar o sinal das balizas, o estimador retomou a etapa de correção, reduzindo os desvios de forma estável e resultando em um RMSE final de 0,17 m em X e 0,34 m em Y.

VI. CONCLUSÃO

Este trabalho apresentou a replicação da aplicação *range-only* de Falek e Kaniewski em ambiente Python com foco exclusivo no modelo Posição-Velocidade-Aceleração (PVA),




Figura 9: Recorte do Cenário 6 sob oclusão temporária. O EKF propaga a cinemática PVA em malha aberta, demonstrando resiliência preditiva sem divergência crítica.

expandindo o escopo original por meio de novos cenários experimentais e métricas estatísticas de consistência. A análise avaliou o comportamento do Filtro de Kalman Estendido (EKF) no rastreamento 2D sob medições não lineares. Em condições nominais de sintonia ($\mathbf{Q} = 0,64\mathbf{I}_6$ e $\mathbf{R} = 0,09\mathbf{I}_4$), o estimador manteve estabilidade geométrica com RMSE submétrico e consistência estocástica com o indicador NIS contido no intervalo de confiança em mais de 95% das amostras, demonstrando resiliência preditiva durante janelas de oclusão de sinal.

Os ensaios sob descalibração paramétrica intencional evidenciaram o desacoplamento entre a acurácia geométrica e a coerência estocástica. A subestimação da covariância de processo ($\mathbf{Q} = 0,01\mathbf{I}_6$) induziu rigidez dinâmica no filtro, reduzindo a Taxa de *Inliers* para o patamar de 10% devido à contração artificial da elipse de incerteza. Alternativamente, a subestimação da covariância de medição ($\mathbf{R} = 0,01\mathbf{I}_4$) forçou o filtro a rastrear componentes de ruído de alta frequência. Embora essa condição resulte em valores baixos de RMSE e mantenha a Taxa de *Inliers* acima de 93%, o estimador opera em regime estatisticamente otimista, anomalia identificada unicamente pela extrapolação sistemática do limite superior qui-quadrado ($\chi^2_{0.975,4} = 11,143$).

A. Contribuições Metodológicas

As contribuições decorrentes desta expansão metodológica dividem-se em três eixos factuais:

- **Contribuição de Implementação (Python):** Desenvolvimento de um ambiente computacional modular e de código aberto baseado na biblioteca NumPy, integrado a uma interface gráfica para parametrização direta de matrizes estocásticas e projeção visual instantânea das elipses de incerteza da Região de Interesse (ROI).

- **Contribuição Experimental (+3 Trajetórias):** Expansão do banco de testes original a partir da inclusão de três cenários dinâmicos adicionais: perfil geométrico em Lemniscata (reversão de curvatura), modelo de Navegação Aleatória contínua e Navegação Aleatória sob intermitência de sinal (occlusão temporária).
- **Contribuição de Avaliação (NIS e Taxa de *Inliers*):** Introdução de ferramentas de auditoria estatística independentes da trajetória de referência. Neste artigo, foi implementada a Taxa de *Inliers* como métrica complementar de validação espacial do *belief*, mapeando a matriz de covariância abstrata em limites de probabilidade geometricamente interpretáveis na arena de teste.

O ganho real frente ao trabalho-base de Fałek e Kaniowski [9] reside estritamente no aumento do escopo analítico-estatístico. Enquanto a abordagem original limitou-se à avaliação geométrica por meio do RMSE e do erro máximo, os resultados experimentais deste estudo demonstraram que tais métricas isoladas são insuficientes para garantir a consistência probabilística do estimador. A aplicação sistemática do teste NIS e da Taxa de *Inliers* resolve essa limitação metodológica, fornecendo critérios de integridade estocástica capazes de diagnosticar o desalinhamento paramétrico de covariâncias.

B. Limitações do Estudo e Trabalhos Futuros

As limitações identificadas nesta etapa concentram-se na modelagem simplificada de ruídos cinemáticos e de leitura como processos estritamente gaussianos, desconsiderando efeitos de multicaminho (*multipath*) e condições de não-linha-de-visada (NLOS). Adicionalmente, o processo de calibração das matrizes $\mathbf{Q}$ e $\mathbf{R}$ permaneceu restrito ao método empírico por tentativa e erro.

Para a continuidade da pesquisa, definem-se os seguintes passos técnicos de desenvolvimento:

- **Sintonia Automática de Covariâncias:** Implementação de algoritmos de otimização adaptativa, baseados em Filtros de Kalman baseados em inovação ou métodos de máxima verossimilhança, para estimar recursivamente as matrizes $\mathbf{Q}$ e $\mathbf{R}$ (Ver [12]).
- **Validação em Sistemas Heterogêneos:** Substituição das equações de linearização por amostragem determinística através do Filtro de Kalman *Unscented* (UKF) e Filtros de Partículas (PF), avaliando o custo computacional e o tempo de convergência em hardware embarcado.
- **Integração Baseada em Região de Interesse (ROI):** Aplicação do vetor de estado e da elipse de incerteza validados pelo EKF para delimitar janelas de busca dinâmica em algoritmos de visão computacional, com foco no aumento de eficiência de processamento em quadros por segundo.

REFERÊNCIAS

- [1] DECEA – Departamento de Controle do Espaço Aéreo, “Glossário DECEA: Multilateração,” 2026. [Online]. Available: <https://www.decea.mil.br/index.cfm?i=utilidades&p=glossario&single=2282>
- [2] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [3] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [4] F. Caron, E. Duflos, D. Pomorski, and P. Vanheeghe, “Gps/imu data fusion using multisensor kalman filtering: Introduction of contextual aspects,” *Information Fusion*, vol. 7, no. 2, pp. 221–230, 2006. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S156625350400065X>
- [5] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME–Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [6] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [7] D. Simon, *Optimal State Estimation: Kalman, H_∞, and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [8] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [9] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.
- [11] Z. Chen, C. Heckman, and S. Julier, “Weak in the nees?: Auto-tuning kalman filters with bayesian optimization,” 2018. [Online]. Available: <https://arxiv.org/abs/1807.08855>
- [12] L. Zhang, D. Sidoti, A. Bienkowski, K. R. Pattipati, Y. Bar-Shalom, and D. L. Kleinman, “On the identification of noise covariances and adaptive kalman filtering: A new look at a 50 year-old problem,” *IEEE Access*, vol. 8, pp. 59 341–59 388, 2020.
- [13] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [14] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.

APÊNDICE A

MATERIAL SUPLEMENTAR E REPOSITÓRIO DO CÓDIGO

O código-fonte do simulador (GUI Python, trajetórias e EKF), os gráficos de alta resolução (NIS) e a ferramenta interativa para ajuste das matrizes $\mathbf{Q}$ e $\mathbf{R}$ em tempo real estão disponíveis publicamente no repositório [10]:

<https://github.com/SauloJose/PASKalmanTraj>

APÊNDICE B

DISCRETIZAÇÃO DA MATRIZ DE RUÍDO DO PROCESSO

No domínio contínuo, a dinâmica do modelo Posição-Velocidade-Aceleração (PVA) considera um ruído branco gaussiano $\mathbf{w}(t)$ com matriz de densidade espectral de potência diagonal $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$, que define a intensidade do ruído em cada eixo e suas derivadas.

Para implementar o Filtro de Kalman Estendido (EKF) em tempo discreto com período de amostragem Δt , esse ruído contínuo deve ser integrado ao longo do intervalo $[0, \Delta t]$. A matriz de covariância do ruído discreto, $\mathbf{Q}$, é calculada pela integral:

$$\mathbf{Q} = \int_0^{\Delta t} \mathbf{F}(\tau) \mathbf{Q}_c \mathbf{F}^T(\tau) d\tau \quad (19)$$

Para o modelo PVA bidimensional, a matriz de transição de estados contínua $\mathbf{F}(\tau)$ é dada por:

$$\mathbf{F}(\tau) = \begin{bmatrix} 1 & 0 & \tau & 0 & \frac{\tau^2}{2} & 0 \\ 0 & 1 & 0 & \tau & 0 & \frac{\tau^2}{2} \\ 0 & 0 & 1 & 0 & \tau & 0 \\ 0 & 0 & 0 & 1 & 0 & \tau \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (20)$$

Resolvendo a integral termo a termo com a substituição de $\mathbf{F}(\tau)$ e $\mathbf{Q}_c$, obtém-se a matriz discreta final $\mathbf{Q}$:

$$\mathbf{Q} = \begin{bmatrix} q_1 \frac{\Delta t^5}{20} & 0 & q_3 \frac{\Delta t^4}{8} & 0 & q_5 \frac{\Delta t^3}{6} & 0 \\ 0 & q_2 \frac{\Delta t^5}{20} & 0 & q_4 \frac{\Delta t^4}{8} & 0 & q_6 \frac{\Delta t^3}{6} \\ q_1 \frac{\Delta t^4}{8} & 0 & q_3 \frac{\Delta t^3}{3} & 0 & q_5 \frac{\Delta t^2}{2} & 0 \\ 0 & q_2 \frac{\Delta t^4}{8} & 0 & q_4 \frac{\Delta t^3}{3} & 0 & q_6 \frac{\Delta t^2}{2} \\ q_1 \frac{\Delta t^3}{6} & 0 & q_3 \frac{\Delta t^2}{2} & 0 & q_5 \Delta t & 0 \\ 0 & q_2 \frac{\Delta t^3}{6} & 0 & q_4 \frac{\Delta t^2}{2} & 0 & q_6 \Delta t \end{bmatrix} \quad (21)$$

Essa formulação garante que as correlações cruzadas entre posição, velocidade e aceleração sejam preservadas ao longo do tempo (termos fora da diagonal principal), mantendo a consistência matemática das elipses de incerteza do EKF durante a etapa de predição do filtro.

APÊNDICE C

MAPEAMENTO VISUAL E ESTATÍSTICO COMPLETO

Este apêndice reúne os gráficos das trajetórias espaciais e a evolução temporal do NIS para os seis cenários testados. A sequência de imagens permite comparar diretamente a precisão e a consistência do EKF sintonizado com o filtro descalibrado. Com isso, fica evidente o impacto visual da parametrização incorreta sobre as elipses de incerteza e os erros do sistema.




Figura 10: Trajetórias estimadas na **condição sintonizada**. Observa-se o rastreamento preciso da dinâmica do alvo e a mitigação contínua do ruído de observação, evidenciando o desempenho ideal do filtro.




Figura 11: Trajetórias estimadas na **condição não sintonizada**. Notam-se divergências significativas em relação à verdade terrestre (*ground truth*), com evidentes atrasos de fase e sobreposições bruscas nas curvas.




Figura 12: Evolução temporal da métrica RMSE para a **condição sintonizada**




Figura 13: Evolução temporal da métrica RMSE para a **condição não sintonizada**.




Figura 14: Evolução temporal da métrica NIS para a **condição sintonizada**. A estatística mantém-se predominantemente abaixo do limite de confiança de 95% (linha tracejada em 9,49), comprovando a consistência interna do estimador.




Figura 15: Evolução temporal da métrica NIS para a **condição não sintonizada**. A constante violação do limiar estatístico evidencia a degradação estrutural e a perda de confiança na matriz de covariância preditiva.




Figura 16: Distribuição dos resíduos (histogramas) para a **condição sintonizada**. Os perfis mantêm forte aderência à distribuição normal, indicando que as inovações do filtro são não viesadas.







Figura 17: Distribuição dos resíduos (histogramas) para a **condição não sintonizada**. Observa-se a acentuada perda de normalidade e o surgimento de assimetrias, o que caracteriza um comportamento subótimo.




(a) Círculo




(b) Quadrado




(c) Tangente Hiperbólica



(d) Lemniscata




(e) Aleatória




(f) Oclusão


Figura 18: Gráficos de dispersão (*scatter plots*) das inovações para a **condição sintonizada**. Os pontos concentram-se simetricamente em torno da origem, refletindo a eficácia do estimador na modelagem do ruído.




(a) Círculo




(b) Quadrado




(c) Tangente Hiperbólica



(d) Lemniscata



(e) Aleatória



(f) Oclusão

Figura 19: Gráficos de dispersão das inovações para a **condição não sintonizada**. A dispersão irregular e o distanciamento acentuado da origem denotam a introdução de viés e a imprecisão preditiva do modelo.