

Rastreamento Bidimensional de Alvos via Filtro de Kalman Estendido em Sistemas de Posicionamento por Estações Base

Saulo José Almeida Silva, *Mestrando, UFCG,*

Resumo—A localização precisa é um requisito fundamental para a operação autônoma de sistemas robóticos móveis. Este trabalho apresenta o desenvolvimento, a implementação e a análise rigorosa de um Filtro de Kalman Estendido (EKF) aplicado ao rastreamento bidimensional de alvos utilizando medições não lineares de distância (*range-only*). Fundamentado em um modelo cinemático de Posição-Velocidade-Aceleração (PVA), o estimador foi avaliado por meio de um ambiente de simulação em Python. A arquitetura viabiliza o monitoramento contínuo da acurácia posicional (RMSE), da consistência estatística via *Normalized Innovation Squared* (NIS) e da validação espacial de crença através da Taxa de *Inliers*. Os resultados demonstram que, sob sintonia adequada das matrizes de processo ($\mathbf{Q}$) e medição ($\mathbf{R}$), o EKF atinge precisão submétrica e robustez contra oclusões temporárias. Em contraste, a descalibração paramétrica revela um desacoplamento perigoso: subestimar $\mathbf{R}$ gera falsas altas taxas de *inliers* enquanto corrompe o NIS, e subestimar $\mathbf{Q}$ induz a atrasos de fase severos. Conclui-se que cruzar métricas geométricas e estatísticas é imperativo para atestar a verdadeira confiabilidade do filtro.

Index Terms—Filtro de Kalman Estendido, Localização em Tempo Real, Posicionamento *Range-Only*, Consistência Estatística.

I. INTRODUÇÃO

A O passo que os sistemas robóticos autônomos assumem tarefas mais complexas, cresce também a exigência por soluções de navegação precisas e confiáveis. Para mitigar as incertezas inerentes a esse processo, a literatura tem apostado fortemente em arquiteturas de fusão sensorial — que combinam dados de múltiplos sensores — associadas a análises estatísticas das medições. Essa integração tem se mostrado essencial para refinar a estimativa de estado do sistema e viabilizar sua aplicação no mundo real [1], [2].

O grande desafio no desenvolvimento dessas soluções de localização está nos erros instrumentais e nos ruídos estocásticos que afetam a dinâmica do robô. Mesmo sob uma modelagem cinemática detalhada, perturbações ambientais e não-linearidades — presentes tanto na resposta física dos sensores quanto na própria dinâmica veicular — acabam inserindo margens inevitáveis de imprecisão no estado estimado.

Para contornar essa limitação e obter estimativas de alta fidelidade, utiliza-se o Filtro de Kalman (KF), um estimador ótimo iterativo para sistemas lineares sob o critério do erro quadrático mínimo [3]. Como parte da família dos filtros

bayesianos, o KF estima variáveis de estado não mensuradas diretamente, o que viabiliza sua aplicação em cenários de observabilidade incompleta [4]. Essa formulação clássica, no entanto, é limitada em sistemas de posicionamento baseados em distância (alcance), cujas equações de observação são essencialmente não-lineares. Nesses cenários, aplica-se o Filtro de Kalman Estendido (EKF), que contorna a não linearidade por meio da linearização do modelo em torno da estimativa corrente [4], [5].

Embora o EKF possua uma fundamentação teórica consolidada, seu sucesso prático depende diretamente do ajuste das matrizes de covariância do processo ($\mathbf{Q}$) e de medição ($\mathbf{R}$). A sintonia desses parâmetros requer simulações computacionais detalhadas, etapa essencial no desenvolvimento de sistemas de navegação. Um exemplo dessa abordagem é o trabalho de Falek e Kaniewski [6], que propuseram um ambiente em MATLAB para avaliar o comportamento do EKF em redes de posicionamento baseadas em estações fixas.

Nesse contexto, este trabalho apresenta um simulador em Python voltado à análise do rastreamento bidimensional de alvos via quatro estações base. A ferramenta integra uma GUI interativa para avaliar a acurácia posicional (RMSE), a consistência estatística (NIS) e o comportamento da crença do robô (Taxa de *Inliers*). Para detalhar essa abordagem, o artigo está estruturado da seguinte forma: a Seção II revisa a fundamentação do EKF; a Seção III detalha a modelagem cinemática proposta; a Seção IV descreve a metodologia e as métricas de validação; a Seção V discute os resultados comparativos de sintonia; e a Seção VI apresenta as conclusões e trabalhos futuros.

A. Notação e Convenções

Neste trabalho, adota-se a seguinte convenção de notação: escalares são representados por letras minúsculas em itálico (a), vetores por minúsculas em negrito ($\mathbf{a}$ ou $\hat{\mathbf{x}}$) e matrizes por maiúsculas em negrito ($\mathbf{A}$ ou $\mathbf{P}$).

No domínio discreto, o subscrito k denota a variável física real no instante de tempo atual (como o estado $\mathbf{x}_k$ ou a medição $\mathbf{z}_k$). Por outro lado, os estados e as covariâncias calculados pelo estimador utilizam uma notação composta:

- $k|k-1$: indica os valores *a priori* (etapa de predição), computados a partir do histórico do sistema até o instante $k-1$, tais como o estado predito $\hat{\mathbf{x}}_{k|k-1}$ e a covariância do erro $\mathbf{P}_{k|k-1}$.
- $k|k$: representa os valores *a posteriori* (etapa de correção), atualizados após a incorporação da nova

medição, tais como o estado corrigido $\hat{\mathbf{x}}_{k|k}$ e a covariância do erro $\mathbf{P}_{k|k}$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta a base teórica para o problema de estimativa de estados em robótica. O texto parte da modelagem determinística ideal e avança para os filtros probabilísticos usados na mitigação de incertezas em sistemas reais. Inicialmente, são apresentados os conceitos de sistemas dinâmicos e as fontes de ruído que afetam o comportamento do robô. Em seguida, introduz-se a definição de crença (*belief*) sob a suposição de Markov, o que fundamenta a relação geométrica entre a matriz de covariância e a região de incerteza do agente. Por fim, são discutidos o modelo Gauss-Markov, a discretização temporal, as formulações do Filtro de Kalman (Linear e Estendido) e as métricas para validação do estimador.

A. Sistemas Dinâmicos e Modelagem Determinística

A modelagem de robôs móveis para navegação e controle costuma utilizar a representação em espaço de estados. No domínio do tempo contínuo, a evolução do vetor de estados ocultos $\mathbf{x}(t) \in \mathbb{R}^n$ e as medições ideais do sistema são descritas por equações diferenciais e algébricas [7], na forma:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{h}(\mathbf{x}(t)) \quad (1)$$

onde $\mathbf{u}(t) \in \mathbb{R}^m$ é o vetor de entradas de controle e $\mathbf{z}(t) \in \mathbb{R}^d$ é o vetor de medições. Se as funções $\mathbf{f}$ e $\mathbf{h}$ forem lineares, o sistema pode ser escrito em sua forma canônica:

$$\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{H}_c \mathbf{x}(t) \quad (2)$$

As matrizes $\mathbf{A}_c$, $\mathbf{B}_c$ e $\mathbf{H}_c$ definem a dinâmica, a entrada e a observação contínuas [7]. Essa abordagem determinística assume sensores perfeitos e um modelo físico exato, desconsiderando os ruídos e distúrbios comuns em ambientes reais.

B. Sistemas Estocásticos e Fontes de Incerteza

Na prática, os sistemas robóticos sofrem perturbações que inviabilizam o uso de modelos puramente determinísticos. Essas incertezas vêm de duas fontes principais [2]:

- 1) **Ruído de Processo (ϵ):** Representa distúrbios dinâmicos, forças ambientais (como atrito variante, irregularidades no solo e correntes de ar) e erros de modelagem que afetam a locomoção do robô.
- 2) **Ruído de Medição (δ):** Agrupa as incertezas dos próprios sensores. Em sistemas de localização por radiofrequência ou acústicos, decorre de efeitos de multicaminho, ruído térmico nos circuitos, atenuação de sinal e falhas de calibração [8].

Com a inclusão desses ruídos, o estado deixa de ser um ponto exato e passa a ser tratado como uma variável aleatória. A evolução temporal do sistema e as leituras dos sensores passam a ser modeladas por densidades de probabilidade condicionais:

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (3)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (4)$$

onde $k \in \mathbb{N}$ indica o passo de tempo discreto. O tratamento matemático dessas incertezas garante que os estimadores operem de forma estável mesmo sob condições severas [6].

C. Robótica Probabilística, Suposição de Markov e a Crença (*Belief*)

Para lidar com as incertezas de modelos e sensores, a robótica probabilística calcula a crença (*belief*) do robô a respeito de seu próprio estado. O *belief* é a distribuição de probabilidade a posteriori do vetor de estados $\mathbf{x}_k$, condicionada ao histórico de comandos enviados e medições recebidas [4]:

$$\text{bel}(\mathbf{x}_k) = P(\mathbf{x}_k | \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (5)$$

Para viabilizar o cálculo dessa distribuição em tempo real, aplica-se a **Suposição de Markov**. Esse postulado assume que o estado atual $\mathbf{x}_k$ é uma estatística suficiente do sistema, contendo toda a informação do passado. Assim, o estado futuro depende apenas do estado presente e da ação atual, o que simplifica a probabilidade condicional para:

$$P(\mathbf{x}_k | \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (6)$$

A propriedade de Markov permite dividir o cálculo do *belief* de forma recursiva em duas etapas: predição e correção, que formam a estrutura dos filtros de estimação sequenciais [4].

D. O Modelo Gauss-Markov

O cálculo das distribuições probabilísticas torna-se tratável quando o sistema segue o Modelo Gauss-Markov. Esse modelo define um processo que obedece à propriedade de Markov e cujos ruídos de processo e medição (ϵ_k e δ_k) são gaussianos, brancos e com média nula [9].

A principal vantagem dessa modelagem está na conservação das propriedades estatísticas: transformações lineares aplicadas a variáveis gaussianas geram novas variáveis gaussianas [8]. Com isso, o *belief* $\text{bel}(\mathbf{x}_k)$ permanece estritamente gaussiano ao longo do tempo.

Como uma distribuição gaussiana é definida apenas pelo seu vetor de médias ($\hat{\mathbf{x}}$) e por sua matriz de covariância ($\mathbf{P}$), o problema de rastrear uma função contínua de dimensão infinita resume-se a atualizar esses dois parâmetros a cada passo de tempo discreto.

E. Discretização do Sistema e das Covariâncias

Embora os modelos cinemáticos baseiem-se no tempo contínuo (t), os processadores digitais operam em intervalos discretos Δt . Considerando o vetor de controle $\mathbf{u}(t)$ constante dentro de cada intervalo de amostragem, o sistema linear contínuo $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ é convertido para sua forma discreta equivalente sob o modelo Gauss-Markov [9]:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (7)$$

As matrizes discretas de transição de estados ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) são obtidas a partir das matrizes contínuas pelas relações:

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \left(\int_0^{\Delta t} e^{\mathbf{A}_c \tau} d\tau \right) \mathbf{B}_c \quad (8)$$

Discretização das Covariâncias de Ruído: A amostragem digital também exige a discretização das matrizes de covariância dos ruídos [9]. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se de acordo com a própria dinâmica do sistema. A matriz discreta equivalente, $\mathbf{Q}_k$, é calculada pela integral:

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (9)$$

Para taxas de amostragem altas ($\Delta t \ll 1$), pode-se aproximar essa relação por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, assumindo um crescimento linear da incerteza [9]. No entanto, em modelos cinemáticos de ordem superior — como o espaço de estados Posição-Velocidade-Aceleração (PVA) deste trabalho —, a resolução analítica da Equação (9) é necessária para manter o acoplamento cruzado das incertezas, gerando os termos polinomiais apresentados na Seção III.

Extensão para Sistemas Não Lineares: Se a dinâmica do sistema contínuo for não linear, utilizam-se métodos de integração numérica para a discretização. O método de Euler, por exemplo, resulta na aproximação:

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (10)$$

Para propagar a incerteza gaussiana nesses casos, o modelo aproximado deve ser linearizado localmente por meio de matrizes Jacobianas a cada passo k [4].

F. Filtros de Estimação Baseados em Kalman

O Filtro de Kalman é a solução ótima para propagar e corrigir o *belief* gaussiano em sistemas lineares sob a suposição de Markov. O algoritmo não estima o estado como um ponto fixo, mas rastreia os parâmetros que definem sua distribuição de probabilidade.

1) *Filtro de Kalman Linear:* Com base no modelo Gauss-Markov discreto, a dinâmica e o modelo de observação incorporam os ruídos de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (11)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (12)$$

onde $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O filtro calcula recursivamente o estado corrigido $\hat{\mathbf{x}}_{k|k}$ (média) e sua matriz de covariância $\mathbf{P}_{k|k}$ (incerteza). O processo é dividido em etapas de predição e correção, conforme descrito no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$$

$$2: \mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$3: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$4: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

Se houver oclusão de sinal ou indisponibilidade dos sensores, a etapa de correção (linhas 4 a 6) não é executada. Nessas situações, o filtro opera em malha aberta apenas com a predição cinemática. Como consequência, a covariância $\mathbf{P}_{k|k-1}$ cresce a cada passo, resultando no aumento contínuo do ROI Dinâmico.

2) *Filtro de Kalman Estendido (EKF):* Quando o sistema de localização utiliza distâncias radiais em relação a estações com coordenadas conhecidas, as equações de observação tornam-se não lineares devido à geometria do problema. Nesses cenários, utiliza-se o Filtro de Kalman Estendido (EKF) [4], que aceita funções não lineares genéricas g e h :

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (13)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (14)$$

Para propagar as matrizes de incerteza, o algoritmo utiliza uma expansão em série de Taylor de primeira ordem. Essa linearização local exige o cálculo das matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$ em torno das estimativas atuais:

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \hat{\mathbf{x}}_{k-1|k-1}} \quad (15)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (16)$$

Essas matrizes Jacobianas substituem as matrizes fixas do caso linear na propagação das incertezas e no cálculo do ganho de Kalman ($\mathbf{K}_k$), permitindo o rastreamento em sistemas com não linearidades geométricas (Algoritmo 2).

Algorithm 2 Filtro de Kalman Estendido (EKF)

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow g(\mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$2: \mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$3: \mathbf{P}_{k|k-1} \leftarrow \mathbf{G}_k \mathbf{P}_{k-1|k-1} \mathbf{G}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$4: \mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$6: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}))$$

$$7: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

G. Métricas de Avaliação e Consistência Estocástica

O desempenho do estimador é avaliado por meio de métricas de precisão geométrica e testes estatísticos baseados nos resíduos da inovação [8].

1) *Root Mean Square Error (RMSE)*: A precisão geométrica espacial nas trajetórias bidimensionais é medida pela Raiz do Erro Quadrático Médio (RMSE). O RMSE calcula a distância euclidiana média entre o estado real $\mathbf{x}_k$ e o estado corrigido $\hat{\mathbf{x}}_{k|k}$ em um horizonte de N amostras:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (17)$$

Essa métrica também pode ser calculada de forma independente para os eixos cartesianos (X e Y) para identificar a direção de eventuais falhas de rastreamento.

2) *Normalized Innovation Squared (NIS)*: A precisão medida pelo RMSE não garante que o estimador seja consistente do ponto de vista estatístico. Um filtro é consistente se seus erros de estimação tiverem média nula e covariância compatível com os valores teóricos calculados pelo próprio algoritmo [8]. O teste do quadrado da inovação normalizada (NIS) verifica se a incerteza estimada na matriz $\mathbf{P}_k$ condiz com o comportamento real das medições.

A inovação $\boldsymbol{\nu}_k \in \mathbb{R}^d$ representa a diferença entre a medição real e a predição calculada pelo filtro:

$$\boldsymbol{\nu}_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}) \quad (18)$$

A matriz de covariância teórica da inovação, obtida na etapa de correção, é dada por:

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k \quad (19)$$

O escalar NIS (ϵ_k) é calculado pela forma quadrática baseada na distância de Mahalanobis:

$$\epsilon_k = \boldsymbol{\nu}_k^T \mathbf{S}_k^{-1} \boldsymbol{\nu}_k \quad (20)$$

Se o modelo cinemático e as matrizes de ruído ($\mathbf{Q}_k$ e $\mathbf{R}_k$) estiverem adequados, a variável ϵ_k segue uma distribuição Qui-Quadrado (χ^2) com n_z graus de liberdade, onde n_z é a dimensão do vetor de medições $\mathbf{z}_k$ [8].

Quando o histograma empírico dos resultados se mantém dentro dos limites de aceitação da distribuição Qui-Quadrado, o filtro e o ROI Dinâmico são considerados consistentes. Desvios prolongados para fora desses limites indicam erros de parametrização, sinalizando que o filtro está subestimando ou superestimando as incertezas reais do sistema [8].

III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Para analisar o comportamento do EKF quanto à convergência, ajuste de parâmetros e consistência estatística, este estudo delinea um cenário de rastreamento bidimensional baseado exclusivamente em dados de distância (*range-only tracking*) [8]. Essa modelagem expande o método sugerido em [6], descrevendo a movimentação do agente por meio de um modelo cinemático estruturado no espaço de estados de Posição, Velocidade e Aceleração (PVA).

A. Descrição do Problema

O problema abordado consiste em estimar a trajetória de um robô móvel que opera em um plano bidimensional. O agente se desloca dentro de uma arena monitorada por uma infraestrutura de localização local, composta por $M = 4$ estações fixas (âncoras) instaladas em posições conhecidas, denotadas por $\mathbf{p}_i = [X_i, Y_i]^T$ para $i = 1, \dots, 4$. O arranjo completo desse ambiente operacional encontra-se esquematizado na Figura 1.

O robô não possui sensores de odometria ou de velocidade própria, dependendo exclusivamente de medições escalares de distância obtidas via radiofrequência ou ondas acústicas em relação a cada uma das estações. O objetivo do estimador é processar essas observações ruidosas e reconstruir, a cada passo temporal, a posição horizontal (X) e vertical (Y) do agente, estimando também suas componentes de velocidade e aceleração instantâneas.




Figura 1: Representação geométrica do sistema de posicionamento: o agente móvel no espaço bidimensional e os raios de medição (*range-only*) oriundos das quatro estações base fixas nos vértices da arena.

B. Modelo Cinemático de Processo (Espaço de Estados PVA)

Diferentemente de abordagens simplificadas de velocidade constante, o estado do agente móvel no instante discreto k passa a ser representado por um vetor expandido de seis dimensões: $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$. Nessa estrutura, (x_k, y_k) correspondem às coordenadas de posição cartesiana, $(v_{x,k}, v_{y,k})$ às componentes da velocidade linear e $(a_{x,k}, a_{y,k})$ às acelerações instantâneas nos eixos X e Y , respectivamente.

A dinâmica temporal do sistema sob regime de aceleração constante (CA) é integrada ao longo do intervalo de amostragem Δt . Essa operação dá origem à matriz de transição de estados $\mathbf{A}_k$ (6×6), especificada na Equação (21):

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (21)$$

Fatores práticos, tais como o escorregamento de rodas, desalinhamentos mecânicos e irregularidades do terreno, introduzem erros cumulativos na navegação [4]. Na formulação PVA adotada, esse comportamento estocástico é incorporado ao modelo assumindo-se que as perturbações atuam de forma independente sobre os componentes de posição, velocidade e aceleração. Essas fontes de incerteza são sintetizadas pela matriz de covariância de ruído do modelo em tempo contínuo $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$, cuja estrutura diagonal é escolhida para reduzir o esforço computacional.

Ao calcular a discretização analítica desse termo, ponderada pela própria dinâmica veicular no intervalo Δt , obtém-se uma matriz de covariância discreta $\mathbf{Q}_k$ caracterizada por ser esparsa e simétrica. O perfil estritamente diagonal de $\mathbf{Q}_c$ garante o desacoplamento estocástico entre as dinâmicas dos eixos horizontal (X) e vertical (Y). Os elementos não nulos associados aos estados do eixo X (índices 0, 2 e 4) são calculados conforme as relações dispostas na Equação (22):

$$\begin{cases} Q_{0,0} = q_1 \Delta t + q_3 \frac{\Delta t^3}{3} + q_5 \frac{\Delta t^5}{20} \\ Q_{0,2} = Q_{2,0} = q_3 \frac{\Delta t^2}{2} + q_5 \frac{\Delta t^4}{8} \\ Q_{0,4} = Q_{4,0} = q_5 \frac{\Delta t^3}{6} \\ Q_{2,2} = q_3 \Delta t + q_5 \frac{\Delta t^3}{3} \\ Q_{2,4} = Q_{4,2} = q_5 \frac{\Delta t^2}{2} \\ Q_{4,4} = q_5 \Delta t \end{cases} \quad (22)$$

De maneira análoga, os componentes vinculados ao eixo Y (índices 1, 3 e 5) replicam essa mesma estrutura algébrica, utilizando as variâncias espectrais específicas $\{q_2, q_4, q_6\}$ detalhadas na Equação (23):

$$\begin{cases} Q_{1,1} = q_2 \Delta t + q_4 \frac{\Delta t^3}{3} + q_6 \frac{\Delta t^5}{20} \\ Q_{1,3} = Q_{3,1} = q_4 \frac{\Delta t^2}{2} + q_6 \frac{\Delta t^4}{8} \\ Q_{1,5} = Q_{5,1} = q_6 \frac{\Delta t^3}{6} \\ Q_{3,3} = q_4 \Delta t + q_6 \frac{\Delta t^3}{3} \\ Q_{3,5} = Q_{5,3} = q_6 \frac{\Delta t^2}{2} \\ Q_{5,5} = q_6 \Delta t \end{cases} \quad (23)$$

C. Modelo de Observação e Geometria das Estações Base

A partir do arranjo de infraestrutura detalhado na Seção III-A, o vetor de observações obtido a cada passo amostral é estruturado como $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$. A relação geométrica entre o estado cinemático estimado do robô e a distância escalar real até a i -ésima estação fixa é governada por uma função de observação não linear $h_i(\mathbf{x}_k)$, descrita na Equação (24):

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (24)$$

Como o vetor de estado possui seis dimensões e as leituras dependem estritamente das coordenadas de posição (x_k, y_k) , as derivadas parciais da função de medição associadas aos componentes de velocidade e aceleração anulam-se por completo [8]. Sob essas condições, a matriz Jacobiana $\mathbf{H}_k$ (4×6) avaliada a cada iteração assume o formato estabelecido na Equação (25):

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (25)$$

Por fim, para complementar a modelagem matemática do sistema de sensoriamento, a matriz de covariância do ruído de medição é definida como $\mathbf{R}_k = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$. Nessa estrutura, os elementos da diagonal principal representam as variâncias dos erros instrumentais intrínsecos de cada âncora de leitura, assumindo-se a independência estatística entre as medições para viabilidade computacional.

D. Cenário de Desafio: Modelagem de Oclusão Temporal

Para avaliar os limites do estimador e a utilidade prática da região de interesse (ROI) dinâmica e do teste NIS, projetou-se uma janela de oclusão severa no ambiente de simulação. Dentro de um intervalo cronometrado $t \in [t_{\text{start}}, t_{\text{end}}]$, as leituras vindas das quatro estações base são intencionalmente suprimidas ($\mathbf{z}_{i,k} \rightarrow \emptyset$).


Esse bloqueio — cujo comportamento é ilustrado na Figura 2 — força o algoritmo a depender apenas das projeções geradas pela matriz de transição PVA (21). Sob condições normais de operação com o filtro atualizando as medições, a elipse mantém-se estável e restrita (Figura 2a). Contudo, sem o suporte das correções trazidas pelos sensores durante a oclusão, as incertezas de aceleração modeladas em $\mathbf{Q}_k$ acumulam-se rapidamente. O resultado direto é uma expansão geométrica acentuada na matriz de covariância predita ($\mathbf{P}_{k|k-1}$), que se traduz no alargamento progressivo da elipse de confiança (ROI) ao longo do deslocamento do robô, variando conforme a trajetória realizada (Figuras 2b e 2c).

IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo detalha a metodologia utilizada para avaliar o desempenho, a sensibilidade e a robustez à oclusão do estimador proposto. A apresentação segue a ordem lógica dos experimentos: inicialmente, descreve-se a geração cinemática das trajetórias de referência. Em seguida, detalham-se os cenários de teste e a modelagem do filtro. Por fim, definem-se as métricas estatísticas aplicadas na avaliação do Filtro de Kalman Estendido (EKF) sob diferentes parametrizações.

A. Síntese Cinemática das Trajetórias de Referência

Para que a precisão do Filtro de Kalman Estendido (EKF) possa ser avaliada, é indispensável compará-lo a um referencial absoluto e livre de ruídos, o *Ground Truth*. Nessa etapa, o simulador atua como um gerador de gabaritos: ele



(a) Operação nominal: predição e atualização. (b) Oclusão: trajetória 1 (predição pura). (c) Oclusão: trajetória 2 (predição pura).

Figura 2: Representação visual da incerteza do EKF (ROI dinâmica): a elipse em cinza denota a incerteza predita ($\mathbf{P}_{k|k-1}$), enquanto a elipse em verde representa a incerteza atualizada após a correção ($\mathbf{P}_{k|k}$). (a) Regime de operação estável sob observações contínuas; (b) e (c) expansão da incerteza e degradação da precisão decorrentes da supressão das medições (occlusão temporal) em distintos perfis de trajetória.

calcula a física exata do alvo para cada instante discreto k e armazena essas informações no vetor de estado $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$, que engloba as posições, velocidades e acelerações reais nos eixos ortogonais.

Como um alvo em uma aplicação real pode apresentar desde um trajeto altamente previsível até manobras bruscas, o simulador foi projetado para testar os limites do estimador utilizando duas abordagens distintas de movimento:

- **Curvas paramétricas analíticas (Determinísticas):** Simulam cenários onde o alvo obedece a regras geométricas bem definidas e contínuas. Servem para testar o filtro sob dinâmicas estáveis e previsíveis.
- **Modelos numéricos comportamentais (Estocásticos):** Inserem aleatoriedade na navegação do alvo. Servem para testar a capacidade de adaptação do EKF quando o objeto realiza trajetórias erráticas ou mudanças repentinas de direção.

O conjunto completo dessas trajetórias, abrangendo todos os perfis cinemáticos abordados nos testes, pode ser visualizado na Figura 3.

1) *Geração de Curvas Paramétricas e Analíticas:* Para os testes com movimentos contínuos e regulares, as posições do alvo no simulador são ditadas por funções trigonométricas e hiperbólicas dependentes do tempo. Um cuidado fundamental nessa etapa foi evitar o cálculo numérico das derivadas. Para garantir que o *Ground Truth* seja matematicamente exemplar e livre de erros de discretização, a velocidade e a aceleração do alvo são extraídas a partir da diferenciação analítica exata das equações de posição, conforme detalha o Algoritmo 3.

As trajetórias com quinas, como o percurso quadrado, obedecem a esse mesmo rigor determinístico. A única diferença é que a modelagem utiliza segmentos de reta conectados para formar as arestas, aplicando-se uma restrição geométrica de fechamento para garantir que o alvo retorne exatamente à coordenada onde iniciou o percurso.

2) *Geração de Navegação Aleatória e Oclusões:* Para aproximar a simulação do comportamento estocástico de um alvo real, desenvolveu-se um algoritmo de navegação aleatória. O agente (UGV - Unmanned Ground Vehicle) move-se em linha reta por distâncias mínimas antes de realizar deflexões

Algorithm 3 Geração de Trajetórias Paramétricas Analíticas

Require: Tempo contínuo $t_k = k\Delta t$, Parâmetros geométricos (Amplitude A , Frequência ω)

```

1: for cada instante  $k$  do
2:   if Perfil = Circular then
3:      $\mathbf{p}_k \leftarrow [c_x + R \cos(\omega t_k), c_y + R \sin(\omega t_k)]^T$ 
4:   else if Perfil = Mudança de Faixa (Tanh) then
5:      $\mathbf{p}_k \leftarrow [v_x t_k, c_y + A \tanh(S \cdot t_k)]^T$ 
6:   else if Perfil = Lemniscata then
7:      $\mathbf{p}_k \leftarrow [c_x + A \sin(\omega t_k), c_y + \frac{A}{2} \sin(2\omega t_k)]^T$ 
8:   end if
9:    $\mathbf{v}_k \leftarrow \frac{d}{dt} \mathbf{p}_k$ 
10:   $\mathbf{a}_k \leftarrow \frac{d}{dt} \mathbf{v}_k$ 
11:   $\mathbf{x}_k \leftarrow [\mathbf{p}_k^T, \mathbf{v}_k^T, \mathbf{a}_k^T]^T$ 
12: end for
```

Ensure: Sequência de estados reais $\mathbf{x}_{1:N}$

suaves. Se o robô atinge os limites da arena (raio superior a 35 metros), um mecanismo de evasão direciona o movimento de volta ao centro, mantendo o robô na área útil.

Como as mudanças de direção são aleatórias, a aceleração de referência é calculada por diferenciação numérica discreta, conforme estruturado no Algoritmo 4.

B. Cenários de Simulação e Estratégia de Sintonia

Para avaliar o estimador na prática, a campanha de testes foi dividida em **6 cenários cinemáticos** (ilustrados na Figura 3), abrangendo diferentes perfis de aceleração e condições de oclusão. Além do movimento do alvo, o comportamento do EKF depende diretamente das suas matrizes de covariância ($\mathbf{Q}_k$ para o processo e $\mathbf{R}_k$ para a medição). Para testar a robustez e a sensibilidade do algoritmo a esses parâmetros, cada cenário foi avaliado sob **duas condições de sintonia distintas**:

- 1) **Situação Sintonizada (Filtro Calibrado):** Representa a condição de funcionamento ideal do rastreador. Os valores das matrizes foram ajustados de forma empírica, baseando-se nas propriedades do ambiente e refinados




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos.

Algorithm 4 Geração de Navegação Dinâmica Aleatória

Require: Vetor posição central $\mathbf{p}_c$, Limite da arena $R_{\max}$, Ruído cinemático w

```

1: for cada instante  $k$  do
2:   if Distância percorrida  $> D_{\min}$  then
3:     if  $\|\mathbf{p}_{k-1} - \mathbf{p}_c\| > R_{\max}$  then
4:        $\theta_{\text{alvo}} \leftarrow$  Ângulo forçado em direção a  $\mathbf{p}_c$ 
5:     else
6:        $\theta_{\text{alvo}} \leftarrow \theta_{k-1} + \mathcal{U}(-\frac{\pi}{3}, \frac{\pi}{3})$ 
7:     end if
8:      $v_{\text{alvo}} \leftarrow v_{\text{base}} + \mathcal{U}(-w, w)$ 
9:   end if
10:   $\theta_k \leftarrow \text{SuavizarTransição}(\theta_{k-1}, \theta_{\text{alvo}})$ 
11:   $v_k \leftarrow \text{SuavizarTransição}(v_{k-1}, v_{\text{alvo}})$ 
12:   $\mathbf{v}_k \leftarrow [v_k \cos(\theta_k), v_k \sin(\theta_k)]^T$ 
13:   $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$ 
14:   $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$ 
15: end for

Configuração Especial para Oclusão Cíclica:
16: if Modo Oclusão then
17:   Emite uma máscara binária atribuindo valor Falso
   (Oculto) no segmento temporal central de 4 blocos.
18: end if

```

por tentativa e erro até que o filtro apresentasse o melhor desempenho. A matriz de medição foi definida como $\mathbf{R} = 0,09\mathbf{I}_4$ (quadrado do desvio padrão do ruído das torres, $\sigma = 0,30$ m). Por sua vez, a matriz de ruído de processo foi estimada empiricamente como

$\mathbf{Q} = 0,64\mathbf{I}_6$ ($0,8^2$) para acomodar as incertezas da modelagem dinâmica, visto que essa configuração minimizou o erro de estimação de forma satisfatória. O critério de sucesso da sintonia foi a convergência do erro de posição aliada a elipses de confiança visual e estatisticamente coerentes com a trajetória real

2) **Situação Não Sintonizada (Filtro Descalibrado):** Representa falhas na configuração do projeto. Nessa etapa, os valores das matrizes foram intencionalmente alterados por superestimação (Sup.) ou subestimação (Sub.). O objetivo de impor essas condições anormais é avaliar a sensibilidade do estimador, demonstrar o impacto do desalinhamento de covariâncias no erro adaptativo e comprovar a importância de uma sintonia rigorosa.

A Tabela I consolida todas as variáveis utilizadas nos testes: a configuração de movimento do alvo, o nível de ruído físico (σ) simulado nos sensores e os valores numéricos utilizados para sintonizar (ou descalibrar) o EKF em cada um dos seis cenários.

C. Configuração do Estimador e Modelagem do Ruído

O objetivo do filtro é estimar o estado completo do alvo (o vetor PVA $\mathbf{x}_k$, detalhado na Seção III). Para alimentar o algoritmo, o sistema mede a distância do robô até quatro estações rádio-base fixadas nos cantos da arena.

Como nenhum sensor no mundo real é perfeito, o simulador precisa "sujar" as medidas ideais do *Ground Truth*. Para imitar a imprecisão real, o sistema injeta um erro aleatório em cada canal: soma-se à distância exata um ruído gaussiano branco

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Circular	Quadrada	Tanh	Lemniscata	Nav. Aleatória	Oclusão Cíclica
Movimento	$v = 10,0 \text{ m/s}$ $r = 30,0 \text{ m}$	$v = 10 \text{ m/s}$ $L = 40,0 \text{ m}$	$A_y = 20,0 \text{ m}$ $v = 10,0 \text{ m/s}$	$v = 10,0 \text{ m/s}$ $A = 35,0 \text{ m}$	$v_0 = 8,0 \text{ m/s}$ $\epsilon_v = 0,5 \text{ m/s}$	$v = 5,0 \text{ m/s}$ 30 fr/occlusão
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Posição das Torres (x,y)	$B_1[10, 10]; B_2[190, 10]; B_3[190, 130]; B_4[10, 130]$					
Tempo de Simulação (s)	40					
Taxa de Quadros (FPS)	30					
Semente Aleatória (Seed)	42					
Ruído nas Torres (σ)	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$
Matriz Processo $Q_{6 \times 6}$	$0.64I_6$	$0.64I_6$	$0.64I_6$	$0.64I_6$	$0.64I_6$	$0.64I_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1I_4$ (Sup.)	$0,1I_4$ (Sup.)	$0,01I_4$ (Sub.)	$0,09I_4$	$0,01I_4$ (Sub.)	$0,01I_4$ (Sub.)
Matriz Processo $Q_{6 \times 6}$	$0,01I_6$ (Sub.)	$0,01I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,3I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,05I_6$ (Sub.)

Nota: I_n representa a matriz identidade de dimensão $n \times n$, denotando configurações diagonais. A matriz R apresenta um superdimensionamento conservador intencional ($0,9I_4$), não refletindo estritamente a variância do ruído injetado (σ^2). No Cenário 4 (Não Sintonizado), R foi propositalmente mantido inalterado para isolar e avaliar exclusivamente o efeito da subestimação de Q . (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.

de média zero e desvio padrão σ (valores indicados na Tabela I).

Isso resulta no vetor de observação $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$, que contém as quatro distâncias ruidosas que o EKF efetivamente recebe como entrada, conforme a Equação (26):

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (26)$$

É importante destacar que o EKF trabalha diretamente com essas distâncias puras na sua forma não-linear ($\mathbf{z}_k$). No entanto, para que possamos desenhar a posição lida pelos sensores na interface gráfica do simulador, o sistema realiza um cálculo paralelo. Ele pega essas quatro distâncias com ruído e aplica um algoritmo numérico de multilateração por Mínimos Quadrados para estimar uma coordenada cartesiana $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$. Essa coordenada 2D serve estritamente como apoio visual para a tela e para a validação externa, não interferindo nas contas do Filtro de Kalman.

D. Ambiente Computacional e Infraestrutura de Simulação

Para automatizar a execução dos cenários e garantir a reprodutibilidade dos dados, o simulador foi desenvolvido em *Python* (versão 3.10) utilizando uma arquitetura modular, conforme ilustrado na Figura 4. O processamento matricial e a computação vetorizada do EKF foram implementados com a biblioteca *NumPy*.

Conforme detalhado no diagrama, a arquitetura divide-se logicamente entre o núcleo de simulação e a camada de aplicação. O fluxo de execução inicia-se na Interface Gráfica do Usuário (GUI), onde são definidos os parâmetros iniciais, incluindo a sintonia empírica das matrizes de covariância de processo ($\mathbf{Q}_k$) e de ruído de medição ($\mathbf{R}_k$). Esses parâmetros




Figura 4: Diagrama da arquitetura de software da aplicação de simulação, destacando o fluxo de dados entre o gerador de trajetórias, o estimador de estados e a camada de aplicação.

alimentam o bloco *Simulador*, onde o *Gerador de Trajetórias* estabelece a cinemática real do alvo (*ground truth*).

Para avaliar adequadamente a capacidade de estimação do filtro, a trajetória exata é ramificada para dois destinos: o *Gerenciador de Métricas* (servindo como base de comparação para o cálculo de erros) e a *Modelagem do Mundo e das Entidades*. Este último atua como o simulador do sistema de localização, convertendo as posições reais em distâncias ruidosas relativas a quatro torres (multilateração). Essa pseudo-observação ruidosa alimenta, então, a etapa de *Correção* do Filtro de Kalman, que trabalha em malha fechada com a *Predição* estocástica.

A GUI, construída nativamente com a biblioteca *Tkinter*, não se limita à parametrização, atuando também na camada de *Aplicação*. Ela integra o *Visualizador de Vídeo* — que renderiza instantaneamente o vetor de observações e a elipse

de incerteza da região de interesse (ROI) — e os painéis do *Gerenciador de Métricas*, que acompanham as estatísticas de NIS e RMSE. Apesar dessa integração visual para inspeção qualitativa, o núcleo numérico do simulador opera de forma independente, garantindo que as campanhas de teste em lote e a geração de arquivos de log ocorram de forma assíncrona e automatizada.

E. Métodos de Avaliação e Consistência

O desempenho do EKF é avaliado pela sua precisão espacial e consistência estatística. A acurácia geométrica é quantificada pela Raiz do Erro Quadrático Médio (RMSE), calculada de forma independente para os eixos X e Y ao comparar as estimativas *a posteriori* ($\hat{x}_{k|k}$, $\hat{y}_{k|k}$) com o *Ground Truth*. O erro médio com sinal (ME) também é monitorado para identificar eventuais vieses sistemáticos no rastreamento.

Embora a análise espacial meça a exatidão geométrica, ela não garante o equilíbrio estatístico do estimador. Para a validação formal de consistência, utiliza-se o *Normalized Innovation Squared* (NIS). O teste do NIS avalia se a magnitude dos resíduos de inovação é coerente com a incerteza teórica parametrizada nas matrizes de covariância $\mathbf{Q}_k$ e $\mathbf{R}_k$ [8].

1) *Validação da Crença do Estimador (Inlier Rate)*: Como métrica complementar em ambiente de simulação, a convergência da crença (*belief*) do filtro é avaliada graficamente pela taxa de *inliers*. Por depender do *Ground Truth*, essa abordagem restringe-se à calibração e análise do comportamento do modelo frente a dados sintéticos controlados.

Baseando-se no conceito de elipsoide de erro [4], quantifica-se a proporção de frames em que o estado real (x_{GT}, y_{GT}) permanece contido na fronteira de incerteza do filtro. A validação baseia-se na distância de Mahalanobis aplicada sobre a submatriz de covariância de posição *a posteriori* $\mathbf{P}_{\text{pos}} = \mathbf{P}_{k|k}^{(1:2,1:2)}$. Definindo o vetor de erro real como $\tilde{\mathbf{p}}_k = [x_{GT,k} - \hat{x}_{k|k}, y_{GT,k} - \hat{y}_{k|k}]^T$, o estado é classificado como um *inlier* se atender à restrição:

$$\tilde{\mathbf{p}}_k^T (\mathbf{P}_{\text{pos}})^{-1} \tilde{\mathbf{p}}_k \leq M \quad (27)$$

em que M é o valor crítico da distribuição Qui-Quadrado (χ^2) bicaudal com 2 graus de liberdade para o nível de significância adotado.

Para a renderização em tempo real na interface gráfica, a elipse é aproximada por uma janela delimitadora (*bounding box*) baseada no critério 3σ . Os desvios-padrão marginais teóricos são dados por:

$$\sigma_{x,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(1,1)})} \quad (28)$$

$$\sigma_{y,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(2,2)})} \quad (29)$$

Os limites semi-eixais da janela visual (L_x, L_y) incorporam uma constante de salvaguarda inferior $\tau_{\min}$ para evitar o colapso da caixa em cenários de incerteza nula ou falhas de inicialização:

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{filt}}) \quad (30)$$

$$L_y = \max(\tau_{\min}, 3\sigma_{y,\text{filt}}) \quad (31)$$

A Figura 5 ilustra a correlação espacial entre a elipse probabilística (Equação 27) e a janela ortogonal de renderização (Equações 30 e 31), permitindo aferir qualitativamente se a dispersão das estimativas é coerente com a evolução da matriz $\mathbf{P}$.

2) *Análise de Estabilidade Estatística via Limites de Confiança do NIS*: Enquanto a taxa de *inliers* atua como um validador visual externo restrito à simulação, o NIS avalia a estabilidade matemática de forma independente do *Ground Truth*, refletindo a operação real do algoritmo. O teste de hipóteses é governado por um intervalo de confiança bicaudal de 95%, cujos graus de liberdade (*DOF*) dependem do número de torres de recepção ativas na multilateração a cada passo de tempo k .

Para um cenário padrão com 4 graus de liberdade (4 *DOF*), os limites críticos da tabela χ^2 são $\chi_{0.025,4}^2 = 0,484$ (inferior) e $\chi_{0.975,4}^2 = 11,143$ (superior). O histórico do NIS permite classificar o comportamento dinâmico do EKF em três regimes:

- **Filtro Consistente**: O NIS oscila predominantemente dentro dos limites calculados. Espera-se que aproximadamente 95% das amostras temporais residam nessa faixa, validando a representação correta da própria incerteza do filtro.
- **Filtro Otimista (Subestimação do Erro)**: O NIS ultrapassa repetidamente o limite superior. Isso indica que os resíduos reais são significativamente maiores do que a covariância calculada em $\mathbf{P}$, sinalizando que o filtro confia excessivamente no modelo preditivo em detrimento das medições, o que gera risco de divergência.
- **Filtro Pessimista (Superestimação do Erro)**: O NIS permanece abaixo do limite inferior. Nesse estado, a matriz de covariância cresce de forma desproporcional aos resíduos de inovação. O filtro torna-se excessivamente conservador e lento para responder a variações dinâmicas do alvo.

V. RESULTADOS E DISCUSSÃO

Este capítulo detalha a avaliação experimental do Filtro de Kalman Estendido (EKF) ao longo dos seis cenários de navegação propostos na Seção IV. A análise fundamenta-se em métricas de acurácia posicional (RMSE e Erro Máximo), consistência estatística (NIS) e validação espacial (Taxa de *Inliers*). Para avaliar a sensibilidade do algoritmo, os ensaios comparam o EKF com matrizes calibradas em contraponto a uma configuração intencionalmente descalibrada. A Tabela II consolida os indicadores quantitativos obtidos na simulação.

Devido a restrições de formatação, as composições gráficas completas (painéis comparativos de todas as trajetórias estimadas e históricos da métrica NIS para os seis cenários) foram alocadas no **Apêndice B**. Além disso, o código-fonte do simulador, os dados brutos e as imagens em alta resolução estão publicamente disponíveis no repositório do projeto no GitHub¹.

¹Disponível em: <https://github.com/SauloJose/PASKalmanTraj> - Acesso em: 22 jun. 2026.

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	$RMSE_x$ [m]	$RMSE_y$ [m]	E_{max} [m]	μ_x [m]	$\overline{NIS}$	$NIS \in IC$ [%]	TD [%]	TI [%]
CONDIÇÃO SINTONIZADA ($Q = 0,64I_6$; $R = 0,09I_4$)								
Cenário 1	0,11	0,16	0,64	+0,01	3,39	96,33	100,00	100,00
Cenário 2	0,13	0,18	0,58	0,00	3,86	95,84	100,00	96,88
Cenário 3	0,12	0,14	0,58	+0,00	3,34	96,58	100,00	100,00
Cenário 4	0,11	0,15	0,58	+0,01	3,34	97,17	100,00	100,00
Cenário 5	0,11	0,16	0,57	+0,00	3,49	96,58	100,00	100,00
Cenário 6	0,17	0,34	2,62	+0,01	3,40	95,19	90,00	100,00
CONDIÇÃO NÃO SINTONIZADA (Parâmetros Descalibrados)								
Cenário 1	0,23	0,34	0,75	+0,01	6,76	80,25	100,00	10,08
Cenário 2	0,60	0,82	2,24	-0,02	24,07	49,48	100,00	28,07
Cenário 3	0,16	0,20	0,79	+0,00	23,85	26,75	100,00	97,25
Cenário 4	0,14	0,20	0,74	+0,01	25,50	22,67	100,00	93,83
Cenário 5	0,15	0,21	0,73	+0,00	24,14	26,08	100,00	96,25
Cenário 6	0,17	0,33	2,62	+0,01	31,67	15,56	90,00	71,76

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limites bicaudais do NIS a 95% de confiança para 4 G.L. são [0, 484; 11, 143]. TD: Taxa de Detecção; TI: Taxa de *Inliers*.




Figura 5: Representação da métrica de *inliers*. A elipse valida estatisticamente a convergência frente ao Ground Truth, enquanto a janela retangular delimita a incerteza para fins de visualização na GUI.

A. Interface Gráfica e Ambiente de Simulação

A Figura 6 exibe o ambiente de simulação desenvolvido para este estudo. A interface gráfica integra a renderização espacial da arena, a telemetria das posições estimadas face ao *ground truth* e os painéis de monitoramento temporal de RMSE e NIS. Essa estrutura permite a manipulação direta das matrizes de covariância Q e R , viabilizando a análise empírica do impacto da calibração nas elipses de incerteza do filtro.

B. Análise de Acurácia Posicional e Distribuição de Erros

A parametrização do EKF apresentou correlação direta com a mitigação do ruído de observação. Conforme os dados consolidados na Tabela II e as trajetórias detalhadas no Apêndice B, a configuração sintonizada manteve o $RMSE_x$ e o $RMSE_y$ em níveis sub-métricos estritos, com erros em X variando entre 0,11m e 0,13m, e em Y entre 0,14m

e 0,18m nos cenários de visibilidade total. No Cenário 2 (Trajetória Quadrada), caracterizado por descontinuidades severas de aceleração ortogonal nos vértices, a sintonia correta demonstrou robustez ao conter o Erro Máximo Absoluto em 0,58m. Em contrapartida, a configuração não sintonizada sob regime lento ($Q = 0,01$; $R = 0,10$) falhou em acompanhar as transições abruptas, resultando em um salto do RMSE para 0,60m em X e 0,82m em Y , além de registrar um pico de erro máximo de 2,24m devido ao atraso de fase clássico.

A evolução temporal dessa métrica é detalhada na Figura 7, onde a curva de erro da condição calibrada permanece estável e contida dentro da margem operacional prevista.

Para aprofundar a avaliação do comportamento estatístico do estimador, a Figura 8 apresenta o comportamento estocástico dos resíduos de predição. Nos gráficos de dispersão e histogramas associados à condição sintonizada, nota-se que os erros de estimação em X e Y se distribuem assintoticamente como uma normal bivariada, com viés médio estatisticamente nulo ($\mu_x \approx -0,00$ m no cenário do quadrado). Quando a sintonia falha, a distribuição perde a sua característica gaussiana e exibe caudas pesadas ou dispersões deslocadas, refletindo o descompasso geométrico e o atraso de fase na estimação dos estados.

C. Consistência Estatística e Monitoramento do NIS

A coerência entre a incerteza teórica calculada pelo filtro e os resíduos de inovação reais foi avaliada por meio da estatística *Normalized Innovation Squared* (NIS). Para o modelo rastreado por quatro torres ativas (4 graus de liberdade), a esperança teórica do NIS é exatamente $\mathbb{E}[NIS] = 4,0$. O limite crítico superior bicaudal para um nível de confiança de 95% situa-se em $\chi_{0,975,4}^2 = 11,143$.

Como ilustra a Figura 9 e os dados da Tabela II, o EKF sintonizado demonstrou alto equilíbrio e consistência estatística. Os valores médios operacionais ($\overline{NIS}$) flutuaram estavelmente entre 3,34 e 3,86, aproximando-se com rigor do valor teórico esperado de 4,0. As taxas de violação do limite superior permaneceram estritamente controladas (entre 0,75%




Figura 6: Ambiente gráfico desenvolvido em Python. O painel central exibe a cinemática do alvo, ladeado pelos controles de simulação à esquerda e gráficos de monitoramento temporal à direita.





Figura 7: Evolução temporal do RMSE (Cenário 2). A estabilidade da curva reflete a consistência do filtro quando devidamente sintonizado frente a manobras evasivas.

e 2,29%), validando estatisticamente a matriz de covariância do erro de estimação $\mathbf{P}$.


Por outro lado, o perfil não sintonizado exibiu dois comportamentos anômalos distintos: nos cenários de subestimação drástica do ruído de leitura ($R = 0,01$ nos Cenários 3 a 6), o filtro operou em regime severamente otimista. A média do NIS disparou (atingindo 31,67 no Cenário 6), com taxas de violação do limite crítico que superaram 84%. Nos cenários com superestimação de R combinada com redução de Q (Cenários 1 e 2), o filtro tendeu à lentidão e perda de capacidade de resposta, acumulando inovações elevadas que inflaram o NIS para 24,07 no Cenário 2, estourando o limite em mais de 50% das amostras.

D. Região de Confiança e Taxa de Inliers

A Taxa de *Inliers* (TI) quantificou a porcentagem de frames em que o erro real de posicionamento esteve contido dentro da elipse de confiança calculada pelo filtro. Nos cenários



(a) Condição Sintonizada



(b) Condição Não Sintonizada

Figura 8: Histogramas e dispersão dos erros de previsão (Cenário 2). Em (a), a condição sintonizada converge para uma distribuição normal centrada no zero. Em (b), a ausência de calibração induz dispersão irregular e acúmulo de erros de fase.




Figura 9: Comportamento temporal da métrica NIS. A calibração adequada mantém o parâmetro próximo à média teórica (4, 0) e abaixo do limite crítico superior (11, 14).

sintonizados, em decorrência da calibração adequada das covariâncias, a TI apresentou um desempenho satisfatório, atingindo 100,00% nas trajetórias suaves (Cenários 1, 3, 4, 5 e 6) e mantendo-se em um patamar seguro de 96,88% na severa geometria do quadrado. Isso assegura que as elipses geradas pelo estimador refletem de forma fiel a dispersão espacial do erro. Na condição descalibrada dos Cenários 1 e 2, o estreitamento incorreto das elipses combinado ao atraso físico da trajetória fez a região de confiança colapsar, derrubando a TI para níveis alarmantes de 10,08% e 28,07%, respectivamente.

E. Resposta Transitória sob Oclusão (Cenário 6)

O Cenário 6 validou a estabilidade do algoritmo em malha aberta ao impor uma janela de oclusão temporária de sinal, reduzindo a Taxa de Detecção (TD) global para 90%. A Figura 10 detalha o intervalo de interrupção das medições. A modelagem cinemática consistente permitiu que a propagação de estados estimasse a posição puramente preditiva com base nas últimas velocidades calculadas. Embora o afastamento temporário do sinal tenha expandido o erro máximo absoluto para 2,62m no ápice da oclusão, o sistema evitou o colapso numérico e restabeleceu a minimização do RMS imediatamente após a reconexão dos dados, mantendo um RMSE global controlado de 0,17m em X e 0,34m em Y .

VI. CONCLUSÃO

A. Resumo e Principais Constatações

Este trabalho analisou o comportamento de um Filtro de Kalman Estendido (EKF) sob o modelo Posição-Velocidade-Aceleração (PVA) no rastreamento 2D com medições *range-only*. Em condições adequadas de sintonia ($Q = 0,64$ e $R = 0,09$), o sistema apresentou alta precisão espacial (RMSE abaixo de 0,34m) e consistência estatística (NIS dentro do intervalo de confiança em mais de 95% do tempo), além de lidar com robustez em cenários de oclusão graças à inércia mecânica do modelo.

A principal observação, evidenciada ao descalibrar as matrizes intencionalmente, foi o claro desacoplamento entre precisão visual e coerência matemática. Subestimar a covariância de processo ($Q = 0,01$) torna o filtro excessivamente rígido, fazendo a Taxa de *Inliers* desabar para cerca de 10%




Figura 10: Recorte do Cenário 6 sob oclusão temporária. O EKF propaga a cinemática em malha aberta sem divergência crítica.

por gerar elipses de incerteza artificialmente pequenas. Já a subestimação da medição ($R = 0,01$) cria uma falsa sensação de acerto: o filtro persegue o ruído às cegas, mantendo o RMSE baixo e os *Inliers* acima de 93%. No entanto, ele opera em completa inconsistência matemática, uma falha crítica que só é exposta pelo fato do NIS estourar o limite de 11,143.

B. Contribuições

As principais entregas desta pesquisa incluem:

- O desenvolvimento de um ambiente de simulação capaz de renderizar elipses de incerteza e auditar matrizes de covariância em tempo real.
- A consolidação do uso conjunto de RMSE e NIS como ferramenta definitiva de diagnóstico, provando que erros de posição aparentes não bastam para validar o filtro.
- A formulação da Taxa de *Inliers* a partir de uma Região de Interesse (ROI) Dinâmica. Além de mensurar a coerência da crença do robô, essa estratégia pode resultar numa solução para sistemas de visão computacional, permitindo que o algoritmo processe apenas recortes preditivos da imagem.

C. Limitações e Trabalhos Futuros

O estudo limitou-se a modelar os ruídos como puramente gaussianos, desconsiderando distúrbios severos encontrados na prática (como efeitos de *multipath* e NLOS em redes UWB), além de ter adotado um processo de calibração manual empírico.

Para solucionar essas lacunas e expandir o projeto, sugerem-se as seguintes frentes de trabalho:

- **Sintonia Automática:** Implementar algoritmos de otimização matemática (como descida de gradiente ou

algoritmos genéticos) para sintonizar $\mathbf{Q}$ e $\mathbf{R}$ de forma totalmente autônoma.

- **Integração com Visão Computacional Prática:** Empregar a ROI preditiva calculada pelo EKF em fluxos reais de processamento de câmera para quantificar ganhos práticos em *Frames Por Segundo* (FPS).
- **Filtros Avançados:** Comparar este EKF com estimadores que não dependem do cálculo de matrizes Jacobianas para contornar dinâmicas altamente não lineares, como o Filtro de Kalman *Unscented* (UKF) ou Filtros de Partículas.

D. Conclusão Final

Por fim, o projeto de um estimador confiável demonstra que quantificar a incerteza de forma realista é tão importante quanto calcular a posição final do alvo. Conciliar a acurácia posicional do RMSE com a consistência estatística avaliada pelo NIS, em conjunto com a validação espacial da Taxa de *Inliers*, estabelece uma metodologia sólida e segura para o desenvolvimento de algoritmos em robótica móvel e sistemas embarcados.

REFERÊNCIAS

- [1] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [6] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [7] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [8] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [9] D. Simon, *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.

APÊNDICE A

MATERIAL SUPLEMENTAR E REPOSITÓRIO DO CÓDIGO

O código-fonte completo da ferramenta de simulação desenvolvida neste trabalho está disponível publicamente para consulta e reprodução dos testes. O repositório inclui a interface gráfica (GUI) em Python, os scripts de geração das trajetórias e a implementação matemática do EKF.

Também foram disponibilizados no link os gráficos de todas as simulações em alta resolução, incluindo as trajetórias espaciais e as métricas do NIS que não couberam na íntegra ao longo do texto.

O acesso ao código e aos dados adicionais pode ser feito pelo link:

<https://github.com/SauloJose/PASKalmanTra>

No repositório [10], é possível rodar o simulador localmente para interagir com o ajuste das matrizes $\mathbf{Q}$ e $\mathbf{R}$, além de acompanhar a variação dinâmica da janela de ROI e das elipses de incerteza do filtro em tempo real.

APÊNDICE B

MAPEAMENTO VISUAL E ESTATÍSTICO COMPLETO

Este apêndice reúne os gráficos das trajetórias espaciais e a evolução temporal do NIS para os seis cenários testados. A sequência de imagens permite comparar diretamente a precisão e a consistência do EKF sintonizado com o filtro descalibrado. Com isso, fica evidente o impacto visual da parametrização incorreta sobre as elipses de incerteza e os erros do sistema.




Figura 11: Trajetórias estimadas na **condição sintonizada**. Observa-se o rastreamento preciso da dinâmica do alvo e a mitigação contínua do ruído de observação, evidenciando o desempenho ideal do filtro.




Figura 12: Trajetórias estimadas na **condição não sintonizada**. Notam-se divergências significativas em relação à verdade terrestre (*ground truth*), com evidentes atrasos de fase e sobreposições bruscas nas curvas.




Figura 13: Evolução temporal da métrica RMSE para a **condição sintonizada**




Figura 14: Evolução temporal da métrica RMSE para a **condição não sintonizada**.




Figura 15: Evolução temporal da métrica NIS para a **condição sintonizada**. A estatística mantém-se predominantemente abaixo do limite de confiança de 95% (linha tracejada em 9,49), comprovando a consistência interna do estimador.




Figura 16: Evolução temporal da métrica NIS para a **condição não sintonizada**. A constante violação do limiar estatístico evidencia a degradação estrutural e a perda de confiança na matriz de covariância preditiva.




Figura 17: Distribuição dos resíduos (histogramas) para a **condição sintonizada**. Os perfis mantêm forte aderência à distribuição normal, indicando que as inovações do filtro são não viesadas.







Figura 18: Distribuição dos resíduos (histogramas) para a **condição não sintonizada**. Observa-se a acentuada perda de normalidade e o surgimento de assimetrias, o que caracteriza um comportamento subótimo.




(a) Círculo




(b) Quadrado




(c) Tangente Hiperbólica



(d) Lemniscata




(e) Aleatória




(f) Oclusão


Figura 19: Gráficos de dispersão (*scatter plots*) das inovações para a **condição sintonizada**. Os pontos concentram-se simetricamente em torno da origem, refletindo a eficácia do estimador na modelagem do ruído.




(a) Círculo




(b) Quadrado




(c) Tangente Hiperbólica



(d) Lemniscata



(e) Aleatória



(f) Oclusão

Figura 20: Gráficos de dispersão das inovações para a **condição não sintonizada**. A dispersão irregular e o distanciamento acentuado da origem denotam a introdução de viés e a imprecisão preditiva do modelo.